

T.C.
GEBZE YÜKSEK TEKNOLOJİ ENSTİTÜSÜ
MÜHENDİSLİK VE FEN BİLİMLERİ ENSTİTÜSÜ

ÖNSEL BİLGİ KULLANILARAK TIBBİ
GÖRÜNTÜLERDE MAKİNE ÖĞRENMESİ
TABANLI KONTUR BULMA VE NESNE
KONUMLANDIRMA

Ayşe Betül OKTAY

BİLGİSAYAR MÜHENDİSLİĞİ
ANABİLİM DALI

TEZ DANIŞMANI
Doç. Dr. Yusuf Sinan AKGÜL

GEBZE
2011

ÖZET

TEZ BAŞLIĞI: ÖNSEL BİLGİ KULLANILARAK TİBBİ GÖRÜNTÜLERDE MAKİNE ÖĞRENMESİ TABANLI KONTUR BULMA VE NESNE KONUMLANDIRMA

YAZAR ADI: AYŞE BETÜL OKTAY

Bilgisayarla görmemin temel problemlerinden olan nesne saptama ve nesnenin konturlarını bulma, önsel bilginin eklenmesi ile daha başarılı sonuçlar üretmektedir. Literatürde, bilgisayarla görme metodlarına birçok önsel bilgi ekleme yaklaşımı sunulmasına rağmen, farklı türlerdeki önsel bilgileri bir araya getirebilen, çok gürültülü ve problemli kısımların olduğu imgelerde çalışan etkili ve verimli yöntemler çok nadirdir.

Bu tezde, çeşitli tıbbi imgeler için nesne saptama ve kontur bulma işlemlerini farklı önsel bilgilerin eklenmesi ile gerçekleştiren makine öğrenmesi tabanlı yöntemler sunulmuştur. Sunulan yöntemlerde, önsel bilgi hiyerarşik bir şekilde lokal ve global olarak ayrılmıştır. Böylece farklı tiplerdeki bilgileri ekleyerek daha verimli, modüler ve etkin bir şekilde nesne saptama ve kontur bulma işlemlerini gerçekleştirmek amaçlanmıştır.

Geliştirilen ilk yöntem, global şekil ve imge bilgisi ile ekokardiyogramlardan ve kalp MR imgelerinden iç ve dış sol karıncık konturlarını bulmaktadır. Geliştirilen diğer bir yöntem ise kalp duvarının hareketi, görünüş ve uzaklık gibi çeşitli lokal önsel bilgilerle, sol karıncığın geometrik şeklini birleştirerek ekokardiyogramlardan kontur bulmaktadır. Bir başka yöntem de, bel omurga MR imgelerinden lomber omurlar arasındaki disklerin konumlandırılması için geliştirilmiştir. Bu yöntem, disklerin lokal özellikleri ile lomber eğrinin global şeklini birleştirmektedir. Son olarak, MR kalp imgelerinden sol karıncığın yeri bulunmuş ve kalp duvarlarını gösteren skor imgeleri oluşturulmuştur.

Geliştirilen yöntemlerin etkinliği, gerçek tıbbi imgeler ve sentetik imgeler kullanılarak gösterilmiştir. Ayrıca, önsel bilgi kullanmayan metodlarla da deneyler gerçekleştirilmiş ve geliştirilen metodların çok daha başarılı olduğu gösterilmiştir.

SUMMARY

THESIS TITLE: MACHINE LEARNING BASED OBJECT LOCALIZATION AND CONTOUR EXTRACTION IN MEDICAL IMAGES WITH PRIOR INFORMATION

AUTHOR: AYŞE BETÜL OKTAY

Object localization and contour extraction, which are two major problems of computer vision, produce improved and more successful results with the incorporation of prior information. Although there are many prior incorporation methods in the literature, methods that bring different types of priors together and run even in very noisy and problematic images are very rare.

In this dissertation, a number of machine learning based methods for the incorporation of different priors into object localization and contour extraction for different types of medical images are presented. In the methods, the prior knowledge is hierarchically classified as local and global priors. By the incorporation of different types of priors, it is intended to make more efficient, modular, and effective object detection and contour extraction process.

The first proposed method extracts the inner and outer left ventricle borders from echocardiograms and cardiac MR images by employing global shape and image information. A second proposed method brings different types of information like the cardiac motion, appearance, and distance together and detects the left ventricle borders from echocardiograms. Another method is developed to localize discs between the lumbar vertebra with the incorporation of local features of discs and global shape of lumbar curve. Finally, a method that localizes the left ventricle in MR images is developed. Also, score images that show the cardiac borders are generated.

The effectiveness of the developed methods is validated on real medical images and synthetic images. Also, experiments are performed with the methods that do not use prior information and the success of the proposed methods is demonstrated.

TEŞEKKÜR

Bu tez çalışmasının planlanması ve yürütülmesinde ilgi ve desteğini esirgemeyen değerli danışman hocam Doç. Dr. Yusuf Sinan Akgül'e fikirleri, yardımları, tavsiyeleri, destekleri, emekleri ve fedakarlıklarını için ve ayrıca bana olan inancı, güveni ve sabrı için;

Tez izleme komitemde bulunan Prof. Dr. Sadık Kara ve Yrd. Doç. Dr. F. Erdoğan Sevilgen hocalarına tezimin ilerleme aşamasındaki görüşleri, önerileri ve katkılarından dolayı;

Yrd. Doç. Dr. Atakan Kurt'a ve Doç. Dr. Hacı Ali Mantar'a tez jürimde bulunmalarından dolayı;

GYTE bünyesindeki tüm hocalarına ve araştırma görevlisi arkadaşlarına tüm parlak fikirleri, destekleri ve ayrıca huzurlu bir çalışma ortamı sağladıklarından dolayı;

Eşim Melek Oktay'a ve tüm aileme manevi destek ve sabırlarından dolayı;

Bilimin ve bilim insanının destekçisi Türkiye Bilimsel ve Teknolojik Araştırma Kurumu'na maddi desteklerinden dolayı;

çok çok teşekkür ederim.

İÇİNDEKİLER DİZİNİ

	<u>Sayfa</u>
ÖZET	iv
SUMMARY	v
TEŞEKKÜR	vi
İÇİNDEKİLER DİZİNİ	vii
SİMGELER VE KISALTMALAR DİZİNİ	x
ŞEKİLLER DİZİNİ	xii
ÇİZELGELER DİZİNİ	xiii
1 GİRİŞ	1
1.1 Biçim Değiştirebilir Modeller	3
1.2 Önsel Bilgi ile Kontur Bulma	7
1.2.1 Aktif Şekil ve Görünüş Modelleri	8
1.2.2 Biçim Değiştirebilir Modeller ve Önsel Bilgi	10
1.3 Nesne Saptama	13
1.4 Motivasyon ve Katkılar	16
1.5 İçerik	18
2 GLOBAL ŞEKİL ve GÖRÜNÜM ÖNSELİ ile KONTUR BULMA	19
2.1 Önsel Tabanlı Kontur Bulma Çerçevesi	20
2.1.1 Şekil Önseli	21
2.1.2 İmge Önseli	22
2.2 Önsel Bilginin Çevrit Bulma İşlemine Eklenmesi	24
2.3 Deneyler ve Doğrulama	25
2.3.1 Ekokardiyogramlarda Kontur Bulma	25
2.3.2 Kalp MR İmgelerinden Kontur Bulma	30
2.4 Yorumlar	35

3 LOKAL VE GLOBAL ÖNSEL BİLGİ KULLANARAK MAKİNE ÖĞRENMESİ ve DÜZEY KÜMESİ METOTLARIYLA KONTUR BULMA	37
3.1 Giriş	37
3.2 Lokal Önseller	40
3.2.1 Ekokardiyogramlardan Lokal Özniteliklerin Çıkarılması	40
3.2.2 Adaboost ile Eğitilme ve Skor Verme	45
3.3 Düzey Kümesi Metodu ile Global Şekil Bilgisi Eklenmesi	46
3.3.1 Düzey Kümesi Formülasyonu	46
3.3.2 Global Önsel Bilginin Eklenmesi	47
3.4 Deneysel Sonuçlar	48
3.4.1 Ekokardiyografik İmgeler	49
3.4.2 Sentetik İmgeler	54
3.5 Yorumlar	60
4 LOMBER OMURLAR ARASINDAKİ DİSKLERİN OTOMATİK OLARAK SAPTANMASI VE KONUMLANDIRILMASI	63
4.1 Giriş	63
4.2 Disklere Skor Verme İşlemi	65
4.2.1 YGH ile Öznitelik Çıkarımı	67
4.2.2 DVM ile Eğitilme ve Skor Verme İşlemi	68
4.3 Disk Merkezlerinin Konumlandırılması	70
4.3.1 Grafiksel Zincir Benzeri Model	70
4.3.2 Zincir Üzerinde Kesin Çıkarım	72
4.4 Deneysel Sonuçlar	72
4.4.1 Disklere Skor Verme İşlemi Sonuçları	73
4.4.2 Disk Konumlandırma Sonuçları	74
4.5 Yorumlar	75
5 PYGH VE LOKAL ÖZNİTELİKLER KULLANARAK KALP YERİNİ BULMA VE SKOR VERME	80
5.1 PYGH ile Sol Karıncığın Bulunması	81
5.2 Adaboost ile Piksellere Skor Değeri Atama	83

5.3 Deneysel Sonuçlar	84
5.4 Yorumlar	86
6 SONUÇLAR ve YORUMLAR	87
KAYNAKLAR	89
ÖZGEÇMİŞ	97
EK A - Terimler (Türkçe - İngilizce)	98

SİMGELER VE KISALTMALAR DİZİNİ

<i>AŞM</i>	: Aktif Şekil Modeli
<i>AGM</i>	: Aktif Görünüş Modeli
<i>TBA</i>	: Temel Bileşen Analizi
<i>NDM</i>	: Nokta Dağılım Modeli
<i>TDA</i>	: Tekil Değer Ayrışımı
<i>ÇYT</i>	: Çekirdek Yoğunluğu Tahmini
<i>VDM</i>	: Vektör Destek Makineleri
<i>MR</i>	: Manyetik rezonans
<i>BT</i>	: Bilgisayarlı tomografi
<i>NÇİ</i>	: Normalize edilmiş Çapraz İlinti
<i>YGH</i>	: Yönlü Gradyan Histogramı
<i>PYGH</i>	: Piramidal Yönlü Gradyan Histogramı

ŞEKİLLER DİZİNİ

<u>Sekil</u>	<u>Sayfa</u>
1.1 Nesne saptama ve kontur bulma örneği	2
1.2 İki boyutlu bir şeklärin 3 boyutlu yüzeyin sıfırıncı düzeyine katılması	4
1.3 Gelişen bir yüzey ve sıfırıncı düzeyin imge üzerindeki şeklär	6
1.4 AŞM'nin el imgesi üzerinde gelişmesi	9
1.5 AGM ile yüz konturlarını bulma	11
1.6 Nesne saptama çerçevesi	13
1.7 Eğitim kümesindeki örnekler ve onları iki sınıfa ayıran bir hiper-düzlem	15
2.1 Örnek ekokardiyogram ve kalp MR imgesi	20
2.2 Geliştirilen önsel bilgi ekleme çerçevesinin işleyışı.	28
2.3 Kartezyen koordinat sisteminde örnek bir c_i noktası, $\theta(c_i)$ ve $R(c_i)$.	28
2.4 Ekokardiyogramlar ve sistemin sonuçları	31
2.5 Farklı verilerle sistem sonuçları	32
2.6 Kalp MR imgelerinde (kesilmiş) bulunan konturlar	33
2.7 Kalp MR imgelerinde bulunan konturlar	34
3.1 Veri kümesindeki örnek ekokardiyografik imgeler	38
3.2 Kutupsal koordinatlara çevrilmiş bir ekokardiyografik imge	42
3.3 Öznitelik çıkarmak için kullanılan 3 filtre kümesi.	44
3.4 Oluşturulan bir skor imgesi	46
3.5 Uzman konturlarının eğriltimesi	49
3.6 Geliştirilen sistemin çalışma şeması.	50
3.7 Sistem tarafından bulunan ve uzmanlar tarafından çizilen konturlar	55
3.8 Hedef sentetik imgeler ve çeşitli metodların bu imgeler üzerinde çalışmasının sonuçları	56
3.9 Şekil 3.8(a)'daki sentetik imgelerin ROC eğrileri	58
3.10 Şekil 3.8'teki 3 imgeye uygulanan farklı filtre kümelerinin ROC eğrileri	61
4.1 Örnek lomber eğri MR imgesi	66
4.2 Disklere skor verme ve etiketlendirme işleminin akış diyagramı.	69

4.3	Oluşturulan zincir benzeri grafiksel model.	70
4.4	Sistemin disk konumlandırma sonuçları	76
4.5	Sistem ve diğer metodların ortalama uzaklıkları	77
4.6	Disk konumlandırma işleminden bazı görsel sonuçlar	78
4.7	Veri kümesindeki en başarısız konumlandırmalar	78
5.1	Bir kalp MR imgesinde sol karıncık alanı ve epikardiyum ve endokardiyum.	81
5.2	Sol karıncık alanı ve PYGH ile çıkartılmış histogramlar	82
5.3	PYGH ile bulunmuş sol karıncık.	85

ÇİZELGELER DİZİNİ

<u>Çizelge</u>	<u>Sayfa</u>
2.1 Otomatik olarak bulunan kontur-uzman ve uzman-uzman arasındaki piksel farkları.	29
2.2 MR veri kümesi üzerinde noktanın eğriye uzaklığı	33
3.1 Toplam 40 test endokardiyum ve epikardiyum imgesi için ortalama piksel uzaklıklarını (ortalama \pm standart sapma)	53
3.2 Şekil 3.8'deki sentetik imgelerin gürültü seviyeleri.	55
3.3 Şekil 3.8'deki bulunan konturlar ve gerçek kontur arasındaki sayısal piksel farkları.	59
4.1 Geliştirilen sistem ve [Schmidt et al., 2007] için ortalama disk saptama yüzdeleri.	74
4.2 Ortalama disk konumlandırma yüzdeleri.	75

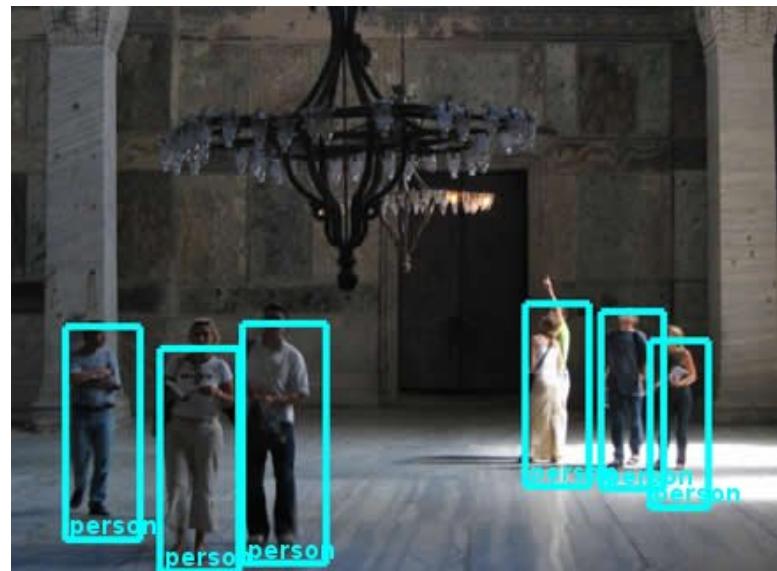
1. GİRİŞ

Nesne saptama ve nesnelerin sınırlarını belirleme, bilgisayarla görme alanındaki temel problemlerdendir. Nesne saptama, imge ya da videoda verilen hedef nesnenin var olup olmadığını ve eğer nesne varsa, o nesnenin konumunu ve boyutunu belirlemektir. Nesnenin sınırlarını belirleme ise, imge ya da videodaki bir nesnenin çevritini (konturunu) bulmaktır. Bilgisayarla görme için bu problemler bakış açısının değişmesi, nesnenin bir kısmının kapanmış olması, nesnenin boyutunun ve ölçüğünün değişmesi gibi nedenlerden dolayı zordur. Şekil 1.1(a)'da verilen bir imgeden insanları saptama sonuçları [Laptev, 2009], Şekil 1.1(b)'de bir imgeden sol karıncık saptama sonucu, Şekil 1.1(c)'de ekokardiyografik bir görüntüden sol karıncığın iç ve dış konturlarını bulma sonucu [Oktay and Akgul, 2009] ve Şekil 1.1(d)'de bir imgeden nesnenin sınırlarını bulma örneği [Rousson and Paragios, 2002] gösterilmiştir.

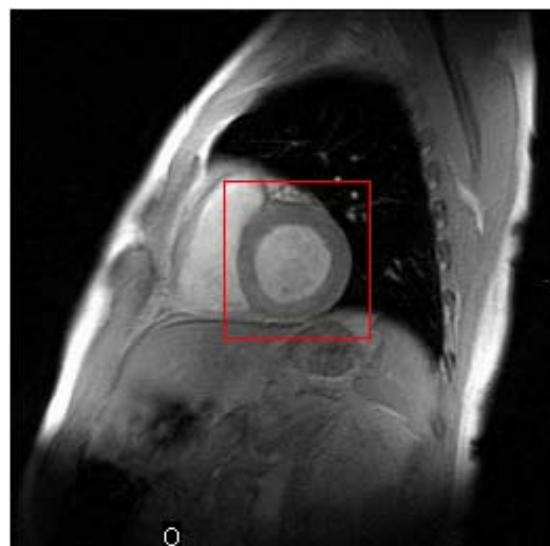
Literatürde, katı nesnelerin (rigid objects) sınırlarını bulmak için Hough dönüşümü [Duda and Hart, 1972] ve şablon eşleştirme [Brunelli, 2009] gibi temel yöntemler kullanılmıştır. Bu yöntemlerle dikdörtgen ve elips gibi sabit şeke sahip cisimler, imge çok fazla gürültülü değilse ve nesne kapanmış (occluded) değilse başarılı bir şekilde bulunabilmektedir. Lakin, dünya üzerindeki çoğu nesne katı şeke sahip olmadığı için bu yöntemler çok kısıtlı kalmaktadır. Katı şeke sahip olmayan nesnelerin sınırlarını belirlemek için ise yılanlar [Kass et al., 1988] ve düzey kümesi [Osher and Sethian, 1988] gibi biçim değiştirebilir modeller kullanılmaktadır.

Literatürde nesne saptama için, görünüş tabanlı yöntemler [Roth and Winter, 2008], öznitelik tabanlı yöntemler [Viola et al., 2003] ve şablon eşleştirme [Trucco and Verri, 1998] gibi teknikler geliştirilmiştir. En popüler metodlardan birisi olan öznitelik tabanlı yöntemler, ilk olarak başka örnek imgelerden nesnenin renk, doku, hareket gibi özniteliklerini çıkarmakta ve makine öğrenmesi teknikleri ile bu öznitelikleri öğrenmektedir. Yeni bir hedef imge verildiğinde, öğrenilen bilgi kullanılarak imgede nesnenin olup olmadığı saptanmaktadır.

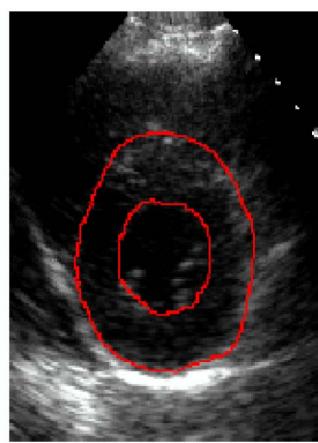
Bu bölümün içeriği şu şekildedir: Bölüm 1.1'de biçim değiştirebilir modeller anlatılmıştır. Bölüm 1.2'de önsel bilginin kontur bulma metotları ile birlikte kullanılması sunulmuştur. Bölüm 1.3'te öznitelik tabanlı nesne saptama anlatılmıştır.



(a)



(b)



(c)



(d)

Şekil 1.1: Örnek (a) insan saptama [Laptev, 2009], (b) sol karıncık saptama, (c) sol karıncık konturunu bulma [Oktay and Akgul, 2009] ve (d) nesne konturu bulma [Rousson and Paragios, 2002] sonucu.

Tezin hazırlanmasındaki motivasyona ve tezin bilime katkılarına Bölüm 1.4'te debynilmiştir. Bölüm 1.5'te ise tezin içeriği sunulmuştur.

1.1. Biçim Değiştirebilir Modeller

Biçim değiştirebilir model, bir imge üzerindeki bir kapalı konturun çeşitli güçlere göre şeklini değiştirebildiği bir modeldir. Yılanlar ve düzey kümesi metodu en popüler iki biçim değiştirebilir model örneğidir.

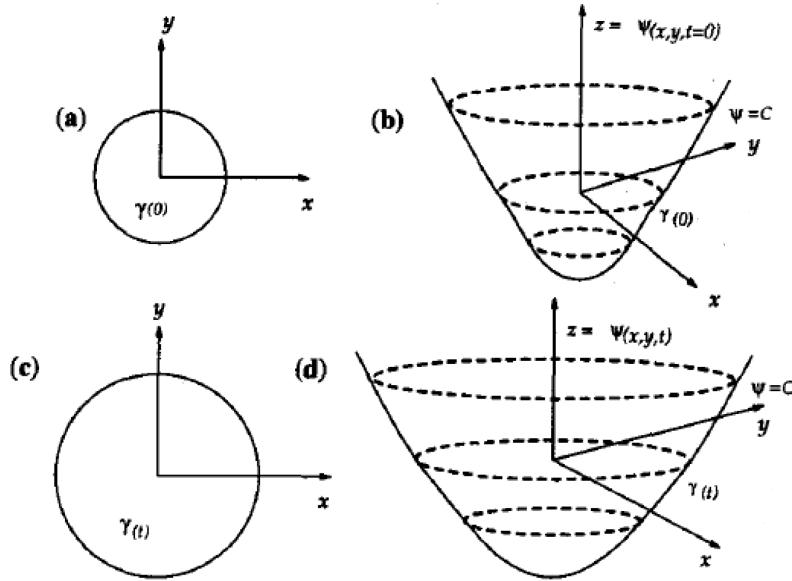
Literatürde, ilk olarak yılan (aktif kontur) adı verilen biçim değiştirebilir model Kass ve diğerleri [Kass et al., 1988] tarafından sunulmuştur. Yılan, imge üzerinde şeklini değiştirip, nesnenin sınırlarına geldiği zaman duran kapalı bir elastik şerit gibi düşünülebilir. Yılan, şekil değiştirmeyi enerji enküüklemesi ile gerçekleştirir. Yılanın enerjisi, iç ve dış güç olmak üzere ikiye ayrılmıştır. Dış güç, imge özelliklerinden gelen imge gradyanı şiddeti gibi değerlere bağlıken, iç güç ise yılanın şeklinin düz olmasını sağlamaktadır.

Yılan iç ve dış güçlerin etkisi ile I imgesini iki parçaya ayıracaktır. Kontur C parametrik bir eğri olsun. C konturu, aşağıda verilen enerji fonksiyonunu enküükleyerek gelişir.

$$E(C) = - \int |\nabla I(C)|^2 ds + \nu_1 \int |C_s|^2 ds + \nu_2 \int |C_{ss}|^2 ds. \quad (1.1)$$

Bu enerji fonksiyonelinde ν_1 ve ν_2 ağırlık parametreleri, C_s eğri parametresi s 'ye göre ilk türevi, C_{ss} de ikinci türevidir. Enerji fonksiyonunda imge gradyanını içeren ilk terim dış güç iken, ikinci ve üçüncü terim konturun sürekliliğini ve düzüğünü sağlayan iç güçlerdir. Bu güçlerin etkisinde, yılan yüksek imge gradyanının olduğu nesne sınırlarına geldiğinde gelişim durur ve böylece nesnenin sınırları bulunmuş olur. Yılanlar üzerinde, enerji fonksiyonu ve enküüklemeye metodu değiştirilerek farklı geliştirmeler de yapılmıştır, fakat burada sadece [Kass et al., 1988]'de verilen temel yılan enerji fonksiyoneline debynilmiştir ve [Trucco and Verri, 1998],[Cremers et al., 2007]'deki anlatım kullanılmıştır.

Yılanlar, kapanmış nesnelerin olmadığı ve gürültüsüz imgelerde başarılı bir şekilde kontur bulma işlemini gerçekleştirirler. Lakin, yılanların bazı eksiklikleri



Şekil 1.2: (a) İki boyutlu bir şeklin (b) $t = 0$ zamanında düzey kümesinin sıfırıncı düzeyine katılması. (c) t zamanında yüzey geliştiğinden sonra sıfırıncı düzeydeki kontur ve (d) gelişen 3 boyutlu yüzey.

bulunmaktadır. İlk olarak, yılanlar ilklendirilmeye bağlıdır. Yani hedef nesneden çok uzağa ilklendirildiğinde, yılan lokal olarak imge gradyanının yüksek olduğu yerlere takılabilmekte ve hedef nesneye ulaşamamaktadır. İkinci olarak, yılanlar topolojik yapısını değiştirememektedir. Dolayısıyla, ilklendirilen iki yılan birleşip bir yılan oluşturamamakta veya birden fazla yılan birleşip tek yılan halini alamamaktadır. Bu yüzden, yılan imge üzerinde sadece bir nesnenin sınırlarını belirleyebilir. Ayrıca, yılanlara anlamlı istatistiksel bilgi eklenmemektedir [Cremers et al., 2007].

Düzey kümesi metodu, yılanlardan sonra sunulmuş [Osher and Sethian, 1988], [Caselles et al., 1993] ve yılanlardaki bazı eksiklikler düzey kümesi metodunda giderilmiştir. Düzey kümesi metodu, nesnelerin şekillerinin (sınırlarının), daha yüksek boyutlu bir yüzeyin sıfırıncı düzeyine katılması fikrine dayanmaktadır. Şekil 1.2'de, Malladi ve diğerleri [Malladi et al., 1995] çalışmasından alınmış, 2 boyutlu bir yuvarlak bir nesne ve bu nesnenin şeklinin 3 boyutlu bir yüzeyin sıfırıncı düzeyine katılmış hali gösterilmiştir. t zamanı ilerledikçe, 3 boyutlu yüzey enerji fonksiyoneline göre şeklini değiştirmiştir (Şekil 1.2(d) haline gelmiş) ve sıfırıncı düzeydeki kontur Şekil 1.2(c)'deki halini almıştır.

Literatürde, düzey kümesi için farklı formülasyonlar bulunmaktadır. Bu tezde,

Li ve diğerleri [Li et al., 2005] tarafından sunulmuş değişimsel formülasyonla düzeykümesi gelişimi gerçekleşmiştir. Bu metot, yeniden ilklendirmeye gerek duymaması, geleneksel düzey kümesi formülasyonlarından daha az karmaşık olması, daha az hesaplama zamanı ve daha az parametreye ihtiyaç duyması gibi avantajlarından dolayı seçilmiştir.

3 boyutlu yüzey ϕ , iç güç terimi $P(\phi)$ ve dış güç terimi $\varepsilon_m(\phi)$ 'den oluşan bir enerji fonksiyonun enküçüklenmesi ile gelişir. Değişimsel enerji fonksiyonu $\varepsilon(\phi)$ şu şekildedir:

$$\varepsilon(\phi) = \mu P(\phi) + \varepsilon_m(\phi). \quad (1.2)$$

İç enerji terimi, düzey kümesi fonksiyonunun bir işaretli uzaklık fonksiyonundan uzaklaşmasını cezalandırır. İşaretli uzaklık fonksiyonunun $|\nabla\phi| = 1$ özelliğini sağlaması gerekmektedir. Dolayısıyla, iç enerji terimi $P(\phi)$ şu şekilde tanımlanmıştır:

$$P(\phi) = \int_{\Omega} \frac{1}{2}(|\nabla\phi| - 1)^2 dx dy. \quad (1.3)$$

$P(\phi)$, yüzey ϕ 'nin, işaretli uzaklık fonksiyonuna yakınlığına göre bir değer alır.

Genellikle, kontur çıkarma işlemlerinde, imgedeki yüksek gradyan şiddetinin değerlerinin olduğu yerler nesnenin sınırları olmalıdır fikri baz alınır. I imgesinde, yüksek gradyan şiddetinin olduğu yerler yani kenarlar için, kenar gösterge fonksiyonu g şu şekildedir:

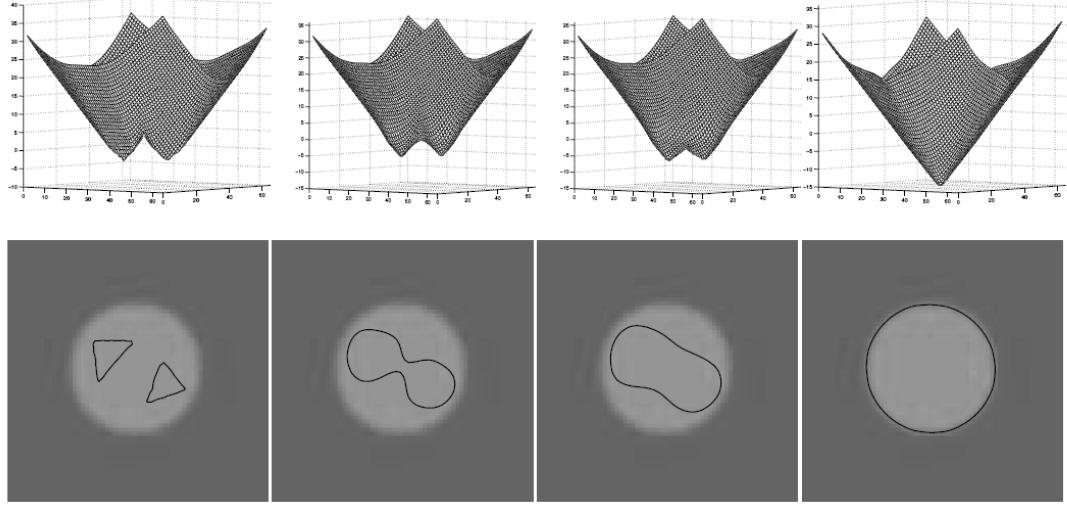
$$g = \frac{1}{1 + |\nabla G_{\sigma} * I|^2}. \quad (1.4)$$

Bu fonksiyonda, G_{σ} standard sapması σ olan bir Gauss çekirdeği, ∇ gradyan ve $*$ konvolüsyon operatöründür.

Dış enerji terimi düzey kümesini nesne sınırlarına doğru çeker. Dış enerji gücü, uzunluk ve alan olmak üzere iki terimden oluşmaktadır.

$$\varepsilon_{g,\lambda,v}(\phi) = \lambda L_g(\phi) + v A_g(\phi), \quad (1.5)$$

λ ve v ağırlık parametreleridir. $L_g(\phi)$, ϕ yüzeyinin sıfırıncı düzeyindeki konturun uzunluğunu, $A_g(\phi)$ ise bu konturun alanını içermektedir ve şu şekilde



Şekil 1.3: Düzey kümesi fonksiyonu ϕ 'nin gelişimi üst satırda, ϕ 'nin sıfırıncı düzeyindeki kontur ve üzerinde geliştiği imge ise alt satırda gösterilmiştir [Li et al., 2005].

tanımlanmışlardır:

$$L_g(\phi) = \int_{\Omega} g\delta(\phi) |\nabla\phi| dxdy, \quad (1.6)$$

$$A_g(\phi) = \int_{\Omega} gH(-\phi) dxdy. \quad (1.7)$$

Uzunluk teriminde kullanılan Dirac(δ) fonksiyonu şöyle tanımlıdır:

$$\delta_\alpha(\phi) = \begin{cases} 0, & |\nabla\phi| > \alpha, \\ \frac{1}{2\alpha}(1 + \cos(\frac{\pi\phi}{\alpha})), & |\nabla\phi| < \alpha. \end{cases} \quad (1.8)$$

Tüm düzey kümesi fonksiyonu $\varepsilon(\phi)$, dik iniş (steepest descent) metodu ile aşağıdaki formül enkükükleñerek bulunur:

$$\frac{\partial\phi}{\partial t} = \mu \left[\Delta\phi - \text{div}\left(\frac{\nabla\phi}{|\nabla\phi|}\right) \right] + \lambda\delta(\phi)\text{div}\left(g\frac{\nabla\phi}{|\nabla\phi|}\right) + vg\delta(\phi). \quad (1.9)$$

Şekil 1.3'de, [Li et al., 2005]'de verilen bir ϕ yüzeyi ve imge üzerinde gelişirken sıfırıncı düzeyindeki kontur gösterilmiştir. Bu şekilde, düzey kümesi metodunun yapı değiştirebilme özelliği açıkça gözükmemektedir.

Düzey kümesi, yılanlarla kıyaslandığında kontur bulma işlemeye büyük yenisilikler getirmiştir, fakat hala eksik kaldığı yönler vardır. İlk olarak, imge gradyan şiddetine göre yüzey geliştiği için gradyan şiddetinin düşük olduğu bölgelerde konturlar doğru bir şekilde bulunamamaktadır. Bazen de kontur, lokal bölgelerdeki yüksek

gradyan şiddetinden dolayı yanlış yerde durmakta ve asıl nesneye ulaşamamaktadır. Bu da metodu, ilklendirmeye bağlı hale getirmektedir. Ayrıca, metot yüksek gürültü seviyelerinden fazla etkilenmekte, bu yüzden katı şekele sahip cisimleri çok da başarılı bulamamaktadır [Rousson and Paragios, 2002].

1.2. Önsel Bilgi ile Kontur Bulma

Biçim değiştirebilir modellerle kontur bulma teknikleri, bir önceki bölümde anlatılan eksikliklerden dolayı kontur bulma işleminde her zaman başarılı olamamaktadır. Özellikle çok gürültülü imgelerde, kapalı nesneler veya nesneyle kesişen ilgisiz parçalar olduğunda hedef imgenin konturu bulunamamaktadır. Hedef nesnenin ne olduğunu önceden belli olduğu durumlarda, nesnelarındaki başka bilgileri de kontur bulma işlemine eklemek nesne sınırlarının daha başarılı bir şekilde bulunmasını sağlamaktadır [Leventon et al., 2000], [Cremers et al., 2007]. Bu şekilde hedef imge ya da nesne hakkında eklenen bilgiye "önsel" ismi verilmektedir. Buradaki "önsel" olasılık teorisinde kullanıldığı üzere veriye bağlı olmayan bir dağılım değildir. Önsel bilgi, kontur çıkarma işleminden evvel hedef imge hakkında öğrenilmiş önceki bilgidir.

Literatürdeki teknikler, bu problemi hedef nesne hakkında şekil önsel bilgisi ekleyerek [Chen et al., 2002], [Paragios, 2003] farklı regularizasyon stratejileri uygulayıp çözmeye çalışmaktadır. Özellikle az imge bilgisinin olduğu yerlerde bu stratejiler kontur bulma işleminin başarısını önemli derecede artırmaktadır. Literatürde ayrıca bilgisayarla görme metodlarına önsel bilgi olarak içerik ekleme ile ilgili bir çok teknik bulunmaktadır [Goferman et al., 2010], [Amores et al., 2004], [Wolf and Bileschi, 2006], [Fink and Perona, 2004].

Bu bölümde, önsel bilgi ile çevrit çıkarımı yapan aktif modeller [Cootes et al., 1995], [Cootes et al., 1998] ve biçim değiştirebilir modellere önsel bilgi eklemek için geliştirilmiş literatürdeki teknikler sunulmaktadır.

1.2.1. Aktif Şekil ve Görünüş Modelleri

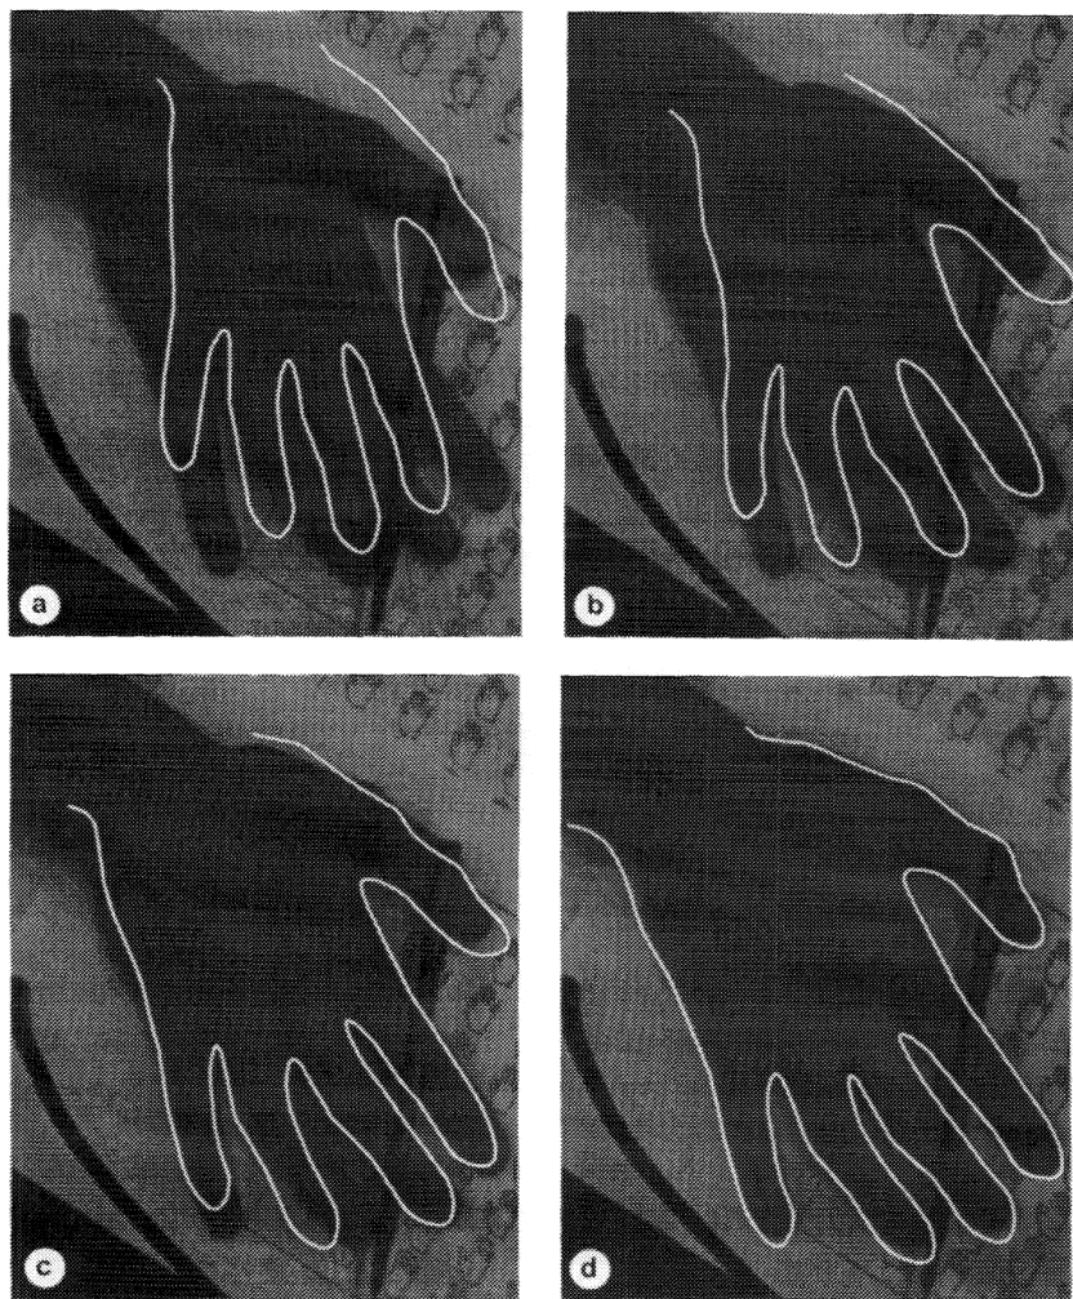
Aktif şekil modeli (AŞM) [Cootes et al., 1995] ve aktif görünüş modelleri (AGM) [Cootes et al., 1998] hedef nesnenin şekil ve görünüş önsel bilgisini kullanarak çözüm uzayını kısıtlayan model tabanlı nesne konumlama metotlarıdır.

AŞM önceden bilinen hedef nesneleri, şekil önseli kullanarak imge üzerinde konumlandırır. Şekiller daha önceden işaretlenmiş belli konumlardaki noktalardan oluşmaktadır. Önsel şekil bilgisini elde etmek için, ilk olarak eğitim kümesinde bulunan nesnenin değişik şekilleri için bir Nokta Dağılım Modeli (NDM) oluşturulur. NDM'yi oluşturmak için Procrustes hizalama metodu [Gower, 1975] ile şekiller hizalanır, ortalama şekil bulunur ve Temel Bileşen Analizi (TBA) ile şekillerin değişimi hesaplanır.

Hedef bir imge verildiğinde, AŞM TBA ile öğrendiği modeli yeni imge üzerine oturtmaya çalışır. Bunun için yinelemeli bir algoritma kullanır. Algoritma, hem şekil modelini oluşturan her bir nokta için daha iyi bir yer arar, hem de model parametrelerini güncelliyerek bulunan şeklin öğrenilen şekele bağlılığını sağlar. Şekil 1.4'te [Cootes et al., 1995] çalışmasında sunulan eğitilmiş bir el şeklinin, bir imgede bulunması esnasındaki halleri ve en son el şeklinin konumlandırılması gösterilmiştir.

AŞM ile hedef nesne, eğitim kümesine benzer bir görünüş arz ediyorsa başarılı bir şekilde bulunabilmektedir. Lakin, yeni imgeler verildiğinde ve şekli biraz farklı nesneler bulunmaya çalışıldığı zaman dayanıklı değildir. Ayrıca, ilklendirmeye bağlıdır ve yinelemeli olarak çalıştığı için iyi bir sonuca yaklaşamayabilir. AŞM, sadece şekil bilgisini kullanmaktadır, bu da çoğu zaman yeterli bilgi sunmamaktadır.

AŞM'den sonra, şekil bilgisinin yanında görünüş bilgisini de kullanan AGM sunulmuştur [Cootes et al., 1998]. AGM çalışma prensipleri olarak AŞM'ye benzemektedir ve şekil bilgisi ile gri düzeydeki değişim bilgisini aynı modelde birleştirmektedir. AGM, hedef imge ile öğrenilen ortalama imge arasındaki farkı enküçükleyen model parametrelerini bulma felsefesine dayanmaktadır.



Şekil 1.4: AŞM'nin bir el imgesi üzerinde (a) ilklendirilmiş hali, (b) 100. iterasyondaki, (c) 300. iterasyondaki ve (d) 350. iterasyonda el nesnesini konumlandırılması [Cootes et al., 1995].

İlk olarak, eğitim kümesindeki imgelerdeki önemli özniteliklerin olduğu noktalar işaretlenmektedir. Bu işaretli noktalar x vektörü olsun. Bu vektörler üzerinde TBA metodu uygulanır ve böylece bir şekil şöyle ifade edilir:

$$x = \bar{x} + P_s b_s, \quad (1.10)$$

\bar{x} ortalama şekli, P_s değişimin modlarını ve b_s şekil parametrelerini göstermektedir. P_s kovaryans matrisinin en yüksek değerli k adet öz-değerine karşılık gelen k adet özvektördür. Daha sonra, görünüş bilgisi için, eğitim kümesindeki şekilleri içeren imgeler ortalama şekilde eğitim imgesindeki şekil çakışacak şekilde deformе edilir. Deforme edilmiş eğitim kümesindeki şekillerdeki gri düzey bilgi g TBA ile bulunur:

$$x = \bar{g} + P_g b_g, \quad (1.11)$$

\bar{g} normalize edilmiş ortalama gri düzey vektörü, P_g kovaryans matrisin en yüksek değerli k adet öz-değerine karşılık gelen k adet özvektörü ve b_g gri düzey parametrelerini göstermektedir. Daha sonra, TBA ile şekil ve gri düzey parametreleri birleştirilir ve böylece ortalama model hem geometrik, hem de görünüş bilgisini içerir. AŞM'de olduğu gibi yine yinelemeli bir algoritma ile, hedef imge üzerinde konulan ortalama model gerçek yerine oturtulamaya çalışılır. Özellikle yüz bulma ve izlemede AGM metodu başarılı sonuçlar vermektedir [Edwards et al., 1998]. Şekil 1.5(a)'da 58 nokta ile belirlenmiş, eğitim kümesindeki bir yüz modeli gösterilmiştir. Şekil 1.5(b), (c) ve (d)'de ise hedef imge ve hedef imge üzerinde AGM metodu ile bulunan yüz konturları gösterilmiştir [Nordstrøm et al., 2004].

AŞM ve AGM, aktif konturların aksine iç içe olan konturları da bulabilmektedir. Lakin, ilkendirme yapılrken konturlar hedef nesnenin uzağında olduğu zaman hedef nesneyi bulamamaktadır. Ayrıca modelleme yapılrken, nirengi noktalarının tek tek belirlenmesi gibi dezavantajları da vardır. Model oluşturulurken, aşırı eğitilme gibi dezavantajı da olabilmektedir.

1.2.2. Biçim Değiştirebilir Modeller ve Önsel Bilgi

Literatürde, kontur bulma işlemini daha başarılı bir hale getirmek için kullanılan başka bir teknik, hedef nesne ile ilgili çeşitli önsel bilgileri kontur bulma işlemi



Şekil 1.5: (a) Eğitim kümesindeki bir yüz modeli, (b) hedef imgé, (c) bulunmuş yüz konturları ve (d) Bulunan konturlara tel-örgü (mesh) geçirilmesi [Nordstrøm et al., 2004].

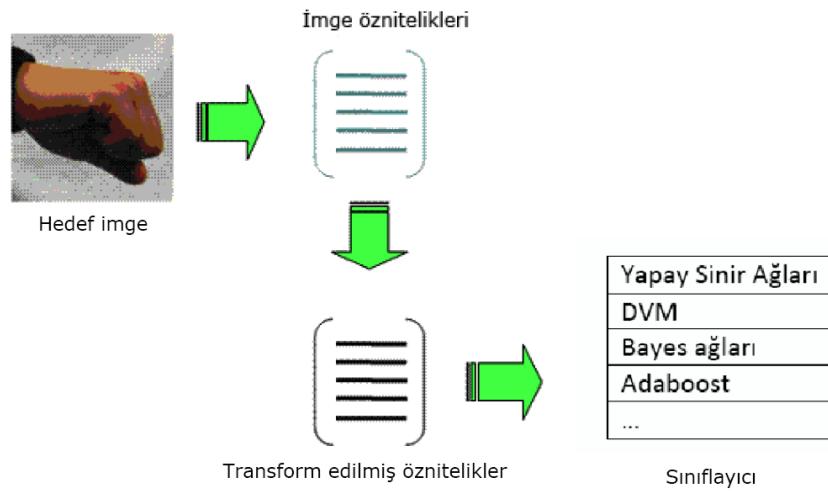
içine dahil etmektir. Literatürde, biçim değiştirebilir modellere önsel bilgi ekleyen birçok çalışma bulunmaktadır.

İlk olarak, Leventon ve diğerleri [Leventon et al., 2000] eğrilerin işaretli uzaklık fonksiyonunu ve TBA kullanarak eğitim kümesinden istatistiksel şekil önseli oluşturmuşlardır ve şekil önselini biçim değiştirebilir modele dahil etmişlerdir. Chen ve diğerleri [Chen et al., 2002], [Leventon et al., 2000]'dan daha farklı bir yaklaşım sunmuşlardır, çünkü istatistiksel önsel yerine değişimsel enerji fonksiyonuna şekil önselini eklemiştir. Temel fikirleri, aktif konturun gelişim hızını sadece imge gradyanı şiddetine göre değil, aynı zamanda önsel şekele göre de ayarlamaktır. Önsel şekil, Procrustes analizi ile oluşturulmaktadır ve eğitim kümesindeki tüm şekillerin ortalaması gibi düşünülebilir. Metotlarını birçok tıbbi imge türü üzerinde doğrulamışlardır. Chen ve diğerleri [Chen et al., 2007] ayrıca şekil ve parlaklık profilini beraber kullanarak tıbbi imgelerde çevrit bulmuşlardır.

Tsai ve diğerleri [Tsai et al., 2001], önsel bilgiyi şekillerin uzaklık fonksiyonlarını kullanarak Tekil Değer Ayırımı (TDA) ile modellemiştir. Ayrıca, enerji fonksiyonelinde alan terimlerini de kullanarak çeşitli imgeler üzerinde başarılı sonuçlar elde etmişlerdir.

Rousson ve Paragios [Rousson and Paragios, 2002], Gauss yoğunluk fonksiyonu ile eğitim kümesinden bir önsel şekil oluşturmuş ve düzey kümesinin gelişirken bu modele bağlı kalmasını sağlamışlardır. Yan ve Kassim [Yan and Kassim, 2006] TBA ile eğitim kümesindeki şekillerin ortalamasını ve değişimini öğrenip, bu bilgiyi en yakın yol biçim değiştirebilir modeline eklemiştirlerdir.

Chen ve Radke [Chen and Radke, 2009], TBA tabanlı metotlardan farklı olarak parametrik olmayan Çekirdek Yoğunluğu Tahmini (ÇYT) ile önseli modellemiş ve şekil ve parlaklık önselini beraber kullanarak kontur bulma işlemini gerçekleştirmiştirlerdir.



Şekil 1.6: Nesne saptama çerçevesi

1.3. Nesne Saptama

Bilgisayarla görme algoritmalarında son yıllarda öznitelik çıkarma ve makine öğrenmesi metotları ile nesne saptama oldukça gelişmiştir. Literatürde "Scale-invariant feature transform" (SIFT) [Lowe, 2004], "Multi-Scale Oriented Patches" (MOPS) [Brown et al., 2005], "Histogram of oriented gradients" (HOG) [Dalal and Triggs, 2005], [Shashua et al., 2004] ve "Bag of Words" (BOW) metotları gibi birçok öznitelik çıkarma ve tanımlama teknigi mevcuttur. Bu tekniklerle imgeden çıkartılan öznitelikler, çeşitli makine öğrenmesi teknikleri ile eğitilmekte ve nesne tanıma bir sınıflandırma problemine dönüştürülerek, öğrenilen bilgiye göre nesne saptama yapılmaktadır. Şekil 1.6'da imgeden öznitelik çıkarma ve makine öğrenmesi çerçevesi gösterilmektedir.

Adaboost [Freund and E.Schapire, 1997] ve Vektör Destek Makineleri (VDM) [Cortes and Vapnik, 1995], bilgisayarla görmede en sık kullanılan makine öğrenmesi metodlarındanandır [Dalal and Triggs, 2005], [Liu et al., 2009].

Boosting [Schapire, 1990], [Freund, 1990] olarak tanımlanan makine öğrenmesi metodlarından en popüler olanlarından Adaboost, zayıf öğrenicileri (weak learner) birleştirerek, güclü bir hipotez oluşturma temeline dayanmaktadır. İlk önce eğitim kümelerindeki örnekler eşit ağırlık verilir. Algoritma, her iterasyonda yeni bir zayıf öğrenici bulur ve örneklerden bu öğrenici ile doğru olarak sınıflandırılanların

ağırlıklarını azaltırken, yanlış olarak sınıflandırılan örneklerin ağırlıklarını ise artırır. Böylece, ileriki iterasyonlarda yanlış sınıflandırılanları daha çok önemser. En son zayıf öğrenicilerin hepsini, atanen ağırlıklara bağlı olarak bir araya getirir ve son güçlü sınıflayıcıyı oluşturur. Aşağıdaki algoritma Adaboost algoritmasının temel adımlarını göstermektedir.

Algorithm 1 Adaboost algoritması

Girdi: Örnekler $(x_1, y_1), \dots, (x_m, y_m)$, $x_i \in X$ ve $y_i \in \{1, -1\}$

Çıktı: H

Ağırlıkları ilklendir $D_1(i) = 1/m$

for $t = 1, \dots, T$ **do**

$$\text{Zayıf hipotez } h_t = \arg \min \epsilon_t = \sum_{i=1}^m D_t(i)[y_i \neq h_j(x_i)]$$

If $\epsilon \geq 1/2$ **end if**

$$\alpha_t = \frac{1}{2} \log\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$$

Güncelle

$$D_{t+1}(i) = \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$$

Z normalizasyon terimidir.

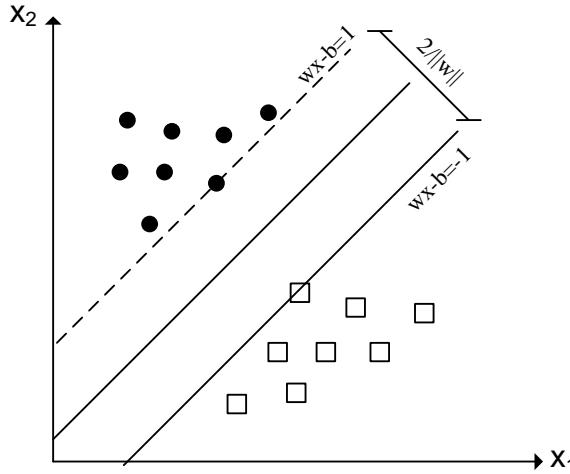
end for

$$H(x) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(x))$$

Algoritmada, m tane $\{-1, 1\}$ etiketini alan örnek vardır ve bu örnekler $(x_1, y_1), \dots, (x_m, y_m)$ olarak tanımlanmıştır. Algoritma ilk olarak her örneğe $1/m$ ağırlığı atar. Daha sonra zayıf hipotez h_t 'yi bulur ve bu zayıf hipoteze göre yanlış sınıflandırılan örneklerle bağlı olarak hatayı (α_t) hesaplar. Bir sonraki iterasyonda kullanmak üzere yeni dağılım $D_{t+1}(i)$ bulunur. Bu yeni dağılımda, yanlış sınıflandırılan örneklerin ağırlığı daha fazla, doğru sınıflandırılanların ağırlığı ise daha azdır. T tane iterasyon tanımlandıktan sonra en son güçlü hipotez H , zayıf hipotezlerin birleştirilmesi ile bulunur.

Adaboost algoritması bir yarı sınıflandırıcıdır ve diğer sınıflandırma metodları ile beraber kullanılabilir. Çok fazla sayıda öznitelik olduğunda dahi başarılı sonuçlar üretir.

VDM de bilgisayarla görme ve örüntü tanıma tekniklerinde sıkça kullanılan



Şekil 1.7: Eğitim kümelerindeki örnekler ve onları iki sınıfaya ayıran bir hiper-düzlem

bir gözetimli öğrenme metodudur [Duda et al., 2001]. VDM, eğitimle verilen bir örnek kümesi için sınıfları birbirinden ayıran bir hiper-düzlem ya da hiperdüzlemler bulur. Yeni bir örnek verildiği zaman, bulunan hiper-düzlemi baz alarak örneğin hangi sınıfta olduğu bulunur. Sınıfları birbirinden ayıran hiper-düzlem, eğitim kümelerindeki örneklerle ne kadar uzaksa, sınıflandırma o kadar başarılı kabul edilmektedir.

Bir eğitim kümelerindeki örnekler $(x_1, y_1), \dots, (x_m, y_m)$ olsun. $x_i \in R^n$ öznitelikleri ve $y_i \in \{1, -1\}$ 'de o özniteliklere sahip örneğin sınıfını göstermektedir. Amaç bu sınıfları birbirinden büyük boşlukla (margin) ayıran hiper-düzlemleri bulmaktır. Bir hiper-düzlem

$$w \cdot x - b = 0, \quad (1.12)$$

denklemi ile ifade edilebilir. w hiper düzleme dik olan normal vektördür ve $\frac{b}{\|w\|}$ de w vektörü boyunca hiper-düzlemin aralığını belirler. Şekil 1.7'de iki sınıflı örnekler için bir hiper-düzlem gösterilmektedir.

Yeni bir örnek verildiğinde, hiper-düzlemlerin ne tarafında düşüğü belirlenerek sınıflandırma işlemi gerçekleştirilmektedir. Çok sınıflı sınıflandırmalarda da DVM başarılı bir şekilde çalışmaktadır.

1.4. Motivasyon ve Katkılar

Birçok bilgisayarla görme metodu, görme işleminin hiyerarşik bir düzene göre yapıldığını kabul etmektedir. [Biederman, 1987] insandaki nesne tanıma işleminin aşağıdan yukarıya yaklaşımıla, önce parçaları tanıayıp sonra tüm nesneyi tanıdığını belirtmiştir ve buna bileşenlerle tanıma (Recognition-by-components) ismini vermiştir. [Biederman, 1987]'a göre insan, kenar ve boşluk gibi toplam 36 geon ve geonların birbirleriyle ilişkisi sayesinde nesneleri tanıyalımaktadır. Dolayısıyla önce özniteliklerle nesnedeki belirli parçalar tanınmakta ve bunlar birleştirilerek tüm nesnenin ve sahnenin ne olduğu bulunmaktadır. Bunun aksine, insandaki görme yetisinin bu şekilde çalışmadığı ve insanın parça ve tüm nesnenin saptanmasını beraber yaptığı da ileri sürülmüştür [Navon, 1977], [Biederman et al., 1982].

Literatürdeki bilgisayarla görme algoritmalarının bazıları düşük düzeyli bilgileri kullanıp parçalarına bakarak nesneyi tanıtmaya çalışmış; bazıları da sadece nesnenin tümsel özelliklerini kullanmışlardır. Mesela yılanlar [Kass et al., 1988], imgé üzerinde sadece lokal bilgi ile hedef nesnenin tüm şeklini hiç hesaba katmadan kontur bulmaktadır. Yaya [Viola et al., 2003] ve yüz bulma [Viola and Jones, 2004] için kullanılan Haar tipi filtrelerle çıkarılan özellikler ve SIFT [Lowe, 2004] ile çıkarılan öznitelikler imgenin tümündeki özellikleri hesaba katmadan lokal seviyede çalışmaktadır. Bölümleme için kullanılan çizge kesme algoritması ise imgenin tamamını göz önüne almakta ve nesnedeki lokal özelliklerini (düzgünlük sağlamaya çalışsa da) enerji fonksiyoneline katmamaktadır.

Bölüm 1.2'de önsel bilgi ve içerik bilgisi ile kontur bulma ve nesne tanıma işleminin daha başarılı bir şekilde yapıldığı literatürden örneklerle anlatılmıştır. Kullanılan önsel bilgi, düzey kümesi metotlarıyla kullanıldığı çoğu zaman [Leventon et al., 2000], [Bresson et al., 2006], sadece nesnenin tüm şeklini -parçalara bakmadan- göz önünde bulundurmaktadır. Çeşitli öznitelik bulma ve makine öğrenmesi metotları beraber nesne saptama için kullanıldığına ise, nesnenin tümünü hesaba katmadan parçaları birleştirerek nesneyi bulmaktadır.

Bu çalışmada, önsel bilgi lokal ve global olarak ikiye ayrılmış ve daha modüler, düzenli ve hiyerarşik bir şekilde kontur çıkarma ve nesne konumlandırma

gerçekleştirilmiştir. Lokal önsel ile, imgenin tamamını ilgilendirmeyen, piksel ya da imgedeki bazı alanlar bazındaki özellikler ifade edilmektedir. Global önsel ise imgenin ya da nesnenin tamamını ilgilendiren ve lokal önsellerin daha üst seviyesinde, lokal özelliklerin birleşmesi ile oluşmuş özellikleri ifade etmektedir. Bu çalışmada, farklı lokal ve global önsellerin birlikte kullanılarak daha başarılı kontur bulma ve nesne saptama işlemleri gerçekleştirmek amaçlanmıştır.

Manyetik rezonans (MR) görüntüleme, ultrason ve bilgisayarlı tomografi (BT) gibi tıbbi görüntüler, insan sağlığı açısından önemli bilgiler vermektedir; fakat bunlar üzerinde bilgisayarla görme metodlarını çalıştmak normal imgelere göre daha zordur. Bu zorluk gürültüden, kapanmış parçalardan, kontrastın değişmesinden ya da çeşitli hastalıklardan kaynaklanmaktadır. Zorluğunun yanında, tıbbi imgelerdeki organlar ve yapılar büyük benzerlikler göstermektedir. Bu benzerlikten doğan bilgi önsel olarak kullanılabilmekte ve tıbbi imgelerde önsel bilgi ile daha başarılı nesne saptama ve kontur bulma işlemleri yapılmaktadır. Dolayısıyla, bu çalışmada geliştirilen önsel bilgi ekleme metotları, tıbbi imgeler üzerinde test edilmiş ve doğrulanmıştır.

Bu tezde geliştirilen metodlar şu şekildedir:

- Ekokardiyografik imgelerden ve kalp MR görüntülerinden, sol karıncığın iç ve dış duvarlarını düzey kümesi metoduna global şekil ve görünüş bilgisi ekleyerek bulan bir sistem geliştirilmiştir.
- Kalp ultrason filmlerinden, sol karıncığın iç ve dış duvarlarını hem lokal bilgi (lokal şekil, görünüş, hareket gibi), hem de global bilgi (sol karıncığın şekli) ile bulan bir sistem tasarlanmıştır.
- Bel omurlarının arasındaki diskleri, lokal disk bilgisi ve global lomber eğri bilgisi kullanarak bulma ve diskleri etiketleriyle birlikte konumlandırma gerçekleştirilmiştir.
- Kalp MR imgelerinde, sol karıncığın yerini bulan ve sadece lokal bilgi ile skor imgeleri üreten bir sistem oluşturulmuştur.

Geliştirilen metodlarda, lokal ve global bilginin hiyerarşik bir şekilde kullanılması sonucu sistemlerin başarılarının, önsel bilgi kullanmayan metodlara göre

büyük ölçüde artırılması hedeflenmiştir. Bunun yanında sistemlerde, farklı türdeki bilgilerin kolay ve verimli bir şekilde eklenebilmesi de amaçlanmıştır. Ayrıca, geliştirilen sistemlerde, şekilleri tanımlamak için parametrelere bağlı bir model oluşturmadan kontur bulma ve nesne saptama gerçekleştirilmeye çalışılmıştır. Sistemler sadece üzerinde çalıştığı tıbbi imgeye özel olmayıp, başka tipteki imgelerde (tıbbi ya da normal) de kullanılabilecek şekilde tasarlanması hedeflenmiştir.

1.5. İçerik

Tezin içeriği şu şekildedir: Bölüm 1'de literatürdeki bazı kontur bulma ve nesne saptama tekniklerine değinilmiştir. Bölüm 2'de global şekil bilgisi ile kontur bulma metodu sunulmaktadır. Bölüm 3'te, lokal ve global bilginin düzeykümesi metodu ve makine öğrenmesi kullanılarak beraber eklenmesi anlatılmıştır. MR imgelerinden, bel omurları arasındaki disklerin bulunup, her bir diskin konumlandırılması Bölüm 4'te sunulmuştur. Bölüm 5'te ise kalp MR imgelerinden sol karıncığın yerinin bulunması ve skor imge oluşturulması anlatılmıştır. Bölüm 6'da ise tez ile ilgili yorumlara ve sonuçlara yer verilmiştir.

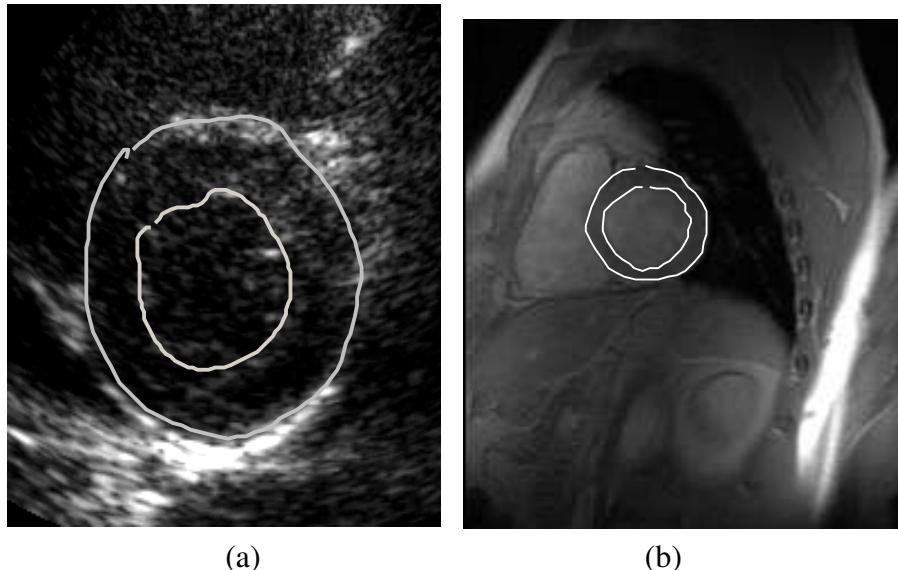
2. GLOBAL ŞEKİL ve GÖRÜNÜM ÖNSELİ ile KONTUR BULMA

Bölüm 1'de anlatıldığı üzere literatürde birçok önsel bilgi ekleme metodu bulunmaktadır [Cremers et al., 2007]. Geliştirilen metodlardaki genel önsel bilgi ekleme yaklaşımı, biçim değiştirebilir kontur fonksiyoneline önsel bilgi için yeni terimler ekleme şeklindedir. Şekil, görünüş gibi farklı tiplerdeki önsel bilgilerin aynı anda eklenmesi fonksiyoneli daha karmaşık hale getirmektedir ve en iyi çözümü öteleme, döndürme ve ölçekleme gibi ihtiyaçlarla gerçeklemek oldukça zordur [Besbes et al., 2009]. Ayrıca eğitim kümesini oluşturmak ve eğitim kümesinde hedef nesnenin değişimlerini modellemek de kolay değildir.

Bu çalışmada, eğitim ile önsel model oluşturmak ve biçim değiştirebilir model fonksiyoneline önsel bilgi için yeni terimler eklemek yerine, daha modüler ve esnek bir önsel bilgi ekleme yaklaşımı sunulmaktadır. Önsel bilgi, çevrit bulma işlemine yeniden ilklendirme esnasında kontur gelişimini durdurarak eklenmektedir. Gelişen yüzey, kendisine en benzeyen uzman konturuna göre yeniden şekillendirilmekte ve şekillendirilmiş yüzey yeniden ilklendirilmektedir [Oktay and Akgul, 2008a], [Oktay and Akgul, 2008b], [Oktay and Akgul, 2011]. Geliştirilen sistem, farklı biçim değiştirebilir modellerle kullanılabilir ve farklı önsel bilgiler kolaylıkla sisteme entegre edilebilir. Bu bölümde, şekil ve görünüş bilgisi önsel bilgi olarak kullanılmıştır.

Geliştirilen metodun birçok avantajı vardır. İlk olarak, karmaşık şekilleri ve ilgili imge özelliklerini önsel olarak modelleyip biçim değiştirebilir model fonksiyoneline eklemek zordur. Bizim metodumuz daha farklı bir yaklaşımla, uzmanlardan elde edilen şekil ve imge bilgisini yeniden ilklendirme esnasında dahil etmektedir. Ayrıca, önsel bilgi için başta bir eğitim safhasına ihtiyaç yoktur ve önsel bilgi doğrudan kontur gelişimi sırasında eklenmektedir. Üstelik, uzmanlardan alınan yeni bilgi anında sisteme dahil edilebilir. Daha önce de vurgulandığı gibi, sistem farklı biçim değiştirebilir modellerle hesapsal güç ihtiyaçlarını önemli derece arttırmadan kullanılabilir.

Geliştirilen metot, ekokardiyogramlarda ve kalp MR imgelerinde test edilmiştir. Test edilen imgelerin kendilerine has, organdan veya görüntüleme kipinden



Şekil 2.1: Örnek bir (a) ekokardiyogram ve (b) 2 boyutlu kalp MR imgesi. Her iki imgede de sol karıncığın iç ve dış duvarı bir uzman tarafından işaretlenmiştir.

kaynaklanan zorlukları vardır. Test edilen ekokardiyogramlar uç-sistol ve uç-diyastol fazında sol karıncığın kısa akslı göğüsten geçen görüntülerini içermektedir (Şekil 2.1-a). Sol kalp karıncığının iç ve dış duvarları (endokardiyum ve epikardiyum) fazla miktarda gürültü içeren ve duvarların yan kısımlarında az kontrast olan kısa akslı ultrason imgelerinde bulunmuştur. Test edilen 2 boyutlu MR kesitleri uç-diyastol fazındaki kısa akslı görüntülerdir ve yine sol karıncığın iç ve dış duvarı bu imgelerden bulunmuştur (Şekil 2.1-b). MR kesitleri ultrason imgeleri kadar gürültülü olmamasına rağmen, kalp duvarının etrafında kalp duvarıyla ilgisiz parçalar ve papiller kaslardan dolayı kontur bulma işlemi zordur.

2.1. Önsel Tabanlı Kontur Bulma Çerçevesi

Geliştirilen önsel bilgi ekleme metodu, iki tekrarlayan adımdan oluşmaktadır. Adım 1'de, biçim değiştirebilir model klasik formülasyonuna uygun bir şekilde gelişir. Adım 2'de, daha önceden başka sol karıncık için çizilmiş uzman konturlarından gelişen kontura şekil ve görünüş olarak en benzeyeni seçilir ve bu seçilen kontur transformasyondan sonra imge üzerinde yeniden ilklendirilir. Daha sonra adım 1 ve adım 2 birbirini tekrar takip eder. Konturun gelişmesi durduğu zaman kontur bulma işlemi tamamlanmış olur. Geliştirilen metodun işleyişi Şekil 2.2'de gösterilmiştir.

2.1.1. Şekil Önseli

Anatomik yapılar benzer şekil ve geometrik özelliklere sahiptir, bu yüzden biçim değiştirebilir modelin son olarak bulduğu konturun da bu tipte bir şekele sahip olması beklenir. Adım 1'de biçim değiştirebilir model önsel bilgi olmadan gelişirken, diğer ilgisiz organlar veya imge özellikleri nedeniyle istemeyen deformasyonlar (yüzeyin birleşmesi ya da parçalara ayrılması gibi) olabilir. Hedef organın geometrik şekil bilgisini eklemek, biçim değiştirebilir modeli belirli bir şekele yönlendirme için istenmeyen deformasyonları engeller.

$C = \{c_1, \dots, c_n\}$, n tane sıralı 2 boyutlu noktadan oluşan ayrıklasılmış, adım 1'de gelişmekte olan kapalı bir kontur olsun. Sürekli kontur C , bu n tane noktayı aradeğerlendirme yaparak elde edilebilir. $E = \{E_1, \dots, E_k\}$, k tane ayrıklasılmış uzman konturlarından oluşan bir küme olsun ve $E_i = \{e_1, \dots, e_m\}$, sıralı 2 boyutlu m tane noktadan oluşsun. Geliştirilen şekil önseli ekleme metodu, C ve E_i arasındaki farkın en az olduğu uzman konturu E_i 'yi bulmak üzerine kuruludur. Maalesef, uzman konturu ve gelişen kontur C arasındaki şekil benzerliği aralarındaki ölçek, öteleme, döndürme ve lokal şekil farklarından dolayı doğrudan bulunamaz. Lakin, organ şekilleri çok fazla karmaşık olmadığından dolayı pratik biçim değiştirebilir kontur eşleştirme algoritmaları ile benzer konturlar bulunabilir.

Kalp konturlarını bulmak için geliştirilen sistemde, ilk olarak gelişen kontur C 'nin ve E kümesindeki uzman konturlarının ağırlık merkezleri bulunmuştur. Bulunan ağırlık merkezi noktaları baz alınarak, konturlar Kartezyen sistemdeki (0,0) noktasına taşınmıştır. Kontur pozisyonu c_i ve merkez (0,0) noktaları arasındaki Öklid uzaklık $R(c_i)$ olarak tanımlanmıştır. Ayrıca başka bir fonksiyon olan $\theta(c_i)$ de, x ekseni ile (0,0) ve c_i noktalarından geçen doğru arasındaki açı olarak tanımlanmıştır (Şekil 2.3).

Uzman kardiyologlar tarafından çizilen konturlar, kendileri ve gelişen kontur arasındaki yönelimsel farkları kapatmak için döndürülmüşlerdir. Uzman kontur kümesi E 'deki her bir kontur E_i , dar bir açı aralığında küçük arttırmalarla döndürülerek yeni döndürülmüş uzman kontur kümesi E^r oluşturulmuştur. E kümesindeki her kontur için E^r kümesi birçok döndürülmüş formu içermektedir.

Gelişen kontur $C = \{c_1, \dots, c_n\}$ ve döndürülmüş kontur $E_i^r = \{e_1^r, \dots, e_m^r\}$ arasındaki benzerliği ölçmek için, $\theta(c_i) \cong \theta(e_j)$ olduğu c_i etrafındaki h komşu nokta kullanılarak e_j^r ve c_i noktaları arasındaki yerel ölçeklendirme miktarı bulunur. e_j^r ve c_i arasındaki yerel ölçeklendirme miktarı $S_f(e_j, c_i)$, $\theta(c_i) \cong \theta(e_j)$ iken aşağıdaki gibidir:

$$S_f(e_j, c_i) = \frac{\sum_{p=-h/2}^{h/2} R(c_{i+p})}{\sum_{p=-h/2}^{h/2} R(e_{j+p})}. \quad (2.1)$$

E_i^r üzerindeki e_j ve C üzerindeki c_i noktaları için yerel ölçeklendirme miktarı hesaplandıktan sonra eğrilenmiş nokta e_j^w

$$e_j^w = S_f(e_j, c_i)R(e_j), \quad (2.2)$$

ile bulunur. $E_i^r = \{e_1^r, \dots, e_m^r\}$ konturunun tüm noktaları C konturu üzerine eğrilttilir ve böylece eğriltilmiş uzman kontur kümesi $E_i^w = \{e_1^w, \dots, e_m^w\}$ Denklem 2.2 ile elde edilir. Aynı işlem E^r kümesindeki tüm uzman konturlarına uygulanır ve yeni eğriltmiş uzman kontur kümesi E^w oluşturulur.

Eğriltilmiş kontur $E_i^w = \{e_1^w, \dots, e_m^w\}$ ile $C = \{c_1, \dots, c_n\}$ arasındaki geometrik benzerlik G , $\theta(c_i) \cong \theta(e_j)$ iken şu şekilde tanımlanmıştır:

$$G(C, E_i^w) = \sum_{i=1}^n |c_i - e_j^w|. \quad (2.3)$$

Denklem 2.3 ile her bir uzman kontur ve C arasındaki geometrik benzerliği hesaplandıktan sonra, yeniden ilklendirilecek uzman konturu bulmak için, ayrıca imge benzerliği de bulunmaktadır. İmge benzerliğinin hesaplanması bir sonraki bölümde anlatılmıştır. Geliştirilen kontur eşleştirme metodu literatürdeki daha sofistike ve hızlı metodlarla değiştirilebilir. Bu çalışmadaki eşleştirme metodu, organlar için yeterli bulunmuştur.

2.1.2. İmge Önseli

Uzman konturunu sadece geometrik benzerliğe göre belirlemek, bazen gelişen konturun yanlış konumlanmasına neden olabilir. Adım 1'de kontur gelişirken, organ

etrafındaki düşük veya yüksek kontrasta sahip olan imge bölümlerinden etkilenip, hedef organ sınırlarına ulaşamayabilir. Adım 2'de gelişen kontura, eğer sadece şekil önseli eklenirse, kontur önsele benzer bir şekele sahip olabileceği gibi hedef organın sınırları dışında bir yerde de konumlanmış olabilir. Bu problemi çözmek için, en benzer uzman konturunu seçme işlemini daha dayanıklı hale getiren geometrik önselin yanında imge önseli de kullanılmıştır. Organ sınırlarında sadece geometrik benzerlik değil, aynı zamanda imge özellikleri de benzer olmalıdır. Bu yüzden uzman konturunu seçerken geometrik ve imge benzerlik metriği beraber uygulanmıştır.

İmge I_c üzerinde gelişen kontur C ve imge I_e için çizilmiş olan uzman konturu E_i arasındaki imge benzerliği, birbirine denk gelen noktalar etrafında Normalize edilmiş Çapraz İlinti (NÇİ) tekniği ile bulunmuştur. $p(I_p, s)$ fonksiyonu I_p imgesindeki s noktası etrafındaki parçayı döndürsün ve NCC normalize edilmiş çapraz ilinti fonksiyonu olsun. Gelişen kontur $C = \{c_1, \dots, c_n\}$ ve uzman konturu $E_i = \{e_1, \dots, e_m\}$ arasındaki imge benzerliği $N(C, E_i)$ şu şekilde tanımlanmıştır:

$$N(C, E_i) = \sum_{i=1}^n NCC(p(I_c, c_i), p(I_e, e_j)), \quad (2.4)$$

$\theta(c_i) \cong \theta(e_j)$ ve c_i ve e_j birbirine denk gelen noktalardır.

Her bir uzman konturun gelişen kontur C ile, Denklem 2.3 ve Denklem 2.4 ile tanımlanmış geometrik ve imge benzerliği vardır. En büyük birleştirilmiş imge ve geometrik benzerliğe sahip olan uzman konturu $E_i \in E^w$ şöyle belirlenir:

$$\arg \max_{E_i \in E^w} \{\alpha_t N(C, E_i) - (1 - \alpha_t) G(C, E_i^w)\}, \quad (2.5)$$

$0 < \alpha_t < 1$ bir ağırlık katsayısıdır. α_t 'nin değeri, adım 1 ve 2'deki döngü sayısı t ile orantılı olarak doğrusal artar (Şekil 2.2). İlk baştaki döngülerde, α_t 0'a yakın bir değer alırken, şekil önseli daha fazla ağırlık kazanır. Böylelikle başlangıçtaki biçim değiştirme adımlarında, gelişen konturun uzman konturlarına daha çok benzemesi sağlanır ve imgedeki organın uzağındaki ilgisiz parçalardan biçim değiştirebilir model etkilenmez. Daha sonraki döngülerde, model organa yaklaştıkça, α_t artırılır ve uzman konturlarındaki imge bilgisine daha çok önem verilir.

2.2. Önsel Bilginin Çevrit Bulma İşlemine Eklenmesi

Geliştirilen önsel bilgi ekleme metodu düzey kümesi metoduna göre tasarlansa da, diğer biçim değiştirebilir modellere kolaylıkla uyarlanabilir. Çalışmamızda Li ve diğerlerinin [Li et al., 2005] düzey kümesi formülasyonu, sağladığı kolay gerçekleştirilebilmesi ve hesaplama verimi avantajlarından dolayı kullanılmıştır.

İç ve dış sol karıncık duvarları (Şekil 2.1(a) ve (b)) aynı anda bulunabilir, bu yüzden bağımlı çift kontur gelişimi kullanılmıştır. Bu iki kontur birbirlerine doğru gelişirler ve içteki kontur iç duvarı, dıştaki kontur ise dış duvarı bulur.

$f_1(t)$ ve $f_2(t)$, zaman t 'ye bağlı \mathbb{R}^2 düzleminde endokardiyum ve epikardiyumu bulmak için gelişen iki bağımlı eşmerkezli kapalı kontur olsun. F , $f_1(0)$ ve $f_2(0)$ üzerinde $t = 0$ zamanındaki nokta kümesi olarak tanımlanır. Ayrıca, $\mathbf{x} \in \mathbb{R}^2$ de pozisyon vektöridür. Ayırıklaştırılmış işaretli uzaklık fonksiyonu $\phi : \mathbb{R}^2 \rightarrow \mathbb{R}$

$$\phi(\mathbf{x}) = \begin{cases} 0, & \text{eğer } \mathbf{x} \in F \\ -d(\mathbf{x}, F), & \text{eğer } \mathbf{x} f_1 \text{'in dışında ama } f_2 \text{'nin içinde ise} \\ d(\mathbf{x}, F), & \text{diğer,} \end{cases} \quad (2.6)$$

olarak tanımlanmıştır. Bu fonksiyonda $d(\mathbf{x}, F)$, \mathbf{x} noktasından F 'e olan en kısa Öklid uzaklıktır. f_1 ve f_2 konturları $t = 0$ zamanında ϕ yüzeyinin sıfırıncı düzeyindeki konturlardır.

3 boyutlu yüzey ϕ iç enerji terimi $P(\phi)$ ve dış enerji terimi $\varepsilon_m(\phi)$ etkisinde gelişir. Varyasyonel enerji fonksiyoneli $\varepsilon(\phi)$

$$\varepsilon(\phi) = \mu P(\phi) + \varepsilon_m(\phi), \quad (2.7)$$

μ iç enerji teriminin ağırlığını belirleyen parametredir. Kullanılan düzey kümesinin detaylı formülasyonu Bölüm 1'de ve [Li et al., 2005]'de bulunabilir.

Bir ekokardiyografik imgede kontur bulmak için, ilk olarak Denklem 2.6 ile ϕ düzeyi, bir sıfırıncı düzey konturu f_1 'i endokardiyumun içine ve bir sıfırıncı düzey f_2 konturunu epikardiyumun dışına yerleştirilerek oluşturulur. Adım 1'de, ϕ yüzeyi iç ve dış enerji terimleri etkisi altında gelişmesi beklenir. f_1 ve f_2 sıfırıncı düzey konturları aynı anda birbirlerine doğru ilerler. Belirli aralıklarla kontur gelişmesi durdurulur

ve adım 2'de Denklem 2.5 ile gelişen konturlara en benzeyen uzman konturları epikardiyum ve endokardiyum için ayrı ayrı seçilir. Seçilen ve eğriltilmiş uzman konturlarını sıfırıncı yüzeye gömerek Denklem 2.6 ile yeni bir yüzey oluşturulur. Oluşturulan yüzey imge üzerine yeniden ilklendirilir ve adım 1'de gelişmeye devam eder. Adım 1 ve adım 2, son kontur bulma işlemine kadar birbirini takip eder. Algoritma 2 ve Şekil 2.2'de sistemin akışı gösterilmiştir. Algoritmanın çalışma süresi döngü sayısı T , uzman kontur sayısı k , yeniden ilklendirme aralığı r ve kullanılan eşleştirme metoduna bağlıdır.

Algorithm 2 Düzey kümesi ile kalp konturu bulma

Girdi: Uzman konturları $E=\{E_1, \dots, E_k\}$, döngü sayısı T , r yeniden ilklendirme aralığı, imge I
 Çıktı: ϕ yüzeyinin sıfırıncı düzey konturları
 3 boyutlu yüzey ϕ oluşturulur (Denklem 2.6)
for $t = 1$ 'den T 'ye **do**
 ϕ yüzeyi Denklem 2.7 ile gelişir
if mod(t,r)==0 **then**
 ϕ yüzeyinin sıfırıncı düzeyi C 'yi al
 Denklem 2.2 ile uzman konturlarını eğrilt ve E^w kümesinin elde et
 Denklem 2.5 ile E^w 'deki c 'ye en benzer uzman konturlarının bul
end if
 Denklem 2.6 ile uzman konturlardan yeni ϕ 'yi oluştur
 ϕ 'yi imge üzerinde yeniden ilklendir
end for

2.3. Deneyler ve Doğrulama

Bu kısımda ekokardiyogramlardan ve kalp MR imgelerinden elde edilen sayısal karşılaştırmalar ve görsel sonuçlar sunulmaktadır.

2.3.1. Ekokardiyogramlarda Kontur Bulma

Bu deneyde kullanılan ekokardiyografik imgeler sol karıncığın bir kalp döngüsü boyunca kısa eksenli gögüsten geçen görüntülerini içermektedir. İmgeler çok gürültülüdür ve kalp sınırları etrafında düşük kontrastlı parçalar bulunmaktadır. Her biri 250'ye 200 piksel boyutunda 28 tane ekokardiyogram vardır. Bu ekokardiyogramlardan 8 tanesi ve onlara ait önceden çizilmiş uzman konturları

şekil ve imge önseli olarak, diğer 20 tanesi ise test imgesi olarak kullanılmıştır. Veri kümesindeki her bir ekokardiyografik imgedeki endokardiyum ve epikardiyum 4 farklı uzman tarafından birbirlerinden bağımsız olarak işaretlenmiştir ve uzmanlar Uz1, Uz2, Uz3 ve Uz4 olarak etiketlenmiştir.

Her imge için bizim sistemimiz Oto1 ve Oto2 olarak etiketlendirilen epikardiyum ve endokardiyum için 2 farklı kontur üretmiştir. Oto1 sadece geometrik şekil bilgisini önsel olarak kullanmaktadır [Oktay and Akgul, 2008b]. Başka bir deyişle, Oto1 Denklem 2.5'deki α_t parametresini döngünün her bir aşaması için 0 olarak belirlemiştir. Oto2 ise hem imge hem de geometrik şekil önselini beraber kullanmaktadır. Ayrıca Li ve diğerlerinin [Li et al., 2005] hiçbir önsel bilgi içermeyen metodu da aynı veri kümesi üzerinde çalıştırılmıştır. Önsel bilgi olmadan çalıştırılan metotta, yüzey gelişimi sırasında yüzey, yan tarafların düşük kontrastlı olması sebebiyle birden fazla parça ayrılmaktadır ya da birleşebilmektedir. Bu yüzden, iki kontur birbirlerine belirli bir sınıra kadar yaklaştığında kontur gelişimi durdurulmuştur.

Otomatik olarak 20 ekokardiyografik imge için bulunan konturlar, uzmanların bu imgeler için işaretledikleri konturlarla sayısal olarak karşılaştırılmışlardır. Ayrıca 4 farklı uzmanın çizdikleri konturlar birbirleriyle de karşılaştırılmıştır. İki farklı kontur olan $C_x = \{x_1, \dots, x_n\}$ ve $C_y = \{y_1, \dots, y_m\}$ arasındaki ortalama piksel farkı

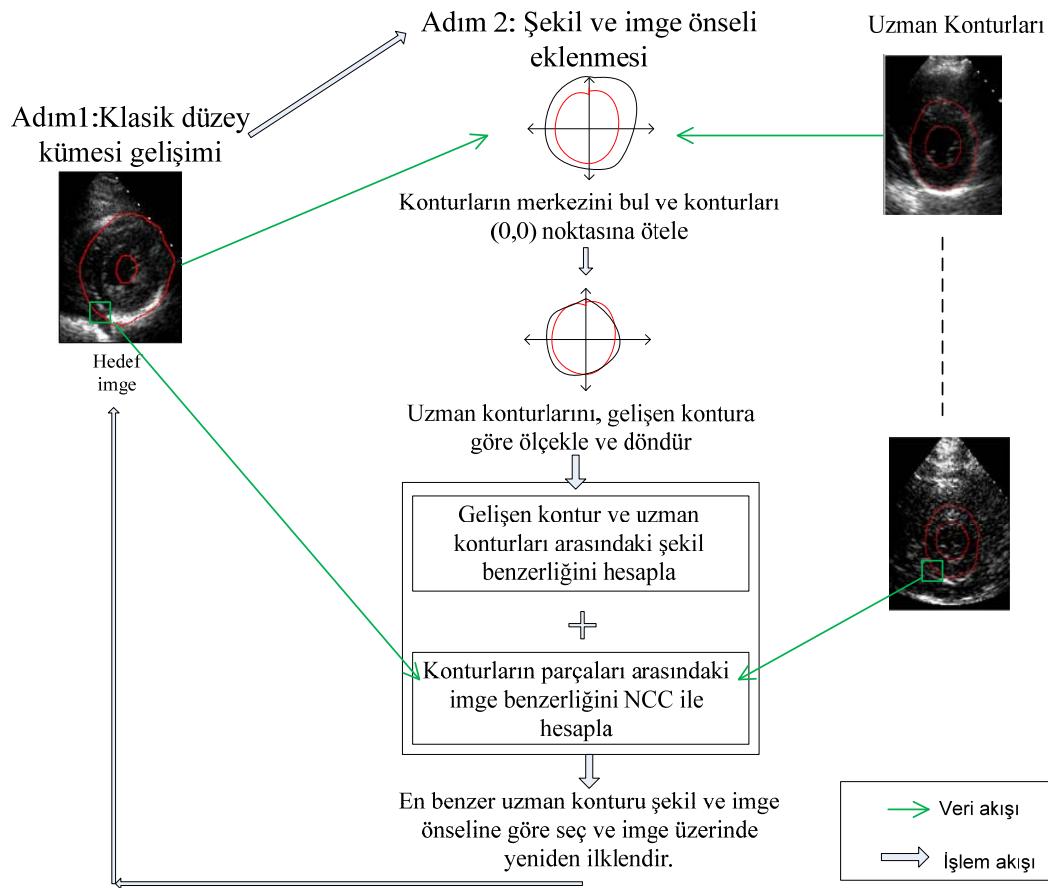
$$E(C_x, C_y) = \frac{\sum_{i=1}^n d(x_i, C_y) + \sum_{j=1}^m d(y_j, C_x)}{n + m}, \quad (2.8)$$

olarak tanımlanmıştır. Bu denklemde $d(x, C)$, x noktası ve C konturu arasındaki minimum Öklid uzaklığını tanımlamaktadır.

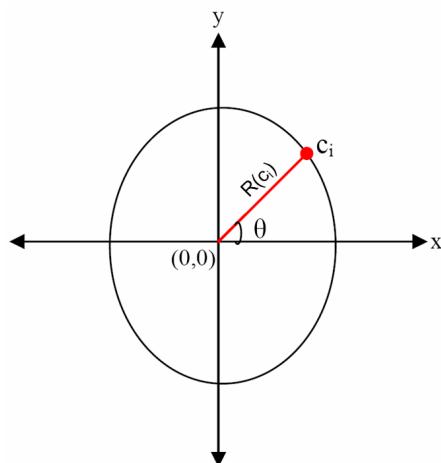
Aynı imge için çizilen konturlar Denklem 2.8 ile karşılaştırılmışlardır. Veri kümesindeki 20 imgenin ortalama uzaklıklarını Çizelge 2.1'de verilmiştir. Veri kümesindeki 3 farklı ekokardiyograma ait otomatik ve uzman konturları da Şekil 2.4'de gösterilmiştir. Sayısal karşılaştırma değerleri ve sonuçların görsel analizi sistem tarafından otomatik olarak bulunan konturların uzmanlar arasındaki değişimin içinde olduğunu göstermektedir. Başka bir deyişle, otomatik bulunan konturlar ve uzmanlar arasındaki karşılaştırma değerleri ile sadece uzmanlar arasındaki karşılaştırma

değerleri birbirlerinden ayırt edilememektedir. Bunun yanında, hiç önsel bilgi kullanmayan metot ve uzmanlar arasında çok büyük farklar bulunmaktadır.

Sonuç olarak, otomatik olarak üretilen konturların güncel uygulamalarda kullanılabilmesi iddia edilebilir. Ayrıca, Oto2 Oto1'den 0.25 piksel daha uzmanlara yakın sonuç üretmektedir. Bu yüzden, şekil ve imge önselinin beraber kullanılması ile birlikte daha başarılı sonuçlar üretildiği gözlemlenmiştir.



Şekil 2.2: Geliştirilen önsel bilgi ekleme çerçevesinin işleyişi.



Şekil 2.3: Kartezyen koordinat sisteminde örnek bir c_i noktası, $\theta(c_i)$ ve $R(c_i)$.

Çizelge 2.1: Otomatik olarak bulunan kontur-uzman ve uzman-uzman arasındaki piksel farkları.

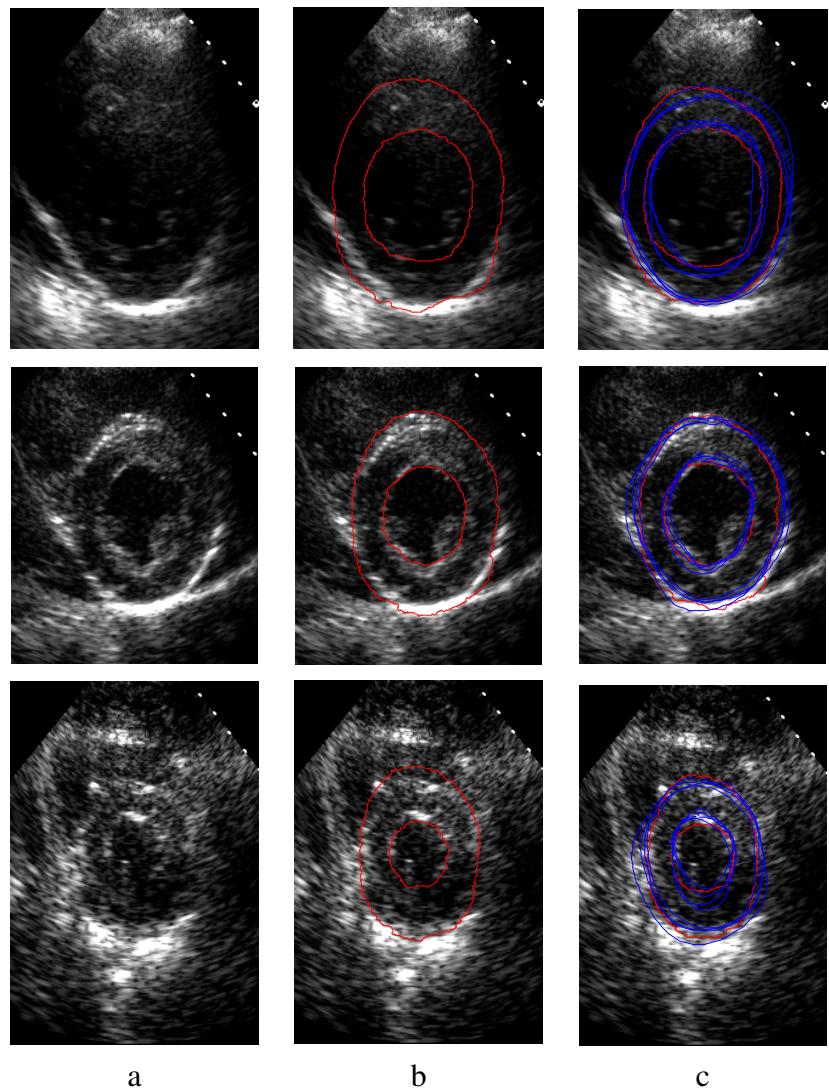
Endokardiyum uzaklığı							Epikardiyum uzaklığı						
	Uz2	Uz3	Uz4	Oto1	Oto2	Li [Li et al., 2005]		Uz2	Uz3	Uz4	Oto1	Oto2	Li [Li et al., 2005]
Uz1	3.49	3.07	4.21	3.42	3.17	7.59		3.16	3.13	7.08	4.81	4.43	6.79
Uz2		3.31	4.07	4.37	4.11	8.01		3.20	7.11	5.17	4.81		7.63
Uz3			3.66	4.51	4.48	7.55			7.00	5.36	5.03		7.21
Uz4				4.74	4.39	8.27				5.91	5.73		8.52

Önsel olarak seçilen uzman konturları gerçekten temsil edici örnekler olmalı ve tüm şekil ihtimalleri ele alınmalıdır. Bu uygulamada organ şekilleri arasında çok fazla fark yoktur, bu yüzden az sayıda uzman konturunun organ şeklini tanımlamaya yeteceğinden düşünülmektedir. Kontur bulma işleminde seçilen uzman konturların etkisini göstermek için, aynı hedef imgenin konturu farklı 5 değişik uzman kontur kümesi önsel olarak kullanılarak belirlenmiştir. Her kümede 8 farklı uzman konturu bulunmaktadır. Her küme için deney toplamda 200 döngü ($T=200$) çalıştırılmıştır. Yeniden ilklendirme aralığı r , 15 olarak seçilmiştir. Gelişen kontur ve uzman konturu arasındaki uzaklık her 10 döngüde bir ölçülmüştür. Şekil 2.5'te döngülerdeki uzaklıklar gösterilmiştir. Grafikten de anlaşıldığı üzere sistem kullanılan uzman kontur kümesine bağlı olmadan yaklaşık 3 piksel uzaklığa ulaşmaktadır. Bu deney, sol karıncığının tanımlamak için az sayıda uzman konturunun yeterli olduğunu ve kullanılan uzman kontur kümesinden bağımsız olduğunu göstermektedir. Ayrıca Şekil 2.5 önsel bilgi kullanmanın gerekliliğini de aynı zamanda göstermektedir, çünkü hiç önsel bilgi kullanılmadan düzey kümesi yaklaşık 9 piksel uzaklığa sahiptir. Bunun yanında, iterasyonlarda uzaklık sürekli azalmış ve yeniden ilklendirme sistemin yakınsamasında bir probleme yol açmamıştır.

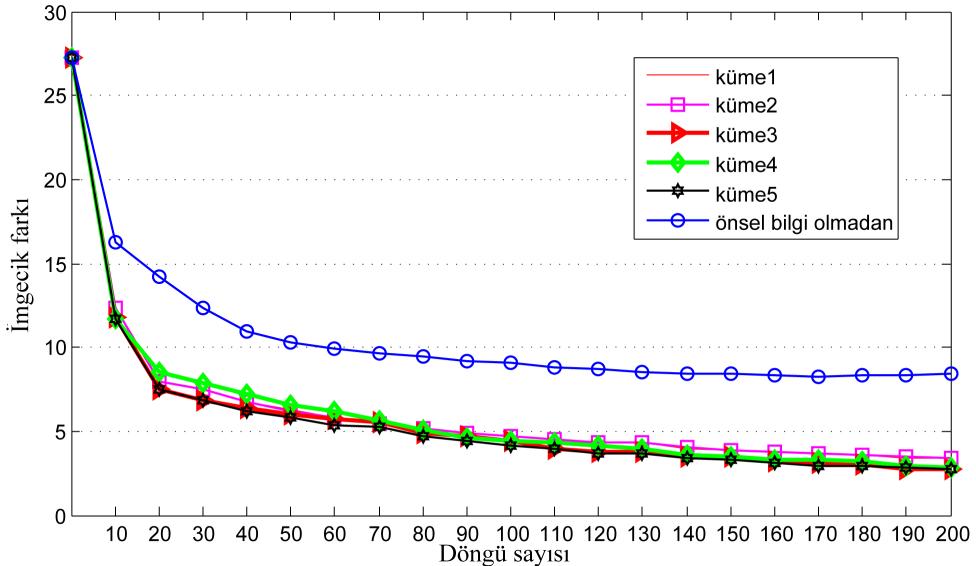
2.3.2. Kalp MR İmgelerinden Kontur Bulma

Geliştirilen metot kalp MR imgelerine de uygulanmıştır. Kalp MR imgesi veri kümesi [Stegmann, 2000] 14 tane 2 boyutlu 256x256 piksel boyutunda kalp MR imgesi içermektedir. Tüm imgeler kısa eksenli, uç-diyastol fazına aittir ve 1.0 Tesla ile çalışan tüm vücut MR cihazı ile elde edilmiştir. Sol karıncığının iç ve dış duvarı, her konturun 33 nokta ile bir kardiyolog uzmanı tarafından işaretlenmesiyle belirlenmiştir.

Geliştirilen metodun doğrulanması birini dışında bırakma değerlendirme ile gerçekleştirılmıştır. Yani bir imgeyi test ederken, diğer imgeler önsel olarak kullanılmışlardır. Aynı veri kümesi üzerinde, Stegman ve diğerleri [Stegmann, 2000] kontur bulma işlemini AGM ve aktif görünüm modelinin bazı varyasyonları ile gerçekleştirmiştir. Geliştirdiğimiz metodumuzun bulduğu sonuçları, [Stegmann, 2000] ile karşılaştırmak için Stegmann'ın kullandığı formül olan noktanın eğriye uzaklığını



Şekil 2.4: (a) Ekokardiyografik imgeler. (b) Oto2 metodu ile üretilen konturlar. (c) Mavi konturlar uzmanlar tarafından çizilen konturlar, kırmızı kontur da Oto2 ile üretilen konturlardır.



Şekil 2.5: Önsel olarak 5 farklı veri kümesi kullanılarak ve hiç önsel olmadan aynı imgeden kontur bulunmasındaki uzaklıklar.

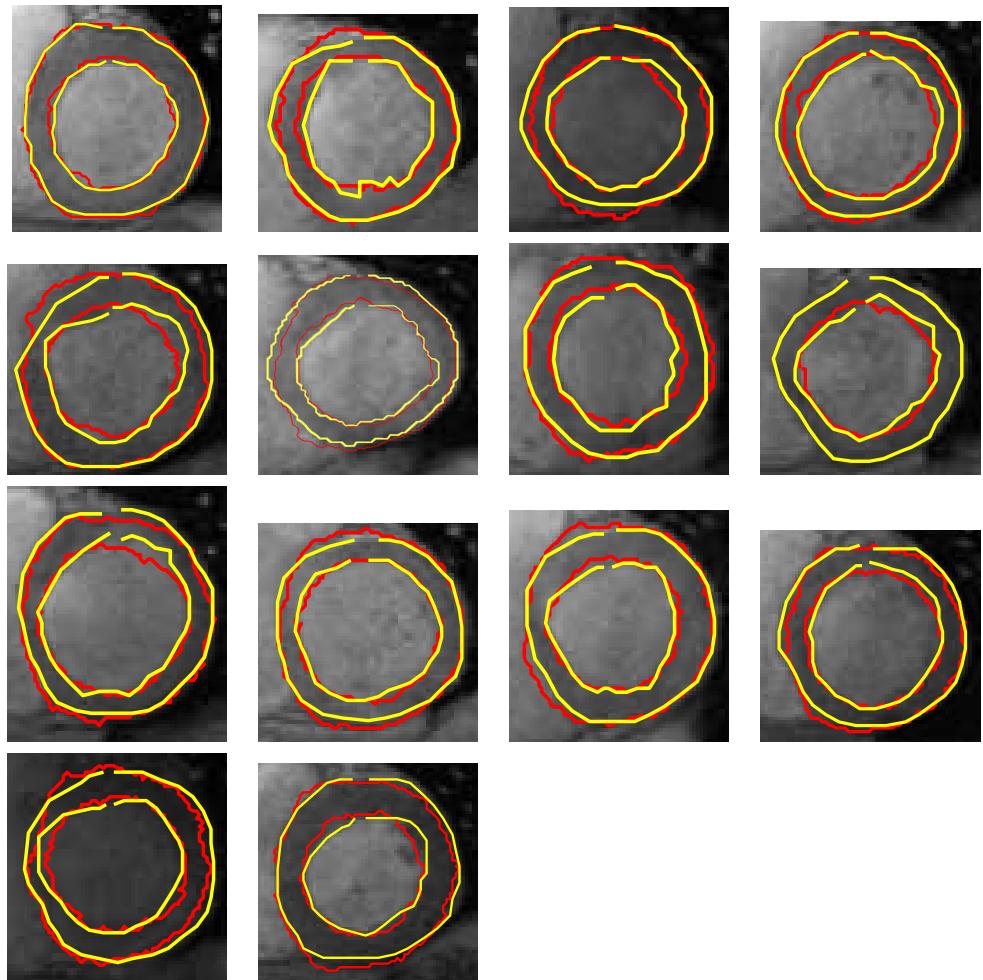
$$D(\mathbf{x}_{ec}, \mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \min_t \sqrt{(x_i - r_y(t))^2 + (y_i - r_x(t))^2} \quad (2.9)$$

kullanılmıştır. Bu formülde, $r(t) = (r_x(t), r_y(t))$, $t \in [0, 1]$ uzman kontur noktaları (ec)'ye yerleştirilmiş doğrusal şerittir ve \mathbf{x} bulunan konturun noktalarını içermektedir.

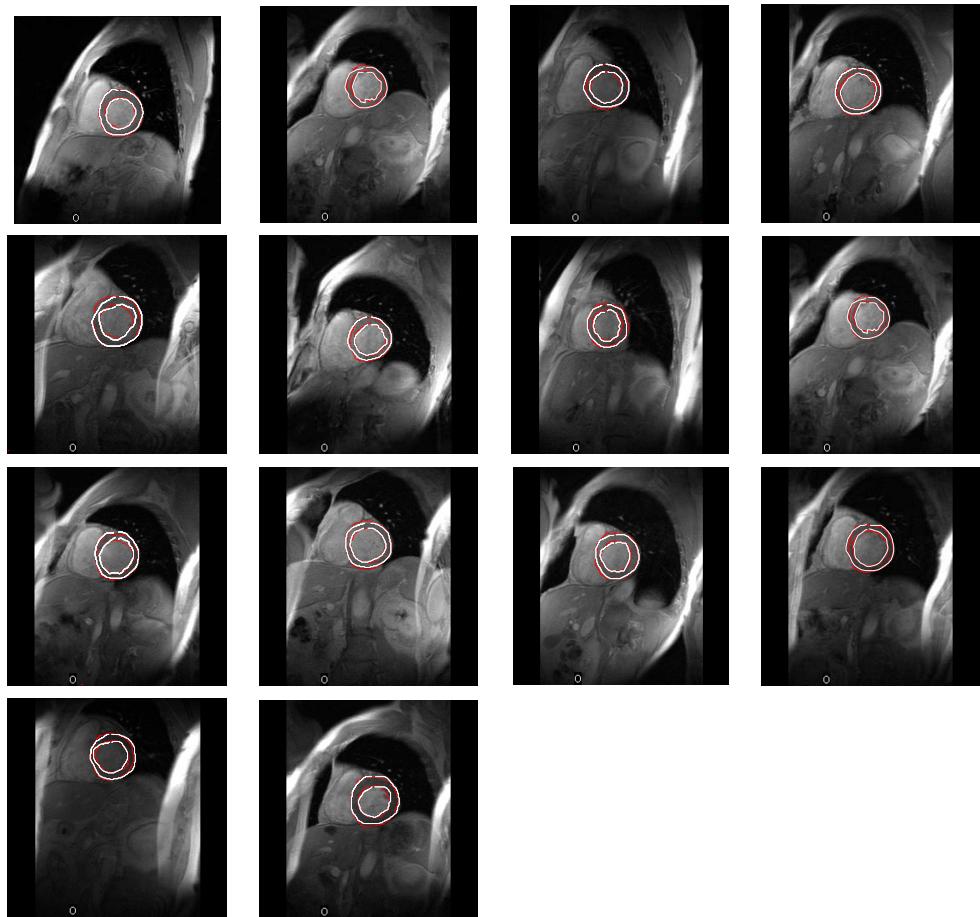
Çizelge 2.2'de geliştirilen sistemin ve Stegmann tarafından geliştirilen sistemlerin Denklem 2.9 ile hesaplanmış uzaklıkları gösterilmiştir. Stegmann, klasik aktif görünüm modelini ve bu metodun 3 farklı genişletimini uygulamıştır. Bu genişletimler, piksel komşuluğundan bilgi elde etme, benzetimli tavlama ile yerleştirilmiş model ve hata normu olarak Lorentzian uzaklışı kullanma şeklindedir. Deneyler aynı şekilde birini dışında bırakma tekniği ile gerçekleşmiştir. [Stegmann, 2000] tarafından bulunan minimum uzaklık 1.06 pikseldir. Geliştirilen sistemin bulduğu ortalama uzaklık ise 1.02 piksel değerindedir. Şekil 2.3.2 geliştirilen sistemin bulduğu veri kümesindeki tüm MR imgeleri için kontur bulma sonuçlarını kesilmiş biçimde, Şekil 2.3.2 ise tüm MR imagesini göstermektedir. Sonuçların görsel analizi sistemin kalp MR imgelerinde de oldukça dayanıklı olduğunu göstermiştir.

Çizelge 2.2: MR veri kümesi üzerinde, 5 farklı metodun bulduğu noktanın eğriye olan uzaklığını gösteren sonuçlar.

Metot	Uzaklık (piksel)
Geliştirilen metot	1.02
Klasik aktif şekil modeli [Stegmann, 2000]	1.18
1+Komşuluk [Stegmann, 2000]	1.73
1+Benzetimli tavlama [Stegmann, 2000]	1.06
3+Lorentzian uzaklığı[Stegmann, 2000]	1.13



Şekil 2.6: Veri kümesindeki kesilmiş 14 kalp MR imgesi. Kırmızı konturlar sistem tarafından otomatik olarak bulunan konturlar, sarı konturlar ise uzman tarafından çizilmiş konturlardır.



Şekil 2.7: Veri kümesindeki 14 kalp MR imgesi. Beyaz konturlar uzman konturu, kırmızı kontur ise sistem tarafından otomatik olarak bulunan konturlardır.

2.4. Yorumlar

Bu bölümde, tıbbi imgelerde biçim değiştirilebilir modeller için bir önsel bilgi ekleme çerçevesi sunulmuştur. Geliştirilen çerçeve, önceden çizilmiş şekil ve görünüm olarak en benzeyen uzman konturunu belirli aralıklarla yeniden ilklendirme tekniğine dayanmaktadır. Önsel bilginin bu şekilde dahil edilmesi, organın şekil ve görünüm özelliklerini kaybetmemesini sağlamaktadır.

Metodun birimselliği, kontur bulma işlemi için esnek bir çevre sağlamaktadır. Metot yılanlar ve düzeykümesi gibi farklı biçim değiştirilebilir modellerle kullanılabilir. Ayrıca, uzman kontur eşleştirme yaklaşımı değiştirilerek farklı organ konturları da bulunabilir. Bu çalışmada, apaçık bir eşleştirme yöntemi kullanılmasına rağmen, daha hızlı ve verimli eşleştirme metotları sisteme dahil edilebilir.

Geliştirilen metod, klasik önsel bilgi tabanlı kontur bulma sistemlerinden daha farklıdır. Metotta, en başta tanımlanmış ve eğitim ile oluşturulmuş bir model kullanılmamaktadır. Bunun yerine önsel bilgi gelişim sırasında direk olarak dahil edilmektedir. Bu, aşırı eğitilme riskini ortadan kaldırılmakta ve anında yeni uzman konturu ekleme ve çıkarma avantajını sunmaktadır ve böylece hata ayıklama kolaylaşmaktadır. Geliştirilen sistemde sadece şekil ve imge bilgisi kullanılmasına rağmen, başka tip bilgiler en benzer uzman konturunu seçme işlemeye kolaylıkla eklenebilir. Mesela, iç kontur alanı veya köşe sayısı gibi bilgiler yeniden ilklendirme sırasında önsel bilgi olarak kullanılabilir. Metodun başka bir avantajı da, önsel bilgi terimlerinin biçimsel model fonksiyoneline eklenmemesidir. Yüzey gelişiminin ve önsel bilgi eklenmesinin birbirinden bağımsız olması daha basit, modüler ve esnek bir formülasyon oluşturmaktadır. Ayrıca ölçekleme, döndürme gibi işlemler en benzer uzman kontur seçimi işleminde gerçekleşmekte ve onlar da biçimsel model fonksiyoneline eklenmemektedir.

Klasik önsel tabanlı kontur bulma metotları genellikle hedef şekiller için bir dağılım farz etmektedirler. Bu metodlar dağılım tipleri ve dağılım parametrelerini tahmin etmek durumundadır. Bu, şekil uzayında tanımlayıcı örneklerin çok dikkatli seçilmesini gerektirir. Geliştirilen metod da tanımlayıcı örneklerle ihtiyaç duysa da, bir dağılım ve parametre tahmin fazına ihtiyaç duymamaktadır.

Diğer taraftan, sistemle alakalı bazı eksiklikler de bulunmaktadır. İlk olarak tüm biçim değiştirebilir modeller gibi, sistem de açık konturları ve kesişen nesneleri (daha karmaşık bir kontur eşleştirme metodu kullanmadan) bulamaz. İkinci olarak, diğer sistemler eğitim aşamasında birkaç tanımlayıcı olmayan konturu tolere edebilir, fakat geliştirilen sistem eğer tanımlayıcı olmayan kontur en benzeyen kontur olarak çok kere seçilirse tolere edemeyebilir. Ayrıca, önsel olarak kullanılan uzman kontur sayısı arttıkça hesaplamasal zaman da artar, fakat bu hızlı eşleştirme algoritmalarıyla düşürülebilir.

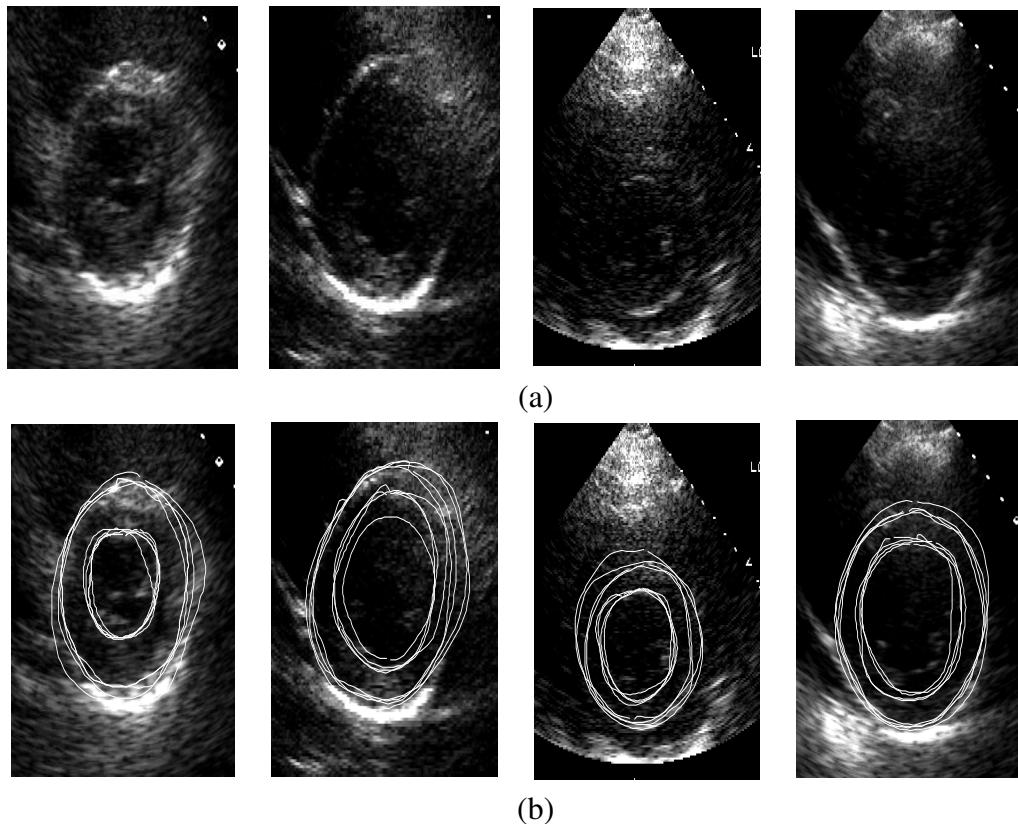
3. LOKAL VE GLOBAL ÖNSEL BİLGİ KULLANARAK MAKİNE ÖĞRENMESİ ve DÜZEY KÜMESİ METOTLARIYLA KONTUR BULMA

3.1. Giriş

Geleneksel kontur bulma teknikleri ([Kass et al., 1988; Malladi et al., 1995] gibi) her zaman doğrudan otomatik kontur bulma işleminde kullanılamaz. Bunun sebebi genellikle çok gürültülü imgeler, kapalı nesneler veya nesneye kesişen ilgisiz parçalar olabilir. Özellikle tıbbi imgelerin çoğunda bu tip problemlerle sık karşılaşıldığı için klasik kontur bulma teknikleri tek başına uygulanmamaktadır. Literatürdeki teknikler, bu problemi hedef nesne hakkında şekil önsel bilgisi ekleyerek [Chen et al., 2002; Paragios, 2003] farklı regülarizasyon stratejileri uygulayıp çözmeye çalışmaktadır. Özellikle az imge bilgisinin olduğu yerlerde, bu stratejiler kontur bulma işleminin başarısını önemli derecede artırmaktadır. Fakat çoğu zaman sadece şekil bilgisi, imge gradyanı şiddetinin az olduğu nesnelerde yeterli olmamaktadır.

Önceki bölümde de dephinildiği üzere Chen ve diğerleri [Chen et al., 2007] bir imge kümesinden eğitimle parlaklık modeli oluşturarak, nesne konturlarının parlaklık profillerini kullanmayı önermişlerdir. Benzer bir parlaklık ve eğrilik profil bilgisi, Leventon ve diğerleri [Leventon et al., 2000] tarafından kullanılmıştır. Bresson ve diğerleri [Bresson et al., 2006] TBA kullanıp şekil modeli oluşturan, imge gradyanı ve alan bilgisini enerji fonksiyonelinde kullanan bir varyasyonel model önermiştir. Böyle önsel bilgileri kullanarak kontur bulma işlemi yapmak gayet kullanışlı olsa da, hareket ve bir noktaya uzaklık gibi imgeye bağlı ve bağlı olmayan önselleri biçim değiştirebilir modellerle bir arada kullanmak özellikle tıbbi imgeler için oldukça zordur.

Makine öğrenmesi metotları, değişik tipteki yapı özniteliklerini eğitimle öğrenerek hedef yapıları saptarlar. Adaboost [Freund and E.Schapire, 1997], tıbbi imgeler üzerinde çalışan topluluklar tarafından organları saptamak amacıyla sıkça kullanılan popüler bir makine öğrenmesi metodudur. Carneiro ve diğerleri [Carneiro et al., 2008] cenine ait yapıları ve Feng ve diğerleri [Feng et al., 2009] ceninlere



Şekil 3.1: (a) Örnek 4 tane sol karıncığın kısa eksenli göğüsten geçen görüntüsünü içeren ekokardiyografik img. Sol karıncığın sol ve sağ yan duvarları sinyal düşmesi nedeniyle düşük imge gradyan şiddetine sahiptir. (b) Aynı imgelerin iç ve dış konturlarının 4 farklı uzman tarafından işaretlenmiş hali.

ait yüzleri istatistiksel artırma ağaç teknigi ile ultrason imgelerinden saptamışlardır. Georgescu ve diğerleri [Georgescu et al., 2005] Adaboost kullanarak sol karıncığın endokardiyal konturunu yapı saptama ile belirlemiştir. Adaboost ayrıca damar sınırlarını bulmak için [Pujol et al., 2003] ve kalp sınırlarını takip etmek için [Qian et al., 2006] kullanılmıştır.

Ekokardiyografi kalp hareketi analizi ve kalp hastalıkları için sıkça kullanılan girişimsel olmayan, düşük maliyetli ve taşınabilir bir tıbbi görüntüleme tekniğidir. Endokardiyum ve epikardiyumun belirlenmesi ile kalp fonksiyonları, kalp duvarının boyutu ve kalınlığı gibi kalp morfolojis, kalp odacıklarının hacmi ve ejeksiyon fraksiyonu (kan pompalama kapasitesi) gibi önemli bilgiler elde edilmektedir. Günümüzdeki klinik uygulamalarda, kalp duvarları uzmanlar tarafından manüel olarak çizilmektedir [Kumar et al., 2009]. Lakin, duvarların çizilmesi işlemi kullanıcıya bağlı, zaman alıcı ve verimsizdir. Ayrıca, uzmanlar arasında değişimlere neden

olmaktadır (Şekil 3.1). Sonuç olarak, kalp duvarlarının otomatik olarak bulunması, ölçümelerin doğruluğunun artırılması ve kalp değerlendirmesini hızlandırmak için önem arz etmektedir.

Bu bölümde, ekokardiyogramlardan epikardiyal ve endokardiyal sınırların bulunması için geliştirilen lokal ve global bilgiyi düzey kümesi ve Adaboost ile ekleme metodu anlatılmaktadır. Eklenen bilgi, lokal ve global olarak iki sınıfa ayrılmıştır, çünkü hedef yapı hakkında farklı bilgiler içermektedirler. Global önsel, diğer klasik önsel metodlarında kullanıldığı gibi, hedef yapının genel şekil bilgisini kastetmektedir. Lokal önsel ise, imgede hedef sınırları yerel olarak tanımlanabilen görünüş bilgisi, zamansal öznitelikleri, yerel geometrik şekil ve bir noktaya uzaklık gibi bilgileri içermektedir. Geliştirilen sistemde, lokal önsel bilgi Adaboost ile herhangi bir regülarizasyon tekniği kullanılmadan öğrenilmektedir. Daha sonra global şekil bilgisi bir önceki bölümde anlatıldığı gibi sisteme dahil edilmektedir [Oktay and Akgul, 2009, 2010].

Sistem ilk olarak ekokardiyografik imgeleri kutupsal imgelere dönüştürmektedir. Kutupsal imgeler lokal önselleri öğrenmek için belirli açı aralıklarına bölünmektedir, çünkü açı aralıkları farklı yerel özniteliklere sahiptir. Endokardiyum ve epikardiyumun da lokal ve global öznitelikleri birbirlerinden farklıdır, bu yüzden onlar da ayrı ayrı eğitilmişlerdir. Test fazında, kutupsal imgedeki her piksel endokardiyum ve epikardiyum olma ihtimalini gösteren iki skor değeri alır. En son, lokal ve global önseller düzey kümesi çerçevesi altında, Adaboost'un çıktısını düzey kümesinde kullanarak birleştirilir.

Metodun birçok avantajı bulunmaktadır. İlk olarak, harekete bağlı zamansal kalp duvari bilgisi kontur bulma işlemine 3 boyutlu zaman-uzamsal Haar tipi filtrelerle ayrı bir 3 boyutlu kontur modeline ihtiyaç kalmadan eklenmiştir. Ekokardiyografide bu büyük bir avantajdır, çünkü kalp duvarının bazı parçaları sadece hareket bilgisi ile belirlenebilmektedir. İkinci olarak kutupsal ekokardiyografik imgelerin açısal aralıklara bölünmesi, açı aralığına özgü eğitim mekanizması sağlamaktadır. Bu avantaj sinyal düşmesi problemini [Qian and Tagare, 2006] büyük ölçüde çözmektedir, çünkü sinyal düşmesi olan ve olmayan aralıklar ayrı ayrı eğitilip birbirlerini etkilememektedir. Üçüncü olarak, lokal önsel bilgisi imgelerden birbirinden çok farklı

filtrelerle çıkartılmış özellikleri ya da parlaklık profilleri gibi öznitelikleri kullanabilir. Mesela, Chen ve diğerleri [Chen et al., 2007] tarafından önerilen imge önseli metoda eklenebilir. Üstelik, komşu sınır noktaları arasındaki geometrik ilişki gibi imge ile alakalı olmayan lokal önseller de metoda eklenebilir. Sonuç olarak, lokal ve global önsellerin ayrılması, farklı tipteki bilgilerin entegrasyonunu sağlayarak daha sistematik ve modüler bir yaklaşım sunmaktadır.

Geliştirilen metod, gerçek kısa eksenli ekokardiyografik imgelerde test edilmiştir. Sistemin doğruluğunu gerçek konturların tam doğruluğunun olmaması nedeniyle değerlendirmek zordur; bu yüzden sentetik olarak oluşturulan imgelerde de sistem test edilmiştir. Ayrıca, sentetik imgeler filtrelerin etkinliğini ölçmek için kullanılmış ve sistem literatürden başka metotlarla değişik gürültü seviyelerinde karşılaştırılmıştır.

3.2. Lokal Önseller

Hedef nesne/organ, farklı zaman-uzamsal konumlarda farklı karakteristiklere sahipse lokal önsel kullanmak gereklidir. Bu yüzden geliştirilen sistemde, kutupsal ekokardiyografik imgelerden lokal, uzamsal ve hareket öznitelikleri çıkartılmıştır. Bu öznitelikler Adaboost ile öğrenilmiş ve hedef imgedeki her piksele global önselle kullanılmak üzere iki skor değeri atanmıştır.

3.2.1. Ekokardiyogramlardan Lokal Özniteliklerin Çıkartılması

Bu bölümdeki lokal önsel bilgi kalbin endokardiyal ve epikardiyal sınırları çevresindeki yerel olarak tanımlanabilen öznitelikleri tanımlamaktadır.

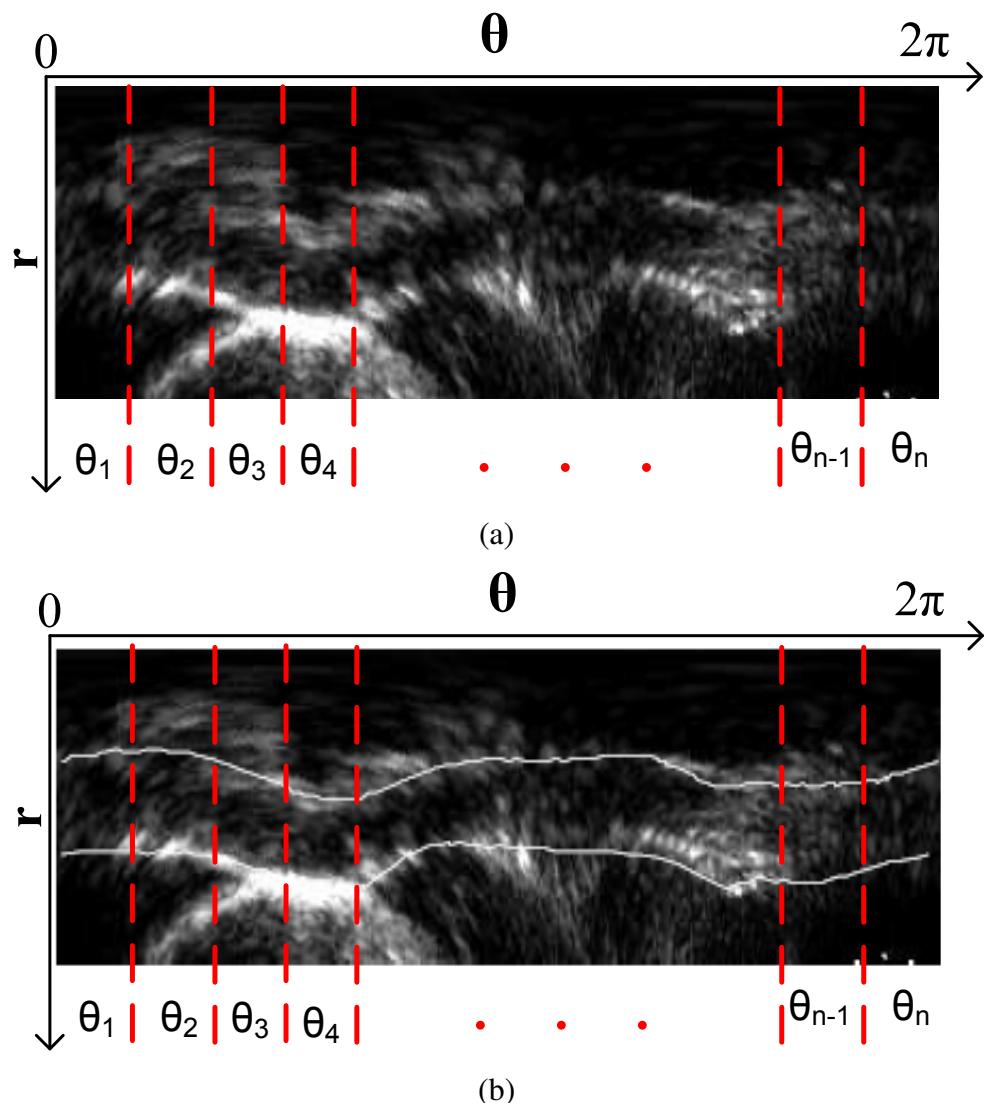
Sol karıncığın merkezini kutupsal merkez olarak (Şekil 3.2) kullanarak imgeleri kutupsal koordinatlara çevirmenin birçok avantajı bulunmaktadır. İlk olarak, imgeler arasındaki ötelemesel farklar en aza indirilmektedir, çünkü sol karıncık merkezleri kutupsal merkez olarak belirlenmektedir. Sonuç olarak, kalp merkezinden kalp konturuna olan uzaklık, lokal önsel olarak kullanılabilecek bir

öz nitelik olmaktadır. İkinci olarak, kutupsal kordinatlarda kalp duvari yönelimi benzerdir (yaklaşık olarak yataydır). Bu yüzden kontur yönelimini belirlemek için, az sayıda filtre kullanmak yeterlidir ve bu da Haar tipi filtrelerin sayısının az olmasını sağlar. Literatürde, tıbbi imgelerde benzer şekilde kutupsal kordinatlar kullanılmıştır [Lee et al., 2010]. Kutupsal koordinat kullanmanın dezavantajı sol karıncık duvarlarını bulmadan önce sol karıncığın merkezini belirtme zorunluluğudur. Sol karıncığın merkezi [Wilson and Geiser, 1992]'deki gibi otomatik olarak bulunabilir, fakat bu çalışmada sol karıncık merkezleri eğitim ve test safhasında manuel olarak belirlenmiştir.

Ultrason cihazı, ultrason ışınlarının paralel olarak geldiği doku arayüzlerinde yüksek imge gradyan şiddetini oluşturur. Eğer ultrason ışınları doku arayüzlerine dik olarak geliyorsa, o zaman düşük imge gradyan değerleri oluşur. Bu etkiye sinyal düşmesi adı verilir (Şekil 3.1). Bu ultrason kipine bağlı bilgiyi elde etmek için kutupsal imge, $i = 1 \dots n$ olduğu ve n 'nin aralık sayısını ifade ettiği birbirleriyle kesişen θ_n aralığına bölünmüştür. θ_1 değeri manuel olarak belirlenmiştir (Şekil 3.2). Her θ_i aralığındaki öznitelikler ayrı ayrı çıkartılmış ve ayrı ayrı eğitilmiştir. Böylelikle, sol karıncığın sinyal düşmesi dahil belirli pozisyonlardaki öznitelikleri birbirleriyle çok fazla karışmadan öğrenilmiştir.

Zaman-uzamsal bilgi sol karıncık sınırlarının belirlenmesi için gereklidir ve bu bilginin kontur bulma işlemine dahil edilmesi daha iyi sonuçlar üretmektedir [Akgul and Kambhamettu, 2003], [Noble and Boukerroui, 2006]. Klinik uygulamalarda uzmanlar kalp döngüsünü bir film gibi izleyerek, zaman-uzamsal bilgiyi de ekleyerek manuel olarak konturları bulurlar [Kumar et al., 2009]. Bu çalışmada, zaman-uzamsal bilgi 3 boyutlu Haar tipi filtreler kullanılarak sisteme dahil edilmektedir ve böylelikle sistem, açık dışarıdan karmaşık ve minimize etmesi zor olan bir zaman-uzamsal biçim değiştirebilir model kullanmaktan kurtarılmaktadır. Bu çözüm, zaman-uzamsal kısıtlamaları güvenle lokal önsellerle birlikte kullanmamızı sağlamaktadır.

Benzer bir teknik, Viola ve diğerleri [Viola et al., 2003] tarafından parlaklık ve hareket bilgisini entegre ederek ve komşu çerçeveler arasındaki farkları kullanarak başarılı bir şekilde yayaları saptamak için kullanılmıştır. [Viola et al., 2003] çalışmasından ve diğer sınıflandırma tabanlı saptama sistemlerinden farklı olarak,



Şekil 3.2: (a) Kutupsal koordinatlara çevrilmiş bir ekokardiyografik imgé (b) aynı imgenin epikardiyal ve endokardiyal sınırlarının uzman tarafından belirlenmiş konturları.

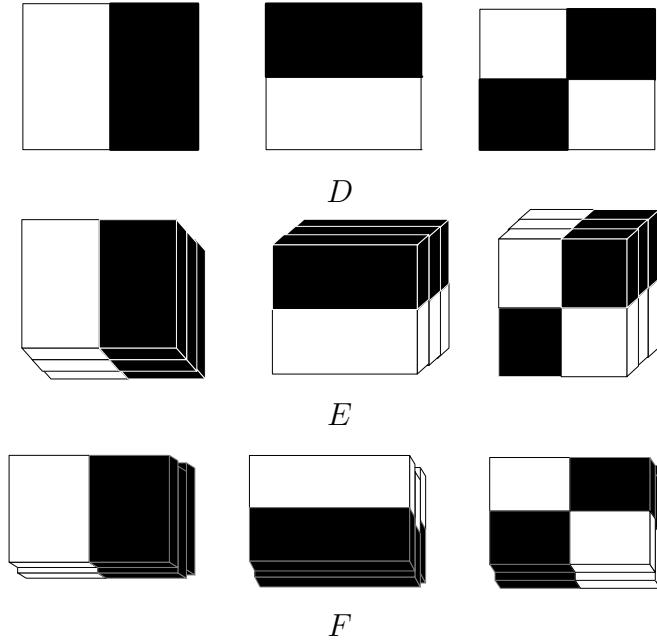
geliştirilen sistemde Adaboost ile herhangi bir nesne saptama yapılmamaktadır. Bunun yerine, Adaboost lokal bilgi içeren skor imgeleri üretmede kullanılmaktadır.

Şekil 3.3'te görüldüğü üzere 3 tip filtre kümesi D , E ve F imge özniteliklerini çıkarmada kullanılmaktadır. Bu filtreler, uç-sistol ve uç-diyastol imgelerine uygulanmaktadır. Ayrıca bu filtrelerin gri düzey tersleri de kullanılmaktadır. Her filtre tipi için, öznitelik değeri koyu renk alanın parlaklık değeri toplamının, açık renk alanın toplam parlaklık değerinden çıkartılması ile hesaplanmaktadır [Viola and Jones, 2004].

2 boyutlu filtre kümesi D uzamsal görünüm bilgisi çıkartır. 3 boyutlu zaman-uzamsal filtre kümesi E , D kümesindeki filtrelerin yiğit haline getirilmiş versiyonudur ve zaman boyutunda görünüm ve hareket bilgisi çıkartmaktadır. F tipindeki filtreler de yine D kümesindeki filtrelerin yiğit haline getirilmiş versiyonudur, fakat filtreleri yiğarken kontur hareketini algılamak için bu filtreler bir miktar kaydırılmıştır. F filtreleri, uç-sistol için yukarıya ve uç-diyastol için aşağıya kaydırılmaktadır. Kutupsal koordinatlara çevrilmiş (θ, r) uzayındaki kalp imgeleri, uç-sistol fazında en küçük r değerine, uç-diyastol fazında da en büyük r değerine sahiptir (Şekil 3.2). Uç-sistol fazındaki imgenin komşu imgelerinin r değerleri, uç-sistol fazındaki imgenin r değerlerinden 1-3 piksel daha büyük r değerlerine sahiptir. Uç-sistol fazındaki kontur hareketini elde etmek için, F filtreleri komşu kareleri 1, 2 veya 3 piksel yukarıya kaydırmaktadır. Benzer şekilde, uç-diyastol fazındaki imgenin komşu kareleri de 1, 2 veya 3 piksel aşağıya kaydırılmaktadır.

Çerçeveler arasındaki kesin hareket bilgisine tam olarak sahip olunmadığından, hareket bilgisini yakalamak için F filtreleri değişik miktarlarda kaydırılarak uygulanmıştır. Daha sonra F filtrelerinden en büyük değeri veren filtre seçilip kullanılmış ve hareket bilgisi etkili bir şekilde elde edilmiştir.

Zaman-uzamsal filtre kümeleri E ve F , ultrason cihazının ürettiği gürültüyü adreslemekte etkilidir çünkü komşu çerçevelerde hareket bilgisini de içermektedir. Filtrelerin birçok değişik versiyonu, boyutları ($2 \times 2 \times 1$ 'den $20 \times 20 \times 5$ 'e kadar), gri düzey tersleri ve dikdörtgensel şekilleri uygulanmıştır. D tip filtreler, integral imge teknigi [Crow, 1984], [Viola and Jones, 2004] ile kolaylıkla hesaplanmaktadır. E ve F filtreleri de integral hacim teknigi [Liu et al., 2009] ile hesaplanmaktadır.



Şekil 3.3: Öznitelik çıkarmak için kullanılan 3 filtre kümesi. Ayrıca, bu filtrelerin gri düzey tersleri de kullanılmaktadır. D kümesi sadece uzamsal filtreleri içerirken, E ve F kümeleri zaman-uzamsal filtreleri içermektedir.

Lokal önsel modeli eğitmek için, m 'nin özniteliğin tipini gösterdiği öznitelikler f_m çıkartılmıştır. θ 'nın açı aralığını belirttiği ve B 'nin kontur tipi (epikardiyum veya endokardiyum) olduğu öznitelikler her $\theta \cdot B$ için ayrı ayrı hesaplanmıştır.

İlk öznitelik tipi $f_1^{(\theta, B)}(p)$, kalp duvar noktası p 'nin sol karıncık merkezine olan uzaklığıdır:

$$f_1^{(\theta, B)}(p) = R(p), \quad (3.1)$$

$R(p)$ kutupsal koordinatlardaki p noktasının r pozisyonudur.

Diğer tüm özellikler imge ile alakalıdır:

$$f_k^{(\theta, B)}(p) \in \{D(p)\} \cup \{E(p)\} \cup \{F_i(p)\}, \quad (3.2)$$

$\{D(p)\}$ ve $\{E(p)\}$, p pikseline uygulanan D ve E kümelerindeki filtrelerin tümüdür. F kümelerindeki filtreler, diğer kümelerdeki filtrelerden biraz daha farklıdır, çünkü komşu çerçevelerdeki hareket ve dolayısıyla kaydırma miktarını belirlemek durumundadır. Kalp filmlerindeki hareket miktarı bilinmediğinden dolayı, p pikseline F kümelerindeki filtrenin tüm kaydırma miktarları uygulanmakta ve en büyük değeri veren $F_i(p)$ seçilmektedir.

Normalde, klasik Adaboost her öznitelijke bir ağırlık atamakta ve bu ağırlıkları doğrusal olarak toplamaktadır. Bizim sistemimizdeki F filtrelerinden herbirine bir ağırlık atanmamakta; bunun yerine en büyük değerleri veren $F_i(p)$ altkümesine ağırlık atanmaktadır. Bu da bizim sistemimizi doğrusal olmayan hale getirmektedir. Bu geliştirilen yeni metot, kalp çerçeveleri arasındaki bilinmeyen kontur hareketini belirlemekte kullanılmaktadır.

3.2.2. Adaboost ile Eğitilme ve Skor Verme

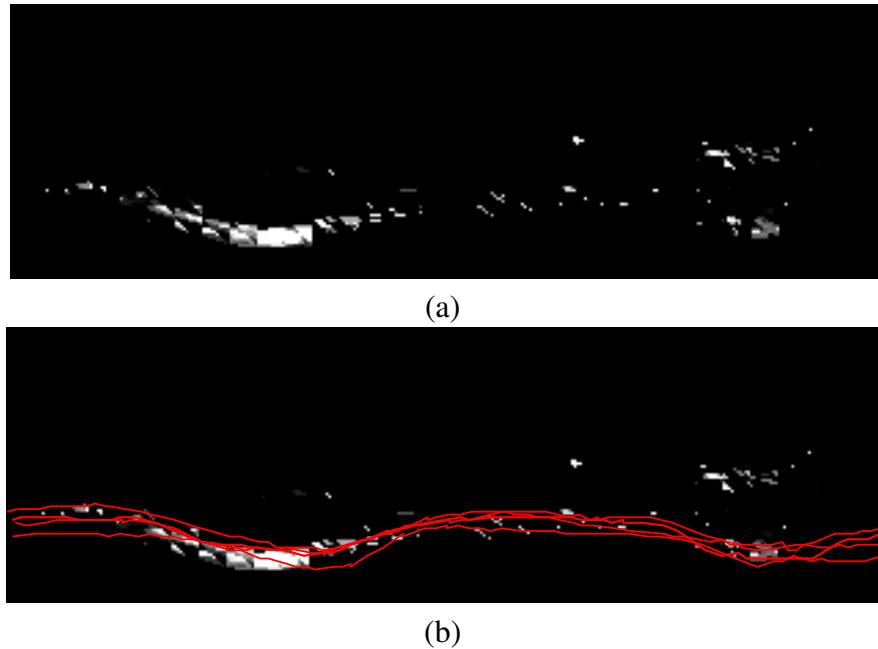
Popüler boosting metodlarından biri olan Adaboost kullanılarak, ekokardiyogramlardan çıkarılan lokal önsellerin eğitilme ve onlara skor verme işlemi gerçekleşmiştir. p pikseli için, (p, c) çiftini ve etiket $c \in \{-1, 1\}$ 'i p pikselinin sınıflandırma etiketi olarak varsayıyalım. p_f , p pikseli için Denklem 3.1 ve 3.2 ile çıkarılmış öznitelikler olsun. Adaboost, $h^{\theta, B}(p_f)$ zayıf sınıflayıcılarını kullanır ve bu sınıflayıcıların doğruluğuyla ters orantılı olarak α ağırlıklarını atar. Klasik Adaboost'tan farklı olarak bu çalışmada doğrudan ayrik sınıf değerlerini $sign(H(p))$ kullanmaktansa, $H(p)$ değerleri skor değerleri olarak kullanılmıştır. En son güçlü skor değeri şu şekilde oluşturulmuştur:

$$H^{\theta, B}(p) = \sum_{t=1}^T \alpha_t h_t^{\theta, B}(p_f), \quad (3.3)$$

T zayıf sınıflayıcıların toplam sayısını ve α ağırlıkları belirtmektedir.

Eğitim için, kutupsal koordinatlara çevrilmiş ekokardiyografik imge 36 θ aralığına bölünmüştür. Uzmanların çizdiği kontur pozisyonları pozitif örnek olarak ve aynı açı aralığındaki diğer pozisyonların rasgele seçilmiş %10'u negatif örnek olarak kullanılmıştır. Uzman çizimleri, bir kalp döngüsündeki sadece uç-sistol ve uç-diyastol imgeleri için mevcuttur; bu yüzden sadece uç-sistol ve uç-diyastol imgeleri eğitilmiş ve test edilmiştir. Her (θ, B) çifti farklı lokal bilgi içeriği için ayrı eğitilmiştir. Yani, bir (θ, B) çifti için bir $H^{\theta, B}$ bulunmuştur.

Skor verme işlemi için, bir açı aralığı θ 'daki her piksele Denklem 3.3 ile $H^{\theta, epi}$ ve $H^{\theta, endo}$ olmak üzere 2 skor değeri atanmıştır. Bu iki skor değeri ile iki skor imgesi



Şekil 3.4: (a) Şekil 3.2’te gösterilen imgenin piksel skorlama ile oluşturulmuş ve [0 255] parlaklığa normalize edilmiş hali. (b) Skor imgenin 4 farklı uzman tarafından çizilmiş epikardiyum konturları.

I^{epi} ve I^{endo} oluşturulmaktadır. Örnek bir skor imgesi I^{epi} , Şekil 3.4’te gösterilmiştir. Bu iki skor imgesi dikdörtgensel koordinatlara çevrilmiş ve [0 255] parlaklığa normalize edilmiştir. Bu iki dikdörtgensel imgi Bölüm 3.3’de anlatılan düzey kümesi fonksiyonunun dış enerji teriminde kullanılacaktır.

3.3. Düzey Kümesi Metodu ile Global Şekil Bilgisi Eklenmesi

Bu çalışmada, global önsel bilgi olarak sadece şekil bilgisi sisteme dahil edilmiştir. Global önsel için bir önceki bölümde anlatılan global bilgi ekleme metodunun değiştirilmiş versiyonu ile birlikte skor imgeleri I^{epi} ve I^{endo} kullanılmaktadır.

3.3.1. Düzey Kümesi Formülasyonu

Sol karıncık duvarlarının bulunması için $c_1(t)$ ve $c_2(t)$ eğrileri, zaman t ’ye bağlı olarak \mathbb{R}^2 düzleminde gelişmekte olsun. $c_1(t)$ ve $c_2(t)$, endokardiyum ve epikardiyumu ayrı ayrı bulacaklardır.

C , $c_1(t)$ ve $c_2(t)$ üzerindeki noktalar kümesi olsun. $\mathbf{x} \in \Re^2$ pozisyon vektörü ve ϕ de, Denklem 2.6'ya benzer şekilde aşağıdaki gibi tanımlanmış bir işaretli uzaklık fonksiyonu olsun:

$$\phi(\mathbf{x}) = \begin{cases} 0, & \text{eğer } \mathbf{x} \in C, \\ -d(\mathbf{x}), & \mathbf{x} \text{ eğer } c_1 \text{'nin dışında, } c_2 \text{'nin içindeyse,} \\ d(\mathbf{x}), & \text{diğer.} \end{cases} \quad (3.4)$$

Bu formülde d , C 'den \mathbf{x} 'e e küçük Öklid uzaklıği olarak tanımlanmıştır.

Bölüm 1'de anlatılan düzey kümesi formülasyonuna göre, oluşturulan yüzey iç ve dış enerji terimleri ile imgé üzerinde gelişir. İmgeden Denklem 1.4 ile çıkartılan kenar gösterge fonksiyonu g , alan ve uzunluk terimlerinin içinde bulunmaktadır. Bu sistemin en büyük farkı, sistemin doğrudan hedef imgeden çıkartılan kenar gösterge fonksiyonu g 'yi kullanmamasıdır. Lokal önsellerle oluşturulan ve içinde görünüş, hareket gibi bilgileri içeren skor imgeleri ile yeni bir imgé oluşturulmuş ve bu yeni oluşturulan imgé, g yerine kullanılmıştır.

I^{endo} ve I^{epi} , Adaboost ile skor değerleri verilmiş piksellerden oluşan ve normalize edilerek tekrar dikdörtgensel koordinatlara çevrilmiş skor imgeleridir. Yüzey ϕ , aşağıdaki gibi tanımlanan I üzerinde çalışır:

$$I(\mathbf{x}) = \begin{cases} \frac{1}{1+I^{endo}(x)}, & \text{eğer } \mathbf{x} c_1 \text{'e yakınsa,} \\ \frac{1}{1+I^{epi}(x)}, & \text{eğer } \mathbf{x} c_2 \text{'ye yakınsa.} \end{cases} \quad (3.5)$$

Oluşan I , enerji fonksiyonelinin dış güç terimleri içinde g yerine kullanılır. Böylece gelişmekte olan konturlar $c_1(t)$ ve $c_2(t)$, I^{endo} ve I^{epi} üzerindeki sınırlara doğru dış enerji ile hareket ederler.

Düzey kümesine, global şekil bilgisinin eklenmesi, Bölüm 2'deki yaklaşımın biraz farklı halidir ve metot kısaca bir sonraki bölümde anlatılmıştır.

3.3.2. Global Önsel Bilginin Eklenmesi

Lokal önsellerle birçok bilgi edinilmesine rağmen, kalp duvarlarının tümüyle bulunması için, global şeklin de bir şekilde kontur bulma işlemine dahil edilmesi gerekmektedir. Böylece, lokal bilginin yeterli olmadığı yerlerde global bilgi net

olmayan konturları bulacaktır. Mesela, Şekil 3.4'te gösterilen lokal bilginin eksik olduğu yerlere global bilgi eklemek zorunlu hale gelmektedir. Bu çalışmada, Bölüm 2'deki metot biraz değiştirilerek uygulanmıştır. İstendiği taktirde, daha sofistike metodlarla da ([Chen et al., 2007], [Bresson et al., 2006]) global şekil bilgisi eklenebilir.

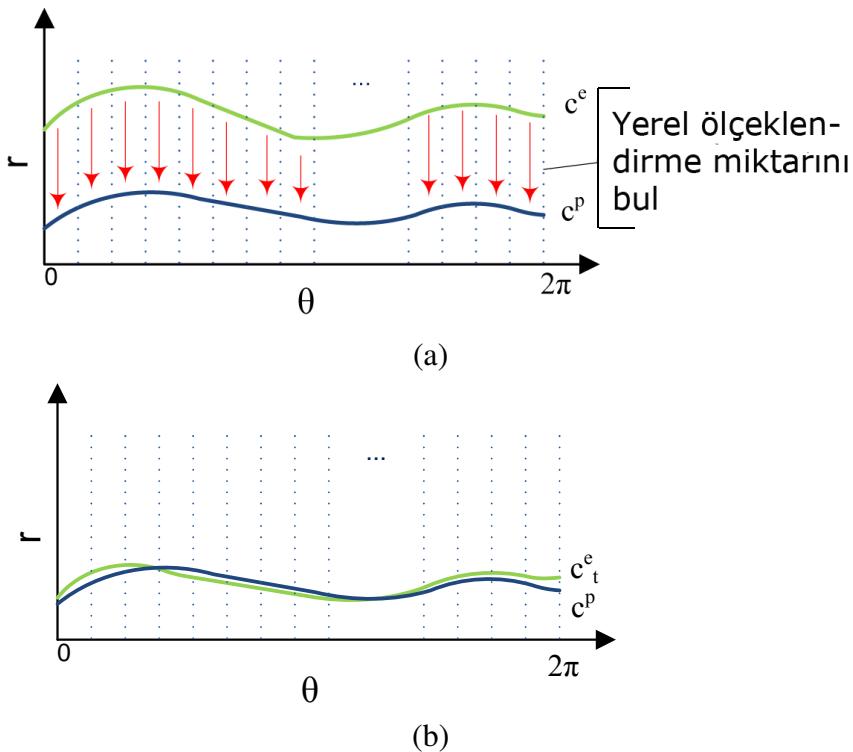
Metot şu şekilde işlemektedir: c_1^p ve c_2^p gelişen düzey kümesi yüzeyi ϕ 'deki sıfırıncı düzey konturları olsun ve c_1^e ve c_2^e de kutupsal koordinatlarla ifade edilmiş ($\theta - r$ uzayında) uzmanlar tarafından çizilen konturlar olsun. Uzman konturları için $e = 1 \dots m$ 'dir ve m toplam uzman konturu sayısıdır. Metot, şekil olarak eğriltilmiş uzman konturlarından, gelişen kontura en benzeyenini seçip, ondan oluşturulan yüzeyi yeniden ilklendirme felsefesine dayanır. Algoritmadaki temel adımlar şu şekildedir:

- c_1^p, c_2^p, c_1^e ve c_2^e konturlarını θ aralıklarına böl.
- Her aralık için, c^p ve c^e arasındaki yerel ölçeklendirme miktarını Denklem 2.1 ile bul (Şekil 3.5(a)).
- Yine her aralık için, bulunan yerel ölçeklendirme miktarını kullanarak, uzman konturu c^e 'yi c^p üzerine Denklem 2.2 ile eğrilt (Şekil 3.5(b)). Eğriltilmiş uzman konturları c_t^e olarak tanımlansın.
- Diğer uzman konturlarını da yukarıda anlatıldığı gibi eğrilt.
- r değerleri cinsinden c^p ile farkı en az olan eğriltilmiş uzman konturu c_t^e 'yi bul.

Şekil olarak gelişen kontura en çok benzeyen uzman konturları yukarıda anlatıldığı gibi bulunur. Endokardiyum ve epikardiyum için ayrı ayrı bulunan eğriltilmiş uzman konturları, Denklem 3.4 ile yeni yüzey oluşturmak için kullanılır. Yeni oluşturulan yüzey I üzerine yeniden ilklendirilir ve böylece uzmanlardan alınan global şekil bilgisi kontur bulma işlemine dahil edilmiş olur. Şekil 3.6'da sistemin işleyişi gösterilmiştir.

3.4. Deneysel Sonuçlar

Sistem hem gerçek ekokardiyografik imgelerde, hem de sentetik imgelerde test edilmiş ve doğrulanmıştır. Ekokardiyogramlardaki deneyler metodun etkili

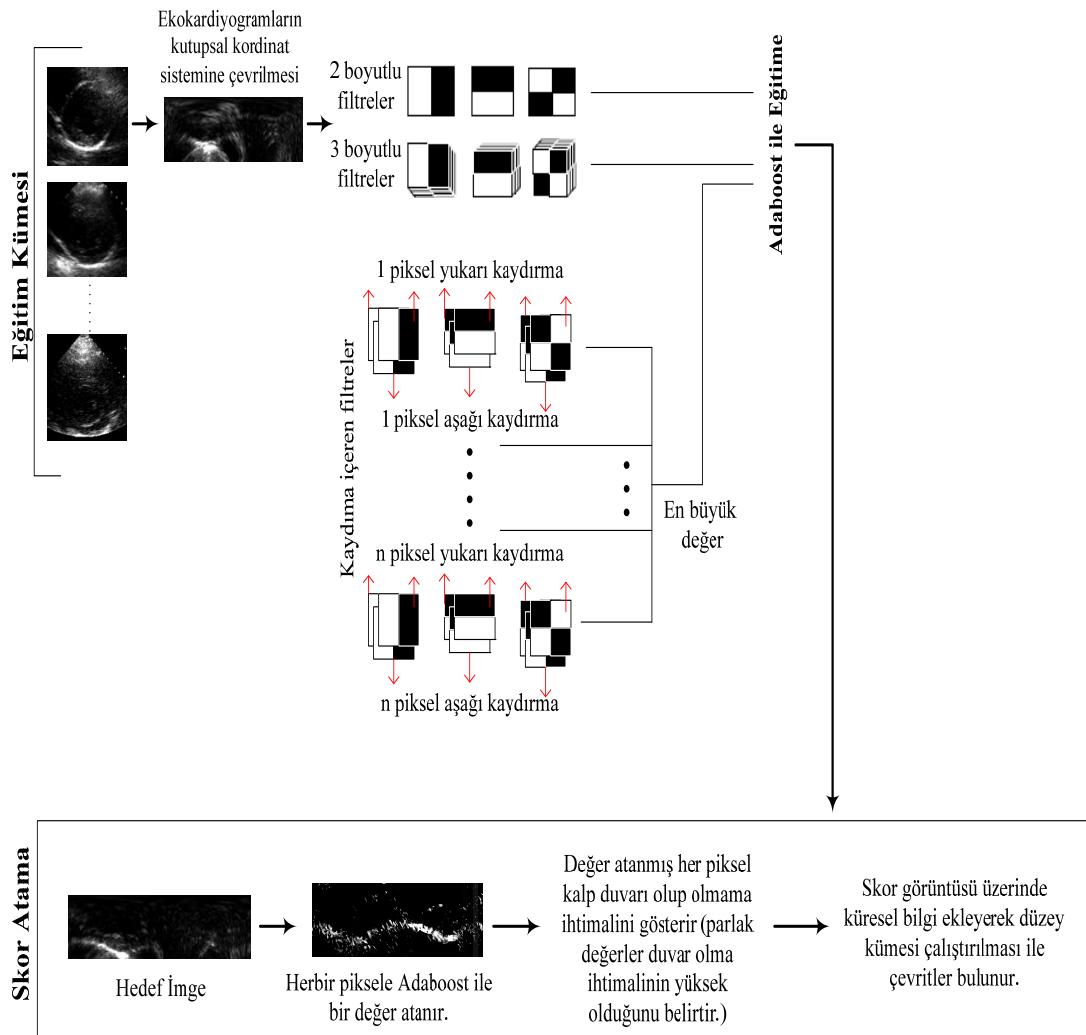


Şekil 3.5: (a) Eğriltmeden önceki sıfırıncı düzey konturları (b) Her θ aralığı için yerel ölçeklendirme miktarı hesaplanır ve uzman konturları, sıfırıncı düzey konturları üzerine eğriltirilir.

olduğunu ve pratik uygulamalarda kullanımını göstermek için yapılmıştır. Sentetik imgeler üzerindeki deneyler ise lokal önsellerin kontrol altındaki gürültü düzeylerinde gösterdikleri dayanıklılığı belirlemek için yapılmıştır. Sentetik imgeler ayrıca geliştirilen metodu literatürdeki başka metodlarla karşılaştırma imkanı sunmuştur.

3.4.1. Ekokardiyografik İmgeler

Once de belirtildiği gibi, metot sol karıncığın kısa eksenli göğüsten geçen ekokardiyografik görüntüleri üzerinde test edilmiştir. Veri kümesi, 20 farklı kişiye ait kalp döngülerindeki çerçeveleri içeren ekokardiyogramlardan oluşmaktadır. Bir kalp döngüsünde bir uç-sistol, bir uç-diyastol ve bunların arasındaki kareler bulunmaktadır. Uç-sistol ve uç-diyastol imgeleri 4 farklı uzman tarafından işaretlenmiştir (Şekil 3.1). Uç-sistol ve uç-diyastol arasındaki kareler işaretlenmemiştir. 20 kişi olduğu için, her hasta için 1 uç-sistol ve 1 uç-diyastol imagesi olmak üzere, uzman tarafından işaretlenmiş 40 tane image vardır. Endokardiyal ve epikardiyal konturların herbiri 100 nirengi noktası ile gösterilmiştir.



Şekil 3.6: Geliştirilen sistemin çalışma şeması.

Lokal önsel bilgi için deneyler şu şekilde yapılmıştır: 20 uç-sistol ve 20 uç-diyastol imgeleri her bir kümede 5 imgé olacak şekilde rasgele 4 alt kümeye ayrılmıştır ve her seferinde 3 alt kümedeki 15 imgé eğitilmiş ve 5 imgé test imgesi olarak kullanılmıştır. Epikardiyum ve endokardiyum için ayrı ayrı 4 tur yapılmış ve böylelikle tüm imgeler 3 kere eğitim kümesinde kullanılmış ve 1 kere test edilmiştir. Bir piksel için çıkartılan toplam öznitelik sayısı 1081'dir. Ayrıca, eğitim kümesindeki imgeler global önsel için de kullanılmaktadır.

Sistemin otomatik olarak bulduğu konturları değerlendirmek için 4 uzman tarafından çizilmiş konturlar kullanılmıştır çünkü tam doğru olan sol karıncık konturları mevcut değildir. Uzmanlar arasındaki farkı belirlemek için aynı şekilde uzman konturları da birbirleriyle karşılaştırılmıştır. Ortalama piksel farkları uzman-uzman ve uzman-sistem konturu şeklinde karşılaştırılmıştır. İki karşılaştırmak üzere verilen kontur $C_x = \{x_1, \dots, x_n\}$ ve $C_y = \{y_1, \dots, y_m\}$ arasındaki Chamfer uzaklığı $E(C_x, C_y)$ [Barrow et al., 1977] şöyle hesaplanmıştır:

$$E(C_x, C_y) = \frac{\sum_{i=1}^n Dist(x_i, C_y) + \sum_{j=1}^m Dist(y_j, C_x)}{n + m}, \quad (3.6)$$

$Dist(z, C)$, z noktası ve C konturu arasındaki en küçük Öklid uzaklığıdır.

40 farklı ekokardiyogram (20 uç-sistol ve 20 uç-diyastol) için piksel farkları hesaplanmıştır. Ortalama uzman-uzman uzaklıkları ve uzman-sistem uzaklıkları, ortalama \pm standart sapma şeklinde Çizelge 3.1'te gösterilmiştir. Veri kümesinden 3 farklı imgé ve sistemin otomatik bulduğu konturlar Şekil 3.7'te gösterilmiştir. En küçük ortalama piksel farkı Uzman 1 ve Uzman 3 arasındaki 3.10 piksel ve en büyük ortalama piksel farkı 6.72'dir (Uzman 1 ve Uzman 4 arasında). Sistemin oluşturduğu uzaklıklar 3.54 ve 5.10 piksel arasındadır.

İki kontur arasındaki piksel farkının az olması, sadece aralarındaki benzerliğin fazla olduğu anlamına gelir. Dolayısıyla, az piksel farkı her zaman iyi bir sonuç olarak yorumlanmamalıdır. Bunun yerine, Çizelge 3.1'deki sayılar, istatistiksel olarak ayrimın fark edilemediğini göstermek için verilmiştir.

Geliştirilen sistem, Bresson ve diğerlerinin [Bresson et al., 2006] temel bileşen analizine dayanan global şekil önseli metodu ile karşılaştırılmıştır. İlk olarak, [Bresson et al., 2006] metodu veri kümesindeki ekokardiyogramlardaki epikardiyal konturları bulmak için aynı deneysel ortamda uygulanmıştır ve sonuçlar Çizelge 3.1'de gösterilmiştir. Bu metot, geliştirilen sistemden doğal olarak daha kötü sonuçlar üretmiştir çünkü lokal olarak sadece imge gradyan bilgisi kullanmıştır ve bu bilgi bizim sistemimizin kullandığı bilgiden daha azdır.

Daha sonra [Bresson et al., 2006] metodu, sistemimiz tarafından bulunan skor imgeleri üzerinde yine aynı deneysel ortamda çalıştırılmıştır ve sonuçları Çizelge 3.1'de verilmiştir. Bresson ve diğerlerinin metodu [Bresson et al., 2006] skor imgeleri ile lokal bilgi eklendiğinde çok daha iyi sonuçlar üretmektedir.

Çizelge 3.1: Toplam 40 test endokardiyum ve epikardiyum imgesi için ortalama piksel uzaklıklar (ortalama \pm standart sapma)

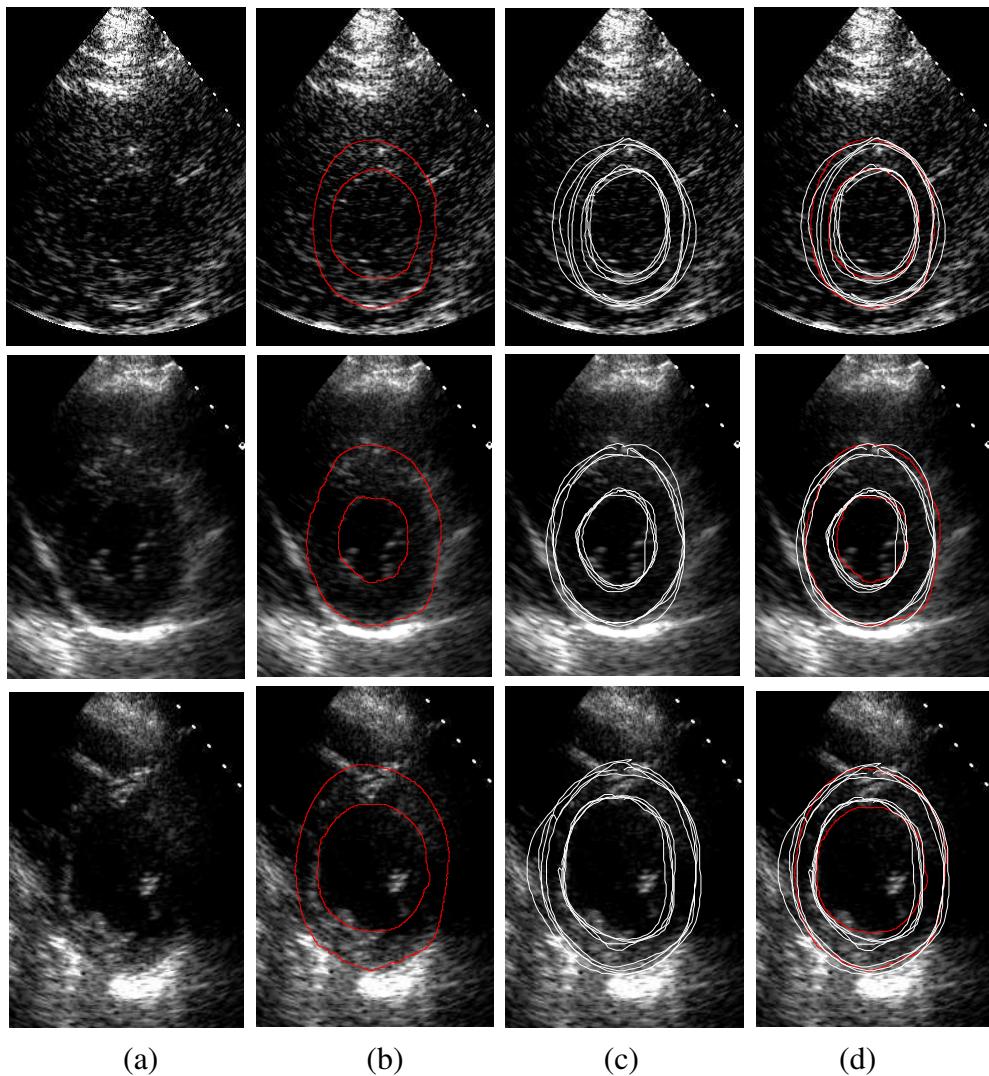
Endokardiyum uzaklıkları					Epikardiyum uzaklıkları					Ekolarda [Bresson et al., 2006]	Skorlarda [Bresson et al., 2006]	
	Uzman 2	Uzman 3	Uzman 4	Sistem	Uzman 2	Uzman 3	Uzman 4	Sistem				
Uzman 1	3.46 \pm 1.08	3.10 \pm 0.86	4.36 \pm 1.64	3.54 \pm 0.69	3.36 \pm 0.89	3.29 \pm 0.73	6.72 \pm 2.64	4.69 \pm 0.92	6.66 \pm 2.03	4.68 \pm 1.57		
Uzman 2		3.23 \pm 1.06	4.23 \pm 1.44	3.99 \pm 1.00		3.37 \pm 1.05	6.64 \pm 2.86	5.02 \pm 1.27	7.00 \pm 1.72	5.11 \pm 1.60		
Uzman 3			4.17 \pm 1.65	4.16 \pm 0.72			6.63 \pm 2.80	4.52 \pm 1.01	6.67 \pm 1.72	4.73 \pm 1.41		
Uzman 4				4.59 \pm 1.32				5.10 \pm 1.64	7.01 \pm 1.92	6.46 \pm 2.11		

3.4.2. Sentetik İmgeler

Geliştirilen kontur bulma sistemi, lokal ve global önsel bilgiyi beraber kullanarak kalp duvarlarını bulmaktadır. Çizelge 3.1, lokal ve global önsel bilginin beraber kullanılması ile gerçek veri üzerinde sayısal sonuçları göstermektedir. Bölüm 2'de kullanılan global önsel bilginin etkinliği gösterilmiştir. Lokal önsel bilginin tek başına ne kadar etkili olduğu ve global bilgiye ihtiyaç duyup duymadığını göstermek için sentetik imgeler oluşturularak çeşitli deneyler yapılmıştır. Bu deneylerle ayrıca D , E ve F filtre kümelerinin etkileri de araştırılmıştır.

Gauss gürültüsü, tuz ve biber gürültüsü ve benek gürültüsü farklı miktarlarda eklenderek birçok sentetik imgé dizisi oluşturulmuştur. İmgeler 100x100 piksel boyutundadır ve 50 gri düzey kontrasta sahiptir. Sentetik imgeler içinde halka gibi bir nesne barındırmaktadır ve bu nesne sol karıncık gibi imgé dizisi boyunca büyüp küçülmektedir. Deneyin daha gerçekçi olmasını sağlamak amacıyla, sol karıncığın büyümeye ve küçülme hızları sabit tutulmayıp rasgele belirlenmiştir.

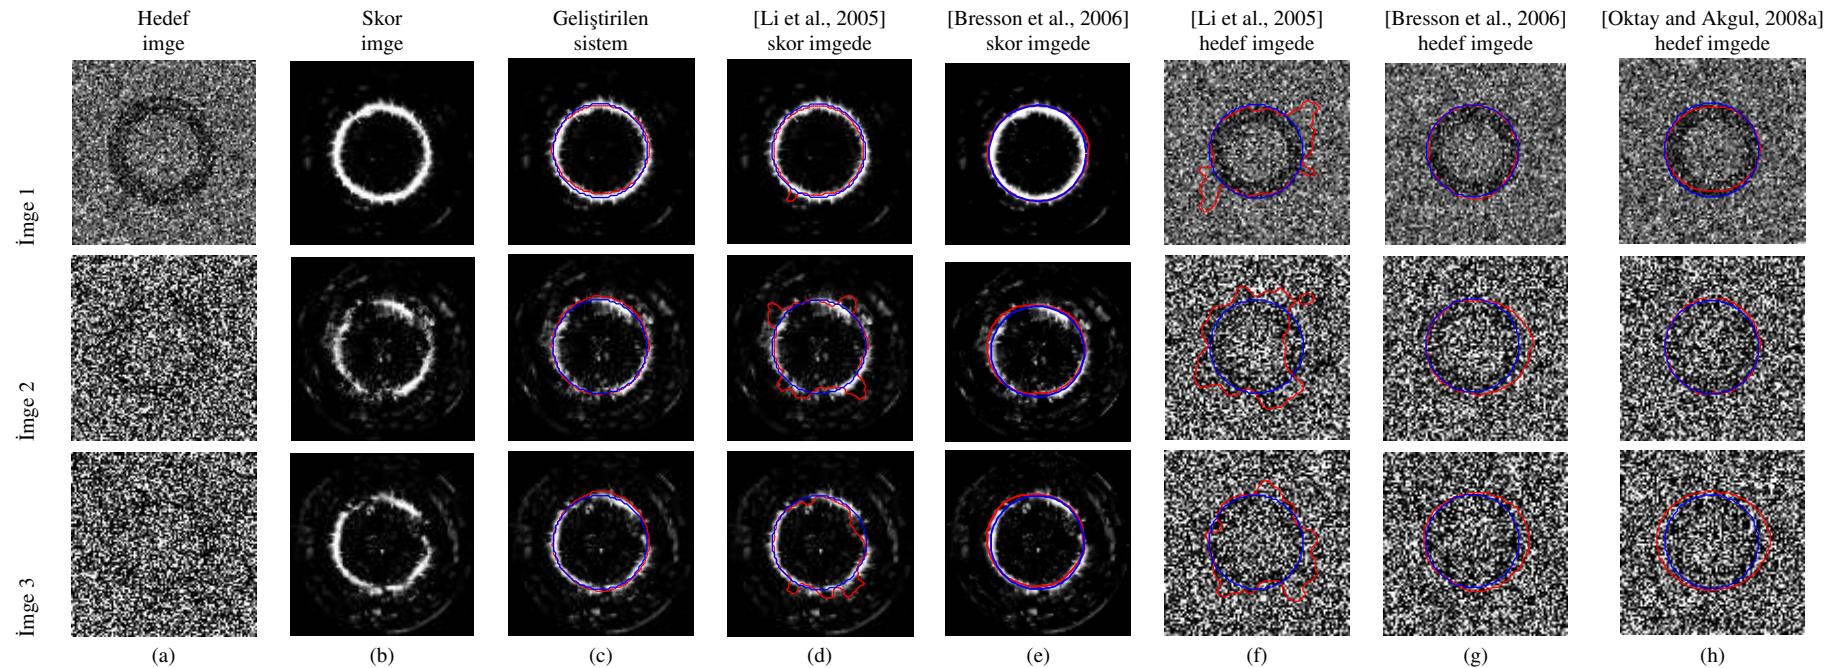
Eğitim için 15 farklı sentetik imgé dizisi kullanılmıştır ve bu imgelerdeki gürültü seviyeleri Çizelge 3.2'te gösterilmiştir. Test için ve skor verme işleminin etkinliğini göstermek için ise farklı gürültü seviyeleri ile 3 sentetik imgé üretilmiştir (Çizelge 3.2). Şekil 3.8(a)'da, 3 test dizisinden örnek çerçeveler gösterilmiştir. Geliştirilen sistemle, halkanın dış konturu için skor verme işlemi yapılmıştır ve Şekil 3.8(b)'de skor imgeleri gösterilmiştir. Skor imgelerinde açık parlaklığa sahip olan pikseller yüksek skor değerlerini (kontur pozisyonu olma durumunu), koyu parlaklığa sahip olan pikseller ise düşük skor değerlerini (kontur pozisyonu olmama durumu) ifade etmektedir. Verilen bir pikseli kontur ya da kontur değil olarak sınıflandıracak standart bir sınıflayıcı oluşturmak için, skor imgelerine (Denklem 3.3 sonuçlarına) eşik uygulanmıştır. Eşik değerini $-\infty$ 'dan ∞ 'a değiştirerek ROC eğrileri oluşturulmuştur ve bu eğriler Şekil 3.9'ta gösterilmiştir. Beklendiği üzere, en az gürültülü imgede en yüksek sınıflandırma değerine ulaşılırken, en çok gürültülü imgede en düşük sınıflandırma değerine ulaşmıştır. Skor imgeleri ve ROC eğrileri incelendiği zaman, nesnelerin sınırlarının yüksek gürültü değerlerinde bile bulunabildiği anlaşılmaktadır.



Şekil 3.7: (a) Üç örnek ekokardiyografik imgé; (b) sistem tarafından epikardiyum ve endokardiyum için otomatik olarak üretilen konturlar; (c) 4 farklı uzman tarafından çizilen konturlar; (d) beyaz konturlar uzman konturları, kırmızı konturlar ise otomatik üretilen sistem konturlarıdır.

Çizelge 3.2: Şekil 3.8'deki sentetik imgé dizilerinin gürültü seviyeleri.

Gürültü çeşidi	Eğitim dizileri (Gürültü aralığı)	Test Dizisi 1	Test Dizisi 2	Test Dizisi 3
Gauss (σ^2)	0.005-0.25	0.04	0.17	0.2
Tuz ve biber (%)	0.5-25	4	17	20
Benek gürültüsü (σ^2)	0.005-0.25	0.04	0.17	0.2



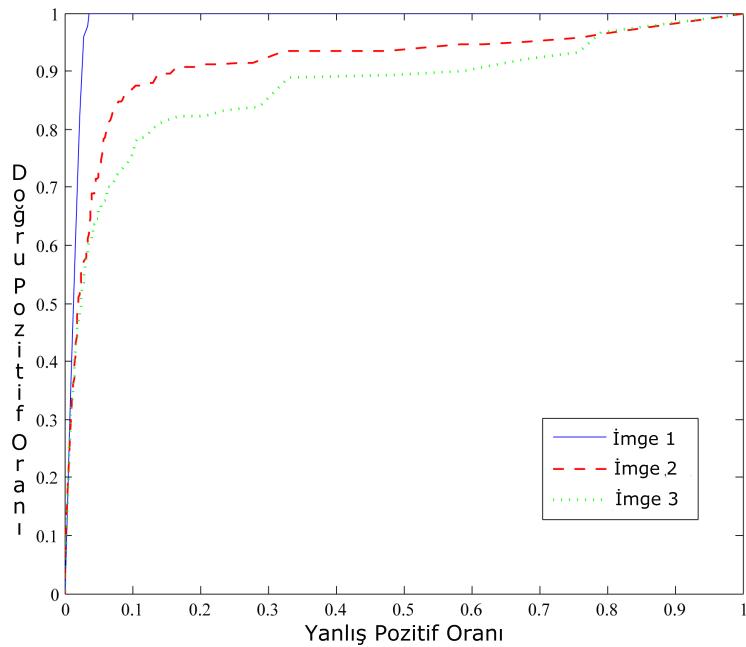
Şekil 3.8: (a) Çizelge 3.2'te verilen seviyelerde gürültü eklenmiş imgeler ve (b) onların skor imgeleri. (c) geliştirilen sistemin, (d) [Li et al., 2005] metodunun ve (e) [Bresson et al., 2006] metodunun skor imgeleri üzerinde çalıştırılması ile oluşan konturlar. (f) [Li et al., 2005] metodunun, (g) [Bresson et al., 2006] metodunun ve (h) sadece global şekil bilgisi ekleyen [Oktay and Akgul, 2008a] metodunun hedef imgeleri üzerinde çalıştırılması ile oluşan sonuçlar. Kırmızı renkli konturlar otomatik olarak bulunan konturları, mavi konturlar da hedef nesnenin gerçek konturlarını göstermektedir. Çizelge 3.3'te gösterilen kontur bulma sonuçlarının sayısal değerleri verilmiştir.

Skor imgeleri ROC eğrileri ile değerlendirdikten sonra, en son kontur bulma sonuçlarını üretmek üzere geliştirilen sistem skor imgeleri üzerinde çalıştırılmıştır (Şekil 3.8(c) ve Çizelge 3.3-A). Global değişkenin son sonuçlara olan katkısını göstermek amacıyla, popüler bir düzeykümesi metodu olan ve imge gradyanı dışında bir bilgi içermeyen Li ve diğerlerinin metodu [Li et al., 2005] , skor imgeler üzerinde çalıştırılmıştır. Bu metot hiç global bilgi olmadan sadece lokal bilgi ile çalışmaktadır ve sonuçları Şekil 3.8(d) ve Çizelge 3.3-B'de gösterilmiştir. Lokal önsel bilgi yalnız başına, gürültülü imgelerde tüm kontur bilgisini çıkartamadığı için global bilgi içermeyen düzeykümesi metodu, halkanın dış sınırlarını lokal ve global bilgiyi beraber kullanan metot kadar iyi bulamamıştır.

Geliştirilen metodu, literatürden başka bir metotla karşılaştırmak için aynı sentetik imgelerle 4 farklı deney gerçekleştirilmiştir. İlk olarak Bresson ve diğerlerinin [Bresson et al., 2006] şekil, sınır ve alan bilgisini kullanıp global şekil bilgisi ekleyen metodu skor imgeleri üzerinde çalıştırılmıştır. [Bresson et al., 2006]'ın şekil modelini oluşturmak için 10 tane farklı yönelimlerde ve en-boy oranlarında elips oluşturulmuştur. Sonuçlar Şekil 3.8(e) ve Çizelge 3.3-C'de gösterilmiştir.

Daha sonra, düzeykümesi metodu [Li et al., 2005] metodu hiçbir değişiklik olmadan hedef sentetik imgeler üzerinde çalıştırılmıştır (Şekil 3.8(f) ve Çizelge 3.3-D). Ayrıca, global şekil bilgisi ekleme metodu [Bresson et al., 2006], hedef sentetik imgeler üzerinde çalıştırılmıştır (Şekil 8(g) ve Çizelge 3.3-E). En son olarak, sadece global şekil bilgisi ekleme metodu [Oktay and Akgul, 2008a] hedef sentetik imgeler üzerinde çalıştırılmıştır. [Oktay and Akgul, 2008a] metodundaki global önsel bilgi için [Bresson et al., 2006] metodunda kullanılan elipsler kullanılmıştır.

Uygulanan metodlar görsel ve sayısal olarak karşılaştırıldığında, geliştirilen metodun diğer metodlardan daha iyi sonuçlar verdiği gözlemlenmektedir. Bu iyi sonuçların iki temel unsurdan kaynaklandığı düşünülmektedir. İlk olarak, sistemin aynı çatı altında lokal ve global önsel bilgiyi beraber kullanmasıdır. İkinci olarak, zamanla ilgili olan ve imge ile ilgili olmayan başka bilgiler de öznitelik çıkarmada elde edilmekte ve varyasyonel düzeykümesi çatısını terk etmeden bu bilgiler kontur bulma işlemine dahil edilmektedir. Böylelikle sistem daha karmaşık hale gelmeden, önemli ölçüde bilgi ile kontur bulma gerçeklenmektedir.



Şekil 3.9: Şekil 3.8(a)'daki sentetik imgelerin, eşik değerinin $-\infty$ 'dan ∞ 'a değiştirilmesi ile oluşan ROC eğrileri.

Bir başka konu da, lokal bilginin mi global bilginin mi kontur bulma işleminde daha önemli olduğunu. Fakat Çizelge 3.3 kolon A, B ve F'ye bakılarak hangisinin daha önemli olduğunu söylemek mümkün değildir. Sadece lokal ve global bilginin önemini, eldeki imge bilgisine bağlı olarak değiştiği söylenebilir ve bir genelleme yapılamaz.

Çizelge 3.3: Şekil 3.8'deki bulunan konturlar ve gerçek kontur arasındaki sayısal piksel farkları.

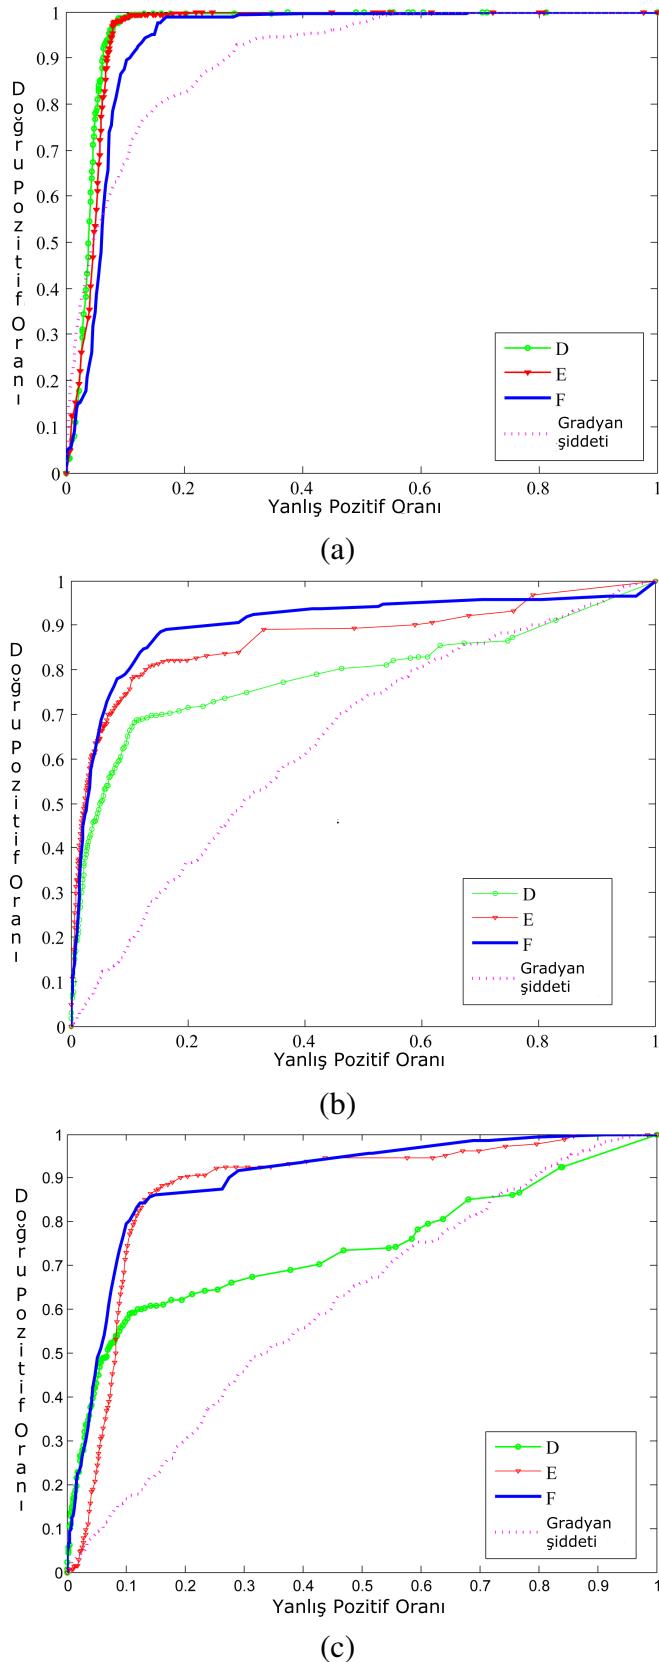
	A	B	C	D	E	F
İmge	Geliştirilen sistem	[Li et al., 2005]	[Bresson et al., 2006]	[Li et al., 2005]	[Bresson et al., 2006]	global önsel [Oktay and Akgul, 2008a]
İmge 1	0.85	1.03	0.72	2.81	0.87	0.98
İmge 2	0.95	1.74	0.84	4.22	1.66	1.23
İmge 3	0.86	1.65	0.85	4.03	1.48	1.73

Bir başka deney de özelliklerin D , E ve F kümelerindeki filtrelerle ayrı ayrı çıkartılıp eğitilmesi ve skor değeri verilmesi ile yapılmıştır. Şekil 3.8(a)'daki 3 imgenin öznitelikleri bu 3 tip filtre ile ayrı ayrı çıkartılmış, eğitilmiş ve skorlandırılmıştır. Şekil 3.10(a), (b) ve (c)'de bu işlem sonucu oluşan ROC eğrileri gösterilmiştir. 3 boyutlu zaman-uzamsal E ve F filtrelerin performansının 2 boyutlu uzamsal D filtresinden daha iyi olduğu gözlemlenmektedir. Bu deney, ekokardiyogramlarda zaman-uzamsal filtrelerle birden çok kare kullanarak daha iyi skor değerlerinin üretildiğini göstermektedir.

Klasik düzey kümesi metodu, dış enerji teriminde sadece imge gradyan şiddetini kullanmaktadır. Fakat, bizim sistemimiz düzey kümesinin dış enerji fonksiyonunda skor verme işlemi sonucu oluşan değerleri kullanmaktadır. Sistemle, klasik düzey kümesi fonksiyonunun dış enerji terimini karşılaştırmak amacıyla bir deney yapılmıştır. Deneyde, imge gradyan şiddetine eşik uygulanarak bir sınıflayıcı oluşturulmuştur. Eşik değerinden yüksek olan pikseller kontur pikseli, altında olanlar da arka plan olarak sınıflandırılmışlardır. Eşik değerini 0'dan ∞ 'a değiştirerek bir ROC eğrisi üretilmiştir. Sınıflayıcının daha başarılı sonuç üretmesi amacıyla Gauss düzleştirme manüel olarak yapılmıştır. Şekil 3.10 bu şekilde oluşturulan ROC eğrisini ve sistemin oluşturduğu ROC eğrisini göstermektedir. Şekil açıkça, otomatik sistemin imge gradyan şiddetinden daha başarılı olduğunu göstermektedir. Bunun nedeni de, kullandığı lokal ve global önselin gradyan şiddetinden daha fazla bilgi içermesi ve 3 boyutlu filtrelerle hareket bilgisinin sisteme dahil edilmesidir.

3.5. Yorumlar

Bu bölümde, ekokardiyografik imgelerden önsel bilgi ile yeni bir kontur çıkarma sistemi sunulmuştur. Önsel bilgiyi daha sistematik bir biçimde kontur bulma işlemeye eklemek için, lokal ve global önsel bilgi ayrı ayrı ele alınmıştır. Global bilgi tüm imgeyi kapsayan ve nesnenin tümüyle alakalı olan bilgi olarak tanımlanmıştır. Sistemde global bilginin eklenmesi, bir önceki bölümde anlatılan en benzeyen uzman konturu imge üzerinde yeniden ilklendirme felsefesine dayanmaktadır. Sistemde sadece nesnenin şekli global bilgi olarak kullanılmış olsa da, farklı global bilgiler de



Şekil 3.10: Şekil 3.8'teki 3 imgeye filtre kümeleri D , E ve F 'nin ayrı ayrı uygulanması ile elde edilen ROC eğrisi.

(tahmin edilen alan büyüklüğü, konturun uzunluğu, gerekli özelliklerin sayısı gibi) sisteme dahil edilebilir.

Lokal imge bilgisi ve hareket bilgisi Haar tipi filtrelerle çıkartılmış ve Adaboost ile öğrenilip, skorlandırılmıştır. Sol karıncık merkezine uzaklık gibi imgeye bağlı olmayan diğer lokal bilgiler de sistemde kullanılmıştır. Farklı tipteki lokal bilgiler, tek makine öğrenmesi çatısı altında kolaylıkla eğitilmiştir. Böylece, imge, hareket ve diğer lokal bilgiler karmaşık bir model oluşturmadan sistem tarafından elde edilmiştir.

Sentetik ve gerçek imgeler üzerinde yapılan deneylerle, sistemin kalp konturlarını bulduğu ve bulunan konturların uzman konturlarından ayırt edilemediği gözlemlenmiştir. Sistem, başka tıbbi imgelere de gerekli lokal ve global özniteliklerin bulunması ile uygulanabilir.

4. LOMBER OMURLAR ARASINDAKİ DİSKLERİN OTOMATİK OLARAK SAPTANMASI VE KONUMLANDIRILMASI

4.1. Giriş

Omurga insan bedeninin temel eksenidir ve gövdenin ağırlığını taşımakla ve omuriliği korumakla görevlidir. Omurga genellikle 4 farklı eğri olarak sınıflandırılmaktadır: Boyun (servikal) eğrisi, sırt (torakal) eğrisi, lomber (bel) eğrisi ve sakral eğridir. Boyun, sırt ve lomber eğride birbirine ekimlerle bağlanmış toplam 24 tane omur bulunmaktadır. Sakral eğri ise, birbirine kaynaşmış 9 omurdan oluşmaktadır. MR ve BT görüntüleme kipleri genellikle omurgayı görüntülemekte ve hastalıkların teşhisinde kullanılmaktadır. MR ve BT imgelerinden omorganın ve omurların otomatik olarak saptanması son 10 yılda fazlasıyla önem kazanmıştır. Mesela, Peng ve diğerleri [Z. Peng and Lee, 2005] parlaklık profil bilgisini kullanarak 24 omuru konumlandırmışlardır. Carballido-Gamio ve diğerleri [Carballido-gamio et al., 2004] normalize edilmiş kesme metodu ile omurgayı konumlandırmış ve omorganın bölümlerini böülütmüşlerdir. Seifert ve diğerleri [Seifert et al., 2009] bilgi tabanlı bir yaklaşımla MR imgelerinde omurgayı yeniden çakmışlardır.

Omurgadaki omurlar, intervertebral diskler tarafından ayrılmışlardır. Bu diskler, omurgadaki omurları bir arada tutar ve omorganın hareket etmesini sağlar. Lomber eğri, birbirine bağlı 5 omurdan oluşmaktadır ve diğer bölgelerden biraz daha fazla önem arz etmektedir. Bel ağrısı en sık karşılaşılan ağrı türüdür ve genellikle lomber eğrideki disk ve omurlardan kaynaklanmaktadır [Giles and Singer, 2007]. Klinik tıbbi uygulamalarda, bel fitiği olarak adlandırılan, lomber omurlar arasındaki disklerin anormal deformasyona uğraması ve disklerin taşması tanısı, MR imgelerinde disklerin konumlandırılmasının ardından teşhis edilmektedir. Sonuç olarak, MR imgelerinden otomatik lomber eğri analizi metotları, lomber omurları arasındaki disklerin konumlandırılması ve etiketlenmesine dayanmaktadır (Şekil 4.1). Mesela, Zheng ve diğerleri [Zheng et al., 2004] floroskopik BT imgelerinden Hough dönüşümü ile lomber omur arasındaki diskleri konumlandırmışlardır. Lomber omurlar arasındaki disklerin benzerliği ve Hough dönüşümünün doğası gereği, sistemleri

yaklaşık disk pozisyonları için insan görmesine ihtiyaç duymaktadır. [Schmidt et al., 2007] omurgadaki disklerin lokasyonlarını belirleyen bir istatistiksel çıkarım metodu sunmuştur. Önerdikleri metot, disk görünüşlerini öznitelik olarak alan ağaç sınıflayıcısı [Lepetit and Fua, 2006] uygulayarak parça tabanlı model kullanmaktadır. Ağaç sınıflayıcısı birçok yerel ölçek ve döndürme değişimleri kullanarak eğitilmiştir. Grafiksel bir çerçeve altında diskler arasındaki ilişkiler sağlanmıştır. İstatistiksel çıkarım algoritması, bulușsal olan ve üstel arama uzayını verimli bir şekilde azaltan budamaya dayalı bir A* araması gerçekleştirmiştir.

[Schmidt et al., 2007]'in çalışmasına benzer olarak, Alomari ve diğerleri [Alomari et al., 2010] lomber omurlar arasındaki diskleri konumlandırmak için grafiksel bir model kullanmışlardır. Modelleri gizli değişkenler kullanarak lokal ve global düzey olarak iki seviyede tasarlanmıştır. Global seviyedeki gizli değişkenler, disk pozisyonlarının birbirlerine bağımlılıklarını sağlar. Lokal gizli değişkenler ise disk değişkenlerini imge parlaklık değerlerinden ayıran bir soyutlama seviyesi olarak kullanılmıştır. Bu modelden yapılan çıkarım apacak çözüm değildir çünkü yaklaşık çözüm veren ve döngülü çıkarım tekniği olan bekleneni enbüütmesi kullanılmıştır. Çıkarımın nihai sonuca ulaşıp disk pozisyonlarını bulabilmesi için, [Alomari et al., 2010] imgedeki beklenilen disk pozisyonları üzerinde ilklendirme yapmıştır. Ancak, gözlemlendiği kadarıyla disk pozisyonları görüntüleme durumları, görüntüleme kiplerinin farklı olması, hasta pozisyonu ve disk rahatsızlıklarından dolayı hastadan hastaya büyük ölçüde değişmektedir.

Bu bölümde, T1-ağırlıklı sagital MR imgelerinden lomber omurları arasındaki disklerin konumlandırılmasını ve etiketlendirilmesini sağlayan biçim değiştirebilir parça tabanlı bir metot sunulmaktadır. Lokal seviyede, metot makine öğrenmesi teknigi olan DVM ve Yönlü Gradyan Histogramı (YGH) teknikleri ile lokal olarak disk pozisyonlarını arar. Global düzeyde, metot omurganın zincire benzer yapısı olmasının avantajını kullanarak grafiksel bir yapı tasarılar. Literatürdeki zincir benzeri grafiksel yapıdan kesin çıkarım metodu ile [Bishop, 2007] nihai disk pozisyonları ve etiketleri bulunur.

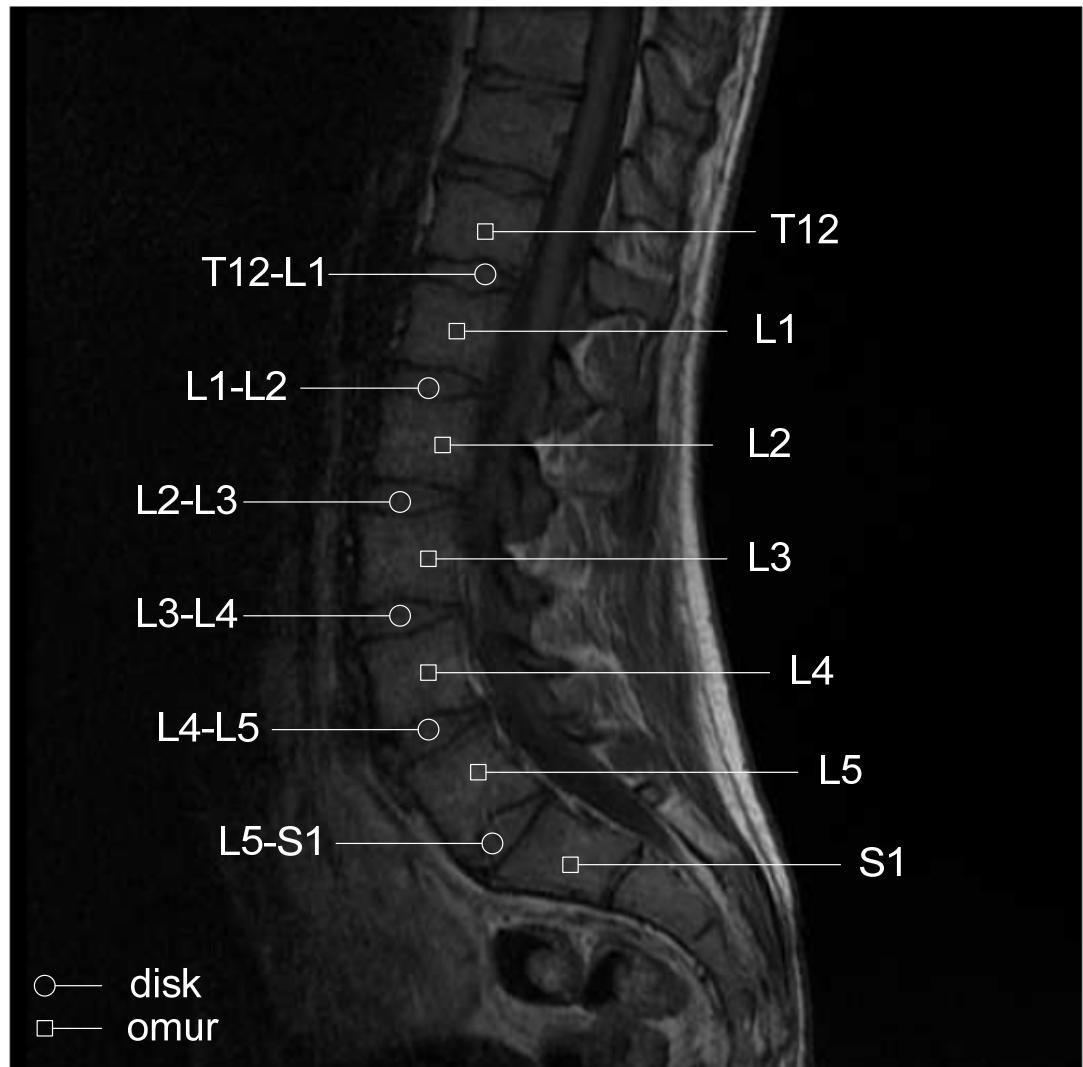
Geliştirilen metot [Alomari et al., 2010] ve [Schmidt et al., 2007] tarafından geliştirilen metotlara bazı benzerlikler göstermektedir. Bu benzerlik, disk pozisyon-

larının saptanması için kullanılan grafiksel modellerden çıkarım yapmaktadır. Lakin, geliştirilen metodun diğerlerinden farklı olarak iki önemli avantajı vardır. İlk avantajı, grafiksel modelde imge parlaklık bilgisini doğrudan kullanılmamasıdır. Bunun yerine YGH tabanlı DVM disk detektörü tarafından bulunan sonuçlar, gözlemlenen veri olarak kullanılmaktadır. Birçok lokal ve yarı-global öznitelikler kolaylıkla ve verimli bir şekilde global düzeydeki çıkarım mekanizmasını karmaşık hale getirmeden modelin disk detektörüne eklenebilir. Mesela, sistemde sadece T1-ağırlıklı imgelerin kullanılmasına rağmen T2-ağırlıklı imgeleri de T1-ağırlıklı imgelerle beraber kullanmak mümkündür. Bu şekilde çalışma zamanı maliyeti çok fazla artmaz çünkü literatürde verimli YGH tabanlı DVM metotları [Dalal and Triggs, 2005] mevcuttur. Deneylerle gösterildiği üzere YGH tabanlı DVM metodu, [Schmidt et al., 2007]'de kullanılan ağaç sınıflayıcısı detektöründen daha fazla imge bilgisi çıkartmaktadır.

Sistemin ikinci temel avantajı, omurganın tek boyutlu yapısını kullanması ve sadece disk pozisyonlarının gizli değişkenler olduğu zincir tipinde bir grafiksel model oluşturmasıdır. Literatürde, polinom zamanlı zincir tipindeki grafiksel modelden çıkarım yapan verimli algoritmalar mevcuttur. Bu çalışmada dinamik programlama ile tek boyutlu zincir tipindeki grafiksel modelden kesin çıkarım yapılmıştır. Ayrıca, zincir tipindeki model sayesinde, sisteme en ucta diskler için ekstra bilgi eklemek mümkün olmaktadır. Sonuç olarak, grafiksel modelin etkinliği sayesinde imgeye bağlı uzamsal bir tahmin yapmaya ihtiyaç duyulmamaktadır. Sistemin bu avantajları, sistemin gerçek MR imgeleri üzerinde ürettiği sonuçlarla doğrulanmıştır. Sistem, literatürde var olan diğer lomber disk bulma ve konumlama metodlarından daha başarılıdır.

4.2. Disklere Skor Verme İşlemi

Geliştirilen sistem birkaç aşamadan oluşmaktadır ve Şekil 4.2'de bu aşamalar gösterilmiştir. Sistemdeki ilk aşama, MR imgesindeki aday disk pozisyonlarına skor verme işlemidir. Literatürdeki lokal disk bulma metotları rasgele sınıflandırma ağaçları ile imge gradyan şiddeti bilgisini [Schmidt et al., 2007], disklerin uzamsal lokasyonlarını ve parlaklıklarını [Alomari et al., 2010; Corso et al., 2008] ve genel Hough dönüşümünü [Seifert et al., 2009] kullanmaktadır. Lakin, bu lokal metotlar lomber omurlar arası disklerin saptanmasında zorluk yaşamaktadır, çünkü lomber



Şekil 4.1: Örnek bir sagital görünüşlü T1-ağırlıklı lomber omurları ve diskleri gösteren MR imgesi. L1, L2, L3, L4 ve L5 lomber omurlarıdır. S1 sakral eğrinin ilk omuru ve T12 de torakal eğrinin son omurudur. L1 ve L2 arasındaki disk L1-L2 olarak etiketlenmiştir.

diskler boyut, konum, şekil ve görünüş olarak hastalıklar yüzünden ve şahsa ait nedenlerle çok fazla değişiklik göstermektedir. Bu çalışmada, disklerin imgelerdeki en değişmez özellikleri parlaklık, şekil ve görünüş değil de, kenar ve kenarların yönelimi olarak gözlemlenmiştir. Bu yüzden, öznitelik çıkartılması YGH tanımlayıcıları ile yapılmış ve disk ve omurga anormalliklerine karşı dayanıklılık sağlanmıştır. YGH tabanlı nesne detektörleri hesaplamaşal verimliliği ve nesne deformasyonuna karşı duyarsız olması nedeniyle sıkça kullanılmaktadır [Dalal and Triggs, 2005].

4.2.1. YGH ile Öznitelik Çıkarımı

YGH ile öznitelik çıkarmada, bir nesne gradyan yönelimlerinin belirli bir sayıda seleye nicelenmesi ile histogram oluşturulur. Her sele, o seleye karşılık gelen açı aralığındaki kenarların sayısını göstermektedir. Piramidal Yönlü Gradyan Histogramı (PYGH) tanımlayıcı tekniği, [Dalal and Triggs, 2005]'teki lokal imge şeklini ve uzamsal piramit çekirdeği metodunu birleştirmektedir [Lazebnik et al., 2006]. Uzamsal piramit bilgisi, imgeyi çok sayıda dörtlü ağaç gibi uzamsal ızgara dizisine bölgerek eklenir. Her ekleme işleminde, piramitte yeni bir düzey oluşturulur. Mesela, ilk düzey imgenin kendisidir. İkinci düzeyde, imge 4 eşit parçaya bölünür. Üçüncü düzeyde, 4 eşit parçadan her biri yine 4 eşit parçaya bölünür ve böylece toplam 16 parça oluşur. Her parça için, YGH hesaplanır ve en son PYGH tanımlayıcısı bu YGH tanımlayıcılarının yan yana getirilmiş halidir.

Disk özniteliklerini çıkarmak için, PYGH metodunun değiştirilmiş hali kullanılmıştır. Disk konturlarının üst kısımları belirginken, sağ ve sol (yan) taraflarda hastalıklardan kaynaklanan açık olmama veya dejener olmadan dolayı belirginliğin azalması durumu olabilir. Bu da PYGH tanımlayıcısında kenarların yönelimlerinin yanlış gösterilmesine neden olmaktadır. Bu yüzden, imge dörtlü ağaç gibi uzamsal ızgara dizisine bölünmemiş, bunun yerine üst ve alt parça olmak üzere iki parçaya (ikili ağaç gibi) bölünmüştür. Böylece, diskler hakkında yanlış bilgiler histograma daha az katılmış ve PYGH tanımlayıcısı daha bilgilendirici olmuştur. PYGH tanımlayıcısı, bütün bu parçaları tanımlayan YGH tanımlayıcılarının birleşimidir.

Değiştirilmiş PYGH tanımlayıcılarını, orijinal imgelerde (512x512 boyutunda)

çıkarmanın hesaplamasal maliyeti yüksektir. Bu yüzden integral histogram teknigi ile [Porikli, 2005] PYGH tanımlayıcısı çıkarma işlemi hızlandırılmıştır. İlk olarak, her sele için, toplam imge gibi bir integral sele histogramı oluşturulmuştur. Bir penceredeki PYGH histogramı, o pencerenin denk düşüğü tüm selelere bakılarak oluşturulmaktadır ve hesaplamasal maliyeti gayet düşüktür.

PYGH ile öznitelik çıkarımı yapılrken, ilk olarak kenarlar Canny kenar detektörü ile bulunur. Daha sonra, her sele için toplam histogram imgesi oluşturulur. Kayan pencere teknigi ile, her pencere için değiştirilmiş PYGH tanımlayıcısı hesaplanır. Belirli bir sayıdan daha az kenara sahip pencereler için, PYGH tanımlayıcısı hesaplanmaz ve pencere disk ihtiva etmiyor olarak değerlendirilir.

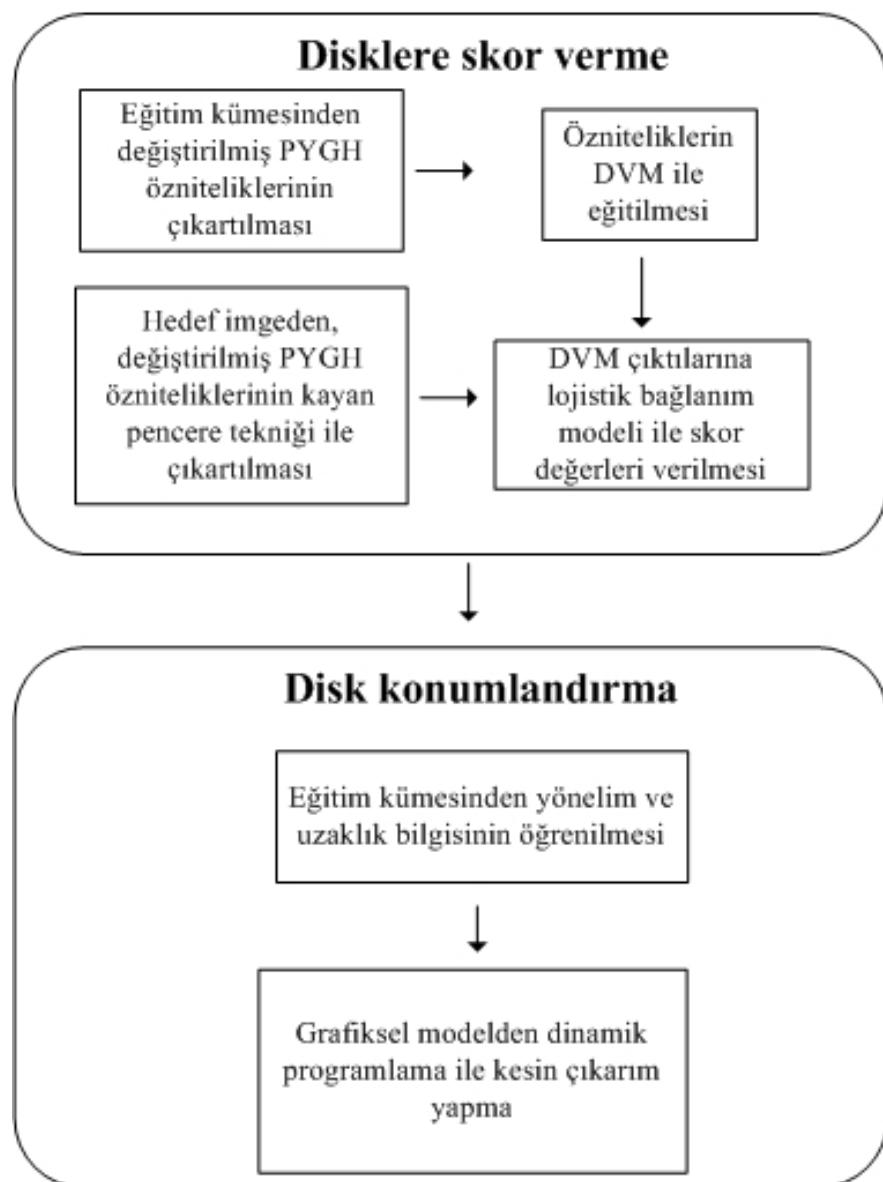
4.2.2. DVM ile Eğitilme ve Skor Verme İşlemi

Değiştirilmiş PYGH tanımlayıcısı ile özniteliklerin çıkartılmasının ardından DVM ile bu öznitelikler eğitilirler. Eğitim için, doğrusal DVM'den daha hızlı olan ardışık en küçük eniyileme [Platt, 1999a] tekniği kullanılmıştır.

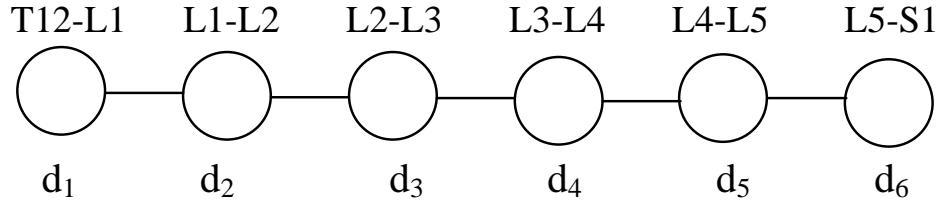
Skor verme işlemi, kayan pencere yaklaşımı ile kotarılmıştır. Pencerenin ortasındaki imgeciğe, disk merkezi olup olmadığını (pencerenin disk içeriip, içermemiğini) gösteren bir skor değeri atanmıştır. Skor değerleri, DVM'nin çıktılarına lojistik bağlanım modeli yerleştirilmesi ile [Platt, 1999b] oluşturulmuştur.

$d = \{d_1, d_2 \dots, d_6\}$ kümesinin, lomber eğri arasındaki diskler (T12-L1, L1-L2, L2-L3, L3-L4, L4-L5 ve L5-S1) olduğunu varsayılm. Her disk d_i , diğerlerinden ayrı olarak eğitilmiş ve skorlandırılmıştır. Bu yüzden, verilen bir I imgesi için, her bir imgeciğe 6 farklı skor değeri atanmaktadır. Daha sonraki işlemler için, 0.5'ten daha küçük olan skor değerleri elenmiştir.

$p_{d_s}(l_k)$ değeri, l_k konumundaki imgeciğe d_s disk için atanmış DVM tarafından üretilen bir skor değeri olsun. d_i disk için, atanmış bu skorlar, $1 < i < 6$ ve m imgedeki piksel sayısını göstermek üzere $p^i = \{p_{d_i}(l_1), p_{d_i}(l_2) \dots, p_{d_i}(l_m)\}$ olarak tanımlanmıştır.



Şekil 4.2: Disklere skor verme ve etiketlendirme işleminin akış diyagramı.



Şekil 4.3: Oluşturulan zincir benzeri grafiksel model.

4.3. Disk Merkezlerinin Konumlandırılması

Son işlem olarak disk merkezlerinin konumlandırılması için, olasılıksal bir grafiksel model önerilmiştir. Disklerin lokal öznitelikleri, PYGH ve DVM ile belirlenmiştir, fakat bu lokal özellikler tek başına lomber eğriderdeki disklerin birbirinden ayırt edilmesi için yeterli değildir. Çünkü birbirine komşu diskler birbirleriyle benzer lokal özellikler taşımaktadır. Bu yüzden en son disklerin konumlandırılması için, diskler arasındaki konumsal ve yönelimsel farklar gibi global bilgiye ihtiyaç duyulmaktadır. Dolayısıyla, bu tipteki global bilgiyi, skor verme işleminden gelen lokal bilgi ile birleştiren zincir benzeri grafiksel model kullanılmıştır.

4.3.1. Grafiksel Zincir Benzeri Model

Oluşturulan grafiksel model, her düğümün bir diski temsil ettiği 6 düğüm ve 5 ayrı içermektedir (Şekil 4.3). $x_k \in \mathbb{R}^2$, k düğümünü onun imge konumuna atayan bir rasgele değişken olsun. $x' = \{x_1, x_2, \dots, x_6\}$ 'in en iyi düzenlenisi, tüm $d = \{d_1, d_2, \dots, d_6\}$ disklerini kendi kesin konumlarına atar.

Sistemdeki temel hedef, maximum a posteriori (MAP) tahmini ile disk merkezlerinin en iyi konumlarının belirlenmesidir:

$$x' = \arg \max_x P(x|p, \alpha), \quad (4.1)$$

α eğitim kümesinden öğrenilmiş olan parametreyi ve $p = \{p^1, \dots, p^6\}$ de atanmış olan skor değerlerini tanımlamaktadır. $P(x|p, \alpha)$ disk olma ihtimalini ve komşu disklerle olan ilişkisiyi ifade etmektedir. $P(x|p, \alpha)$ 'nın Gibbs dağılımı şu şekildedir:

$$P(x|p, \alpha) = \frac{1}{Z} \exp \left\{ - \left[\sum \psi_L(I, x_k) + \lambda \sum \psi_G(x_k, x_{k+1}, \alpha) \right] \right\}. \quad (4.2)$$

Bu denklemde potansiyel fonksiyon $\psi_L(I, x_k)$ diskler hakkında lokal bilgi taşımakta ve potansiyel fonksiyon $\psi_G(x_k, x_{k+1}, \alpha)$ da uzaklık ve yönelim gibi global bilgi taşımaktadır. Ayrıca, λ ağırlığı belirleyen bir parametredir.

Lokal potansiyel fonksiyon $\psi_L(I, x_k)$ 'de, DVM çıktılarına lojistik bağlanım modeli yerleştirilmesi ile oluşan skor değerleri doğrudan kullanılmıştır.

Global potansiyel fonksiyonu $\psi_G(x_k, x_{k+1}, \alpha)$ şu şekilde tanımlanmıştır:

$$\psi_G(x_k, x_{k+1}, \alpha) = U(x_k, x_{k+1}, \alpha)R(x_k, x_{k+1}\alpha), \quad (4.3)$$

U ve R komşu disk değişkenleri x_k ve x_{k+1} arasındaki konumsal ve yönelimsel farkları içermektedir.

$y^i = \{y_1, y_2, \dots, y_t\}$, eğitim kümesindeki disk değişkenleri x_i ve x_{i+1} arasındaki Öklid uzaklıklar olsun. t de eğitim kümesindeki örnek sayısı olarak tanımlansın. Uzaklık fonksiyonu $U(x_k, x_{k+1}, \alpha)$ şöyle tanımlanmıştır:

$$U(x_k, x_{k+1}, \alpha) = \begin{cases} \frac{E - \mu(y^k)}{w}, & \text{eğer } E \in [\min(y^k) - \sigma, \\ & \quad \max(y^k) + \sigma], \\ \infty, & \text{diğer,} \end{cases} \quad (4.4)$$

$\mu(y^k)$ eğitim kümesinden hesaplanan ortalama y^k , $w = \max(y^k) - \min(y^k)$, σ bir eşik değeri ve E de disk değişkenleri x_k ve x_{k+1} arasındaki Öklid uzaklıktır.

Diskler arasındaki açısal farklar, omurganın bel bölgesinin eğriye benzer şeklini oluşturur. Bu eğriye benzer bilgiyi elde etmek için, bel diskleri arasındaki açı bilgisi kullanılmıştır. $r^i = \{r_1, r_2, \dots, r_t\}$, eğitim kümesinden öğrenilen komşu disk değişkenleri x_i and x_{i+1} arasındaki açılar olsun. Yönelim terimi $R(x_k, x_{k+1}, \alpha)$ aşağıda ifade edildiği gibidir:

$$R(x_k, x_{k+1}, \alpha) = \begin{cases} \frac{O - \mu(r^k)}{f}, & \text{eğer } O \in [\min(r^k) - \sigma, \\ & \quad \max(r^k) + \sigma], \\ \infty, & \text{diğer,} \end{cases} \quad (4.5)$$

O disk değişkenleri x_k ve x_{k+1} arasındaki açı farkları, $\mu(r_k)$ eğitim kümesinden öğrenilmiş ortalama yönelim, σ bir eşik değeri ve $f = \max(r^k) - \min(r^k)$ 'dır.

4.3.2. Zincir Üzerinde Kesin Çıkarım

Verilen bir hedef imgesi I için gaye, Denklem 4.1'i en büyütleyerek en iyi x' düzenlenişini çıkarmaktır. Oluşturulan grafiksel modelde, bir düğüm en fazla komşu iki düşüme bağlıdır.

Disk konumlandırma işlemi için, imgé I 'deki tüm imgecikleri kullanmak yerine sadece aday disk merkezleri kullanılmaktadır. Böylece, en iyi x' için arama uzayı koşullu bağımlılık ve bulunan aday diskler sayesinde küçülmektedir. Bu da bize, global en iyi çözümü dinamik programlama tabanlı özyinelemeli mesaj aktarma [Bishop, 2007] sayesinde çözme olanağı sağlamaktadır.

Hesaplamasal zaman olarak geliştirilen sistemin çıkarım zamanı, A* arama metodu tabanlı çıkarım metodundan [Schmidt et al., 2007] daha iyidir. A* araması, global en iyi çözümü uygun bir sezgisel metot ile bulmasına rağmen, kolay bir şekilde elde edilememektedir. Ayrıca A* arama metodunun performansı oldukça düşüktür. Alternatif bir çıkarım metodu olan beklenen enbüyütmesi daha çabuk çözümü bulabilir, fakat global eniyi çözümü bulamayabilir ve yakınsama problemi yaşıar.

4.4. Deneysel Sonuçlar

Geliştirilen sistem bel omurgası içeren gerçek bir MR veri kümesi üzerinde test edilmiş ve doğrulanmıştır. Bir 3 boyutlu MR hacmi 512x512x12 voksel boyutundadır. Sagital görünüşte, lomber omurlar arasında en az 6 tane disk ve ayrıca sakrum ve sırt omurları arasında sayısı değişen bazı diskler içermektedir. Uç lomber disklerinde konumlandırma sonuçlarını iyileştirmek için, grafiksel model T11-T12 ve S1-S2 diskleri de eklenerek sistem genişletilmiştir. Lakin, amacımız sadece lomber diskleri bulmak olduğu için, bu disklerin konumlandırma sonuçları rapor edilmemiştir.

Veri kümesi 40 farklı kişinin MR volümelerini içermektedir. Veri kümesinde, 4 kişide herhangi bir lomber disk/omur kaynaklı hastalık bulunmazken; diğerlerinde disk dejenerasyonu, fitik ve skolyoz gibi hastalıklar bulunmaktadır. İmgelerde toplam 240 tane lomber disk vardır ve bu disklerin 97 tanesinde hastalık bulunmaktadır.

Disk saptama işlemi, T1-ağırlıklı sagital imgeler üzerinde gerçekleştirilmiştir. Tıbbi uygulamalarda olduğu üzere, hacmin en ortasındaki kesit disk saptama ve etiketlendirme için kullanılmıştır. Disklerin merkez noktaları ve çevre konturları bir uzman tarafından işaretlenmiştir.

4.4.1. Disklere Skor Verme İşlemi Sonuçları

Disklere skor verme işlemi için, 10 taneyi dışında bırak değerlendirmesinin bir alt kümesi gerçekleştirilmiştir. Veri kümesi, rasgele her bir alt kümenin 10 kişinin MR imagesini içерdiği 4 ayrı alt kümeye bölünmüştür. Toplamda 4 alt deney yapılmıştır. Her alt deneyde, toplam 30 imgenin 3 altküme eğitim için kullanılmış ve diğer altküme test edilmiştir. Böylelikle, her imgenin 3 kere eğitim kümesinde, 1 kere de test altkümesinde kullanılmıştır.

PYGH tanımlayıcısı olarak toplamda her disk için 24 öznitelik çıkartılmıştır. Her disk ayrı ayrı eğitilmiş ve skorlandırılmıştır. Eğitim aşamasında, her disk için 90 pozitif örnek ve 900 negatif örnek kullanılmıştır.

Skor verme işlemi için, hedef imgelerden öznitelikler çıkartılmıştır. PYGH tanımlayıcısı için pencere boyutu, eğitim kümesindeki o disk için en büyük ve en küçük disk boyutu arasında değiştirilmiştir. 100 imgecikten daha az sayıda kenar imgeciğine sahip olan pencereler disk içermiyor olarak değerlendirilmiştir.

4 altkümenin, ayrı ayrı sınıflandırılması ile ortaya çıkan ortalama DVM sınıflandırma yüzdeleri Çizelge 4.1'de gösterilmiştir. Normalde, skorlar DVM çıktılarına lojistik bağlanım modeli uydurulması ile bulunmaktadır. Disk sınıflandırma işlemi için, eğer bir pencere 0.5 değerinden daha büyük bir skor değerine sahipse disk içermektedir; daha küçük bir skor değerine sahipse disk içermiyor olarak tanımlanmıştır. Bir sınıflandırmanın doğru sayılabilmesi için, diskin tüm sınırlarının o pencerenin içerisinde olması gerekmektedir. Sınıflandırma yüzdesi, doğru sınıflandırılan pencerelerin sayısının tüm pencere sayısına bölünmesi ile bulunmuştur. En küçük sınıflandırma yüzdesi %93.51'dir ve o da L4-L5 diski içindir. Yanlış sınıflandırılan diskler, genellikle komşu diskle olan benzerlikten kaynaklanmaktadır. Komşu diskler, benzer yönelimlere sahiptir ve hedef diski saptarken komşu diskleri de, yanlış bir

Çizelge 4.1: Geliştirilen sistem ve [Schmidt et al., 2007] için ortalama disk saptama yüzdeleri.

Geliştirilen metot	T12-L1	L1-L2	L2-L3	L3-L4	L4-L5	L5-S1
Altküme 1	98.04	97.20	97.85	98.45	97.06	97.99
Altküme 2	97.44	97.08	97.73	98.17	98.08	98.88
Altküme 3	96.41	96.50	96.71	97.89	96.25	98.58
Altküme 4	97.12	97.57	97.78	98.89	97.93	98.96
Ortalama	97.25	97.09	97.52	98.35	97.33	98.59
[Schmidt et al., 2007]	52	79	65	94	87	44

şekilde etiketlendirmektedir. Komşu disklerin birbiriyile karıştırılması beklenen birşeydir, çünkü disk saptama işlemi tamamen lokal bir işledir.

Rasgele sınıflandırma ağaçları ile bulunmuş disk saptama değerleri [Schmidt et al., 2007] de, Çizelge 4.1'de gösterilmiştir ve ortalama %70.16 değerine sahiptir. Geliştirilen sistemin ortalama sınıflandırma yüzdesi ise %97'dir ve bu sonuç da lokal disk saptama tekniği olarak kullanılan PYGH tanımlayıcısının dayanıklılığını göstermektedir.

4.4.2. Disk Konumlandırma Sonuçları

Geliştirilen grafiksel model ile disk merkezi konumlandırma ve diskleri etiketlendirme metodu, DVM sonuçlarının ürettiği skor değerleri üzerinde çalışmaktadır. Bir önceki bölümde anlatılan eğitim ve test altkümelerinin aynları, disk konumlandırma için de kullanılmıştır.

Sistemin disk konumlandırma performansının değerlendirilmesi için iki farklı metot kullanılmıştır. İlk değerlendirme metodunda, eğer sistem tarafından otomatik olarak disk merkezi, uzman tarafından işaretlenmiş disk konturunun içindeyse konumlandırma doğru olarak tanımlanmıştır. Bu şekilde bulunan değerlendirme sonuçları Çizelge 4.2'de gösterilmiştir. Sistemin ortalama disk konumlandırma yüzdesi %95'tir. Lomber eğrinin ilk ve son omurları (T12-L1 ve L5-S1), diğer disklerden daha düşük konumlandırma yüzdesine sahiptir. Ayrıca, L2-L3 diski tüm imgelerde doğru olarak bulunmuştur. Ortadaki diskler (L2-L3, L3-L4, L4-L5), başlangıç (T12-L1) ve bitiş (L5-S1) disklerinden daha yüksek konumlandırma yüzdelerine sahiptirler çünkü

Çizelge 4.2: Ortalama disk konumlandırma yüzdeleri.

	T12-L1	L1-L2	L2-L3	L3-L4	L4-L5	L5-S1	Ortalama
Altküme 1	100	100	100	100	100	80	96,66
Altküme 2	90	90	100	100	100	80	93,33
Altküme 3	90	100	100	90	90	90	93,33
Altküme 4	90	100	100	100	100	90	96,66
Ortalama	92.5	97.5	100	97.5	97.5	85	95
[Alomari et al., 2010] metodu							90.7

komşu disklerden daha fazla bilgi almaktadır. Ayrıca, veri kümesindeki 4 sağlıklı hastanın tüm diskleri doğru bir şekilde konumlandırılmıştır. Sistemin ortalama %95 olan konumlandırma yüzdesi, literatürdeki Alomari ve diğerleri [Alomari et al., 2010] tarafından bulunan ve %90.7 olan yüzdeden daha yüksektir.

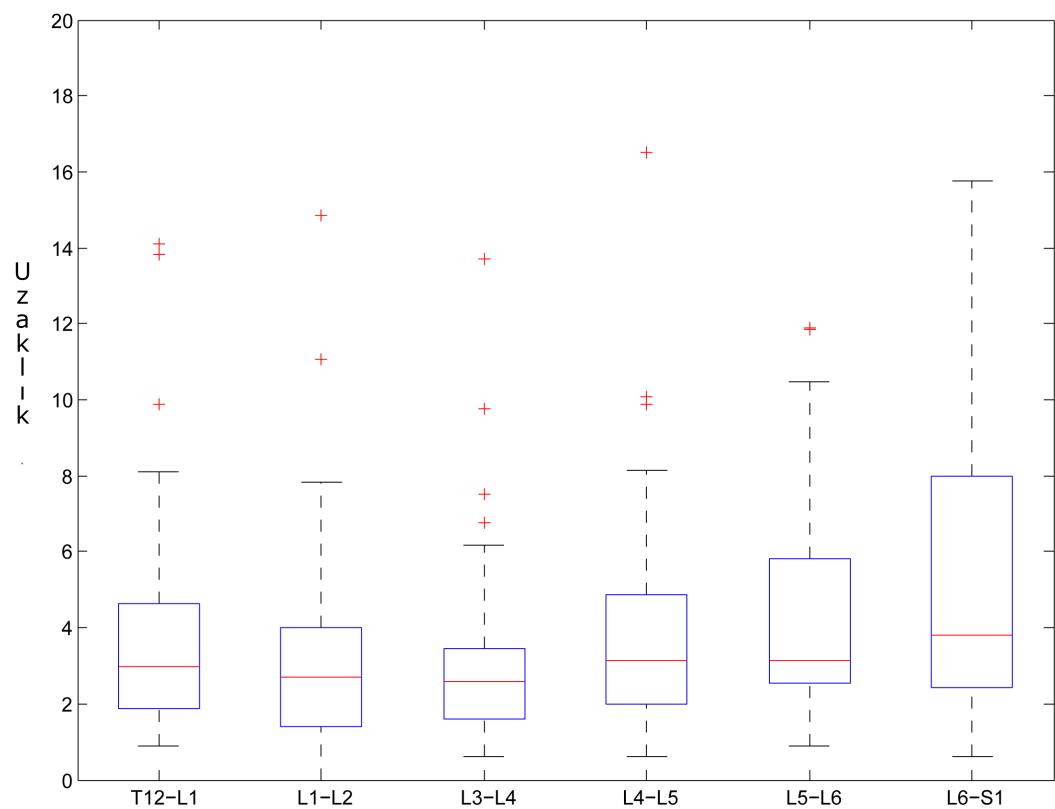
Disk konumlandırma için ikinci değerlendirme metodu ise, sistem tarafından otomatik olarak bulunan disk merkezlerinin uzman tarafından çizilmiş gerçek merkeze olan Öklid uzaklığıdır. Lomber eğrideki diskler için Öklid uzaklıklar Şekil 4.4'te gösterilmiştir.

Şekil 4.5 geliştirilen metodun ve literatürdeki [Alomari et al., 2010] ve [Schmidt et al., 2007] metodlarının lomber diskler için medyan Öklid uzaklıklarını göstermektedir. Geliştirilen metodun medyan uzaklıkları diğer iki metottan her disk için daha küçüktür.

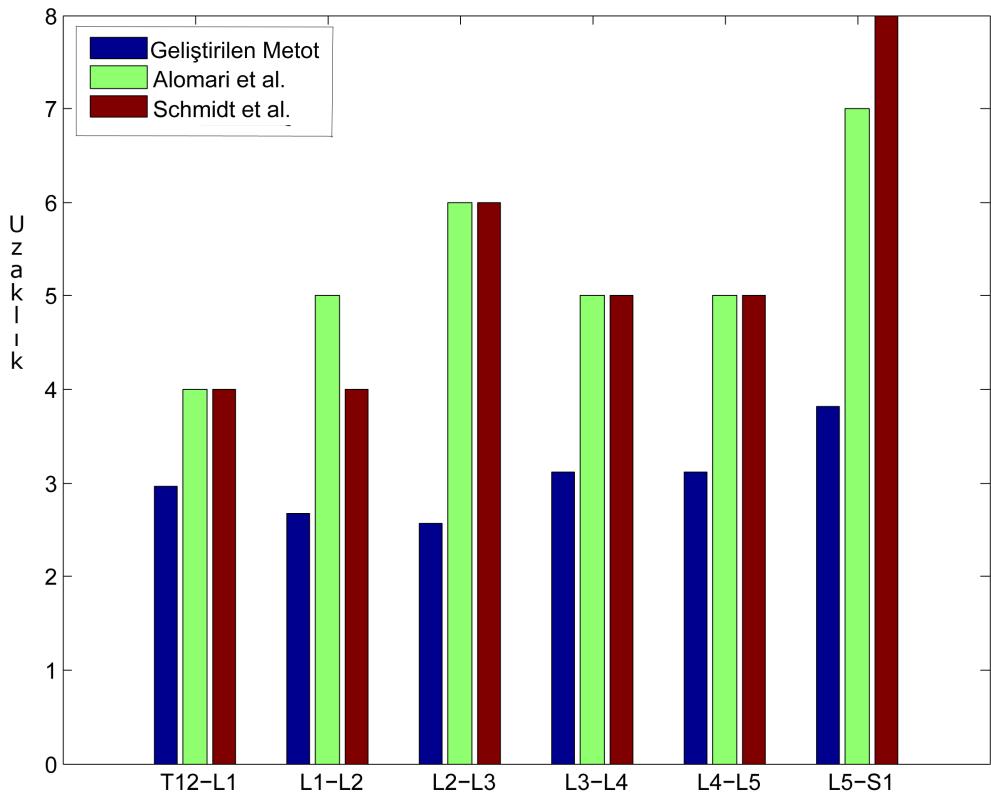
Geliştirilen sistemin bazı sonuçları Şekil 4.6'de gösterilmiştir. Görsel olarak da belirlendiği üzere hastahlı durumlarda dahi sistem diskleri çoğunlukla başarılı bir şekilde konumlandırmaktadır. Sistemin büyük hata yüzdesiyle en başarısız konumlandırdığı diskler de Şekil 4.7'de gösterilmiştir.

4.5. Yorumlar

Bu bölümde, makine öğrenmesi ve grafiksel model tabanlı disk saptama ve disk konumlandırma metodu sunulmuştur. Metot, ilk olarak PYGH tanımlayıcılarını, eğitim kümesindeki imgelerden çıkarmaktadır. Çıkarılan öznitelikler DVM ile



Şekil 4.4: Kutu diyagramı, disk merkezlerine olan Öklid uzaklıkları mm cinsinden göstermektedir. Kutuların ortasındaki çizgi medyan, üst ve alt çizgiler 25. ve 75. yüzdeliği ve artılar da istatistiksel aykırı değerlerdir.



Şekil 4.5: Grafik geliştirilen metodun, [Alomari et al., 2010] ve [Schmidt et al., 2007] metodlarının lumber diskler için ortalama medyan Öklid uzaklıklarını göstermektedir.

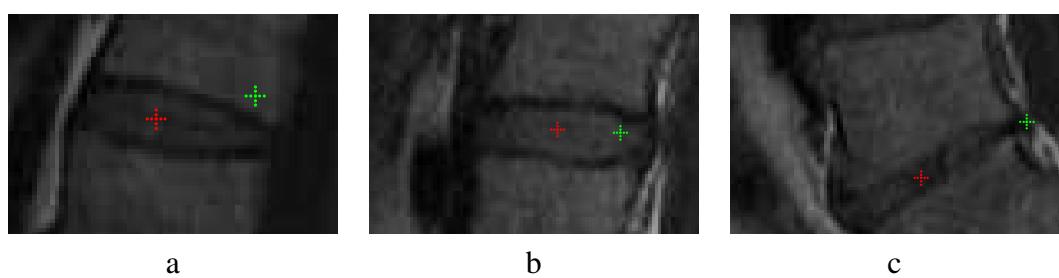
öğrenilmekte ve yeni bir hedef imge verildiği zaman, piksellere disk merkezi olma durumunu gösteren skor değerleri atanmaktadır. Oluşturulan skor değerleri kullanılarak, grafiksel modelden en iyi lumber disk konfigürasyonu bulunmaktadır.

Metot lokal disk bilgisini ve global şekil bilgisini birleştirmektedir. İlk, disklerin lokal özellikleri olan gradyan bilgisi PYGH tanımlayıcılarını kullanarak DVM ile bulunmaktadır. Tüm disklerin birbirleri olan uzaklık ve yön gibi etkileşimi de global grafiksel modelde tanımlanmıştır. Böylece diskler konumlandırılırken, hem lokal disk bilgisi hem de disklerin lumber eğriderdeki durumları önsel olarak kullanılmıştır. Metot, lokal ve global önsellerin modüler bir şekilde birleştirilmesi açısından önem taşımaktadır.

Geliştirilen disklere skor değeri verme işlemi, literatürdeki diğer metodlardan deneylerle de doğrulandığı üzere daha dayanıklıdır. Ayrıca, sisteme T2-ağırlıklı imgelerden daha başka lokal önseller de eklenebilir. Sistem, disklere skor verme işleminin başarısına güvenmekte ve disk olmayan yerleri kesin çıkarım metoduna dahil



Şekil 4.6: Disk konumlandırma işleminden bazı görsel sonuçlar. Kırmızı artı işaretleri tam doğru merkezleri, yeşil artılar da sistemin otomatik olarak bulduğu diskleri göstermektedir. İmgeler görselliği artırmak için kesilmiştir.



Şekil 4.7: Veri kümesindeki (a) T12-L1, (b) L4-L5, (c) L5-S1 diskler için en başarısız konumlandırmalar. Kırmızı artılar gerçek merkezi, yeşil artılar da sistemin bulduğu disk merkezlerini göstermektedir.

etmemektedir. Böylece, sistem daha verimli hale gelmektedir. Polinom zamanda kesin çıkışım algoritması çalışmakta ve diskleri imge üzerinde konumlandırmaktadır. Sistemde basit değişiklikler yapılarak kolaylıkla tüm omurga üzerinde çalışır hale getirilebilir.

Gerçek lomber eğri içeren MR imgeleri üzerinde yapılan deneyler, sistemin lomber diskleri başarı ile bulduğunu ve literatürdeki metodlardan daha iyi olduğunu göstermiştir.

5. PYGH VE LOKAL ÖZNİTELİKLER KULLANARAK KALP YERİNİ BULMA VE SKOR VERME

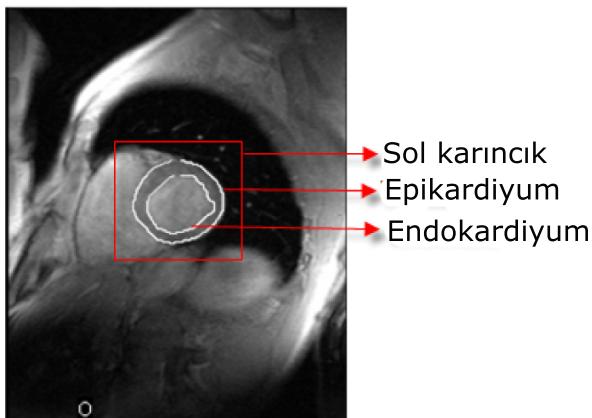
Bu bölümde, sadece lokal bilgi kullanarak kalp sınırlarının bulunması için bir yaklaşım sunulmaktadır. Yaklaşım, nesne konturlarını bulmak için AGM, düzey kümesi gibi geleneksel metodlar kullanmak yerine, piksel bazında pikselleri birleştiren başka bilgi olmadan skor verme işlemini gerçekleştirmektedir.

Adaboost ile sol karıncığın MR imgesi üzerindeki yerine belirleme ve kalp sınırlarına skor verme işlemi yapılmaktadır (Şekil 5.1). İlk olarak, sol karıncığın yeri PYGH tanımlayıcıları [Bosch et al., 2007] kullanarak kayan pencere tekniği ile bulunmaktadır. PYGH tanımlayıcıları Adaboost ile eğitilmekte ve test edilmektedir. Daha sonra, kalbin bulunduğu penceredeki piksellerin lokal öznitelikleri çıkartılmakta ve yine Adaboost ile hangi piksellerin kalp duvarı olduğunu veya olmadığını gösteren skor değerleri verilmektedir.

Oluşturulan skor değerlerini içeren imgeler, geleneksel kontur bulma metodlarında kullanılabilir. Ayrıca, bu sistem sadece lokal bilgi ile konturların ne kadarının bulunabildiğine dair bilgi vermektedir.

YGH tanımlayıcıları literatürde genellikle insan aktivitelerinin tanınmasında kullanılmaktadır [Dalal and Triggs, 2005]. Özellikle MR imgeleri çok fazla gürültülü olmadığı ve yüksek kontrasta sahip olduğu için organların kenarları açıkça görülebilmektedir. Ayrıca, MR kalp imgelerinde dönme olmadığı için, imgelerdeki organlar bir noktaya göre çok benzer açılara sahiptir. Bu yüzden, tıbbi imgelerden öznitelik çıkarmada YGH tanımlayıcıları gayet etkilidir ve organların özellikleri hakkında yeterli bilgi sağlamaktadır.

Klasik makine öğrenmesi tabanlı imge analizi sistemleri, genellikle imge alanları üzerinde hipotez testi yapmaktadır. Bu çalışmada, sol karıncık yerini belirleme işlemi de benzer bir işlemidir. Yakın zamanda, imgedeki alanlar üzerinde hipotez testi yapmak yerine, piksel tabanlı skor verme işlemi popüler olmaktadır [Oktay and Akgul, 2009], [Fulkerson et al., 2008]. Bu çalışmada, ilk olarak alan



Şekil 5.1: Bir kalp MR imgesinde sol karıncık alanı ve epikardiyum ve endokardiyum.

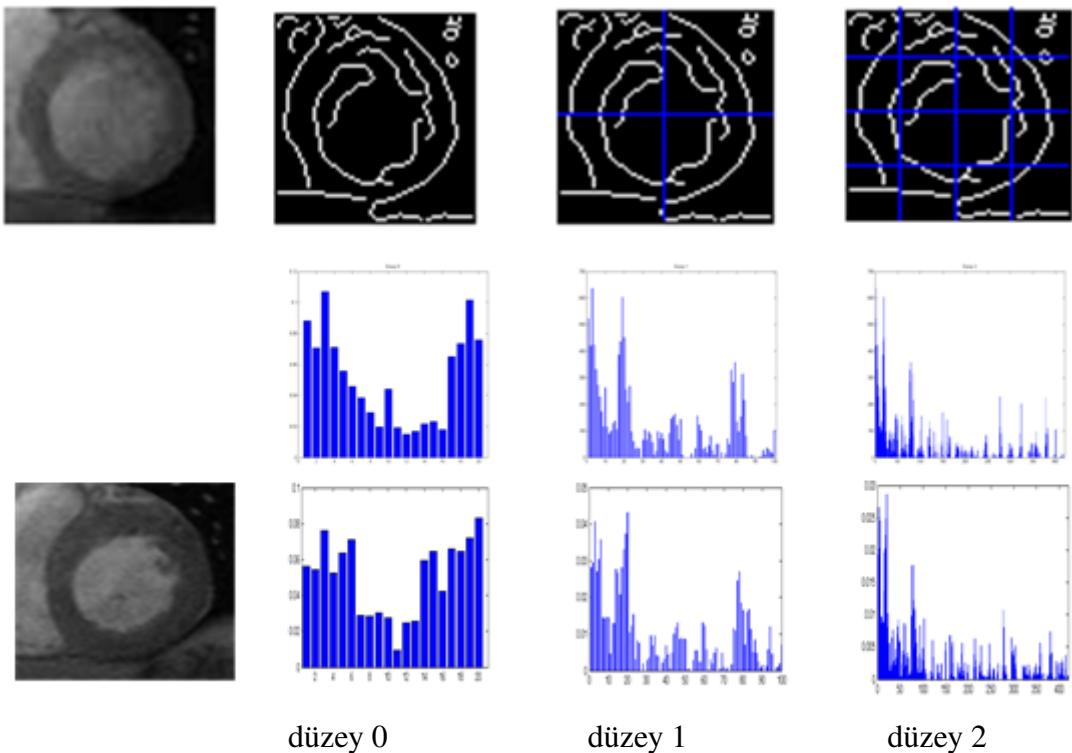
tabanlı hipotez testi ile sol karıncık alanı bulunmakta, sonra piksel tabanlı yaklaşımla daha fazla lokal bilgi kullanılarak piksellere skor verme işlemi gerçekleştirilmektedir.

5.1. PYGH ile Sol Karıncığın Bulunması

Kalp MR imgeleri, kalp dışında birçok farklı organ ve yapıyı da içermektedir. Kontur bulma metotları ilklendirmeye bağlı olduğu için, eğer sol karıncıktan çok uzakta bir yere ilklendirilirse bazı yüksek imge gradyanının olduğu yerlere takılabilmekte ve sol karıncığa hiç ulaşamamaktadır. Bu yüzden ilklendirmenin sol karıncığa yakın bir yere yapılması önemlidir. Sol karıncığın yerini otomatik olarak tespit etmek, kontur bulma işlemini oldukça kolaylaştırmaktadır.

İmgede sol karıncığın yeri kayan pencere yöntemi ile eğitilmekte ve bulunmaktadır. YGH tanımlayıcısı ile her pencerenin öznitelikleri çıkarılmaktadır. PYGH tanımlayıcısı önceki bölümlerde de dephinildiği üzere [Dalal and Triggs, 2005]'teki lokal imge şeklini ve uzamsal piramit çekirdeği metodunu birleştirmektedir [Lazebnik et al., 2006].

Piramit yapıyı sağlamak için imge her düzeyde dörtlü ağaç gibi dört eşit parçaya bölünmekte ve her parça için tekrar YGH tanımlayıcı ile öznitelikler çıkartılmaktadır. En sonunda her parçanın öznitelikleri birleştirilip PYGH tanımlayıcısı oluşturulmaktadır. Şekil 5.2'te kalp alanı ve 3 değişik düzeyde çıkarılmış ve 20 seleye konmuş PYGH tanımlayıcıları gösterilmiştir. İlk sütunda bir



Şekil 5.2: İlk sütunda kalp alanları görülmektedir. İkinci sütunda bu kalp alanlarından çıkartılmış sıfırıncı düzey YGH histogramı, üçüncü ve dördüncü sütunlarda ise düzey 1 ve düzey 2'deki PYGH histogramları gösterilmiştir. İki imgenin, histogramları arasındaki benzerlik, PYGH tanımlayıcısının etkinliğini ortaya koymaktadır.

sol karıncık alanı, ikinci sütunda sıfırıncı düzeyde kalp alanından çıkartılmış PYGH histogramı gösterilmiştir. Üçüncü sütunda, alan 4 eşit parçaaya bölünmüştür ve her parça için ayrı ayrı PYGH tanımlayıcısı çıkarılmıştır. Üçüncü sütundaki histogram sıfırıncı düzeydeki histogramla, bu dört parçadan çıkan histogramın birleştirilmiş halidir. Son sütunda ise, her parça tekrar 4 eşit parçaaya bölünmüştür ve kalp alanı toplam 16 parçaaya bölünmüştür. Histogram, bir önceki düzeydeki histogramın bu 16 parçadan çıkan histogramla birleştirilmiş halidir. En alt satırda başka bir kalp alanı ve onun PYGH histogramı verilmiştir. İki farklı kalp alanından çıkarılan PYGH histogramları birbirleriyle büyük benzerlik göstermektedir. Her PYGH düzeyinde önemli ayırt edici özellikler tanımlanmıştır.

Kalp alanının eğitim ile öğrenilmesi için, kalp imgelerinden değişik boyutlarda pencereler kullanılmıştır. İçinde kalp bulunan pencereler, pozitif örnekler, kalp bulunmayan pencereler ise negatif örnek olarak belirlenmiştir. Test için ise, hedef imgeden kayan pencere teknigi ile değişik boytlardaki pencereler için PYGH tanımlayıcıları

çıkartılmıştır. Hedef imgeden çıkarılan pencerelerin özellikleri Adaboost ile test edilmiş ve içinde kalp var olarak sınıflandırılan pencerelerin kesişimi kalp alanı olarak tanımlanmıştır.

5.2. Adaboost ile Piksellere Skor Değeri Atama

Önceki kısımda anlatıldığı üzere sol karıncık alanının bulunmasından sonra, epikardiyum ve endokardiyumun bulunması daha uygun hale gelir. Bu aşamada, sadece lokal bilgilerle sol karıncığın global şeklini işlemin içine katmadan piksel bazında skor verme işlemi gerçekleştirilmektedir. Oluşan skor imgesinin önsel bilgi olarak kontur çıkarma metotlarıyla kullanılabilmesinin yanı sıra, sadece lokal bilgi ile kontur bulma işlemini de göstermektedir.

Bulunan sol karıncık alanındaki her piksel için toplam 21 tane basit lokal öznitelik çıkarılmaktadır. Bunlar:

- pikselin kenar olup olmadığı,
- komşu kenar piksellerinin sayısı (bir bölgede),
- lokal parlaklık histogramı (bir bölgede),
- pikselin pencerenin merkezine uzaklığı,
- birbirine bağlı kenar sayısı (bir bölgede).

Çıkarılan 21 basit öznitelik Adaboost ile eğitilir. Bölüm 1.3'de anlatılan Adaboost algoritmasından farklı olarak, zayıf hipotezleri birleştirip $sign(H(x))$ değerini kullanmak yerine, $H(x)$ değeri doğrudan skor olarak kullanılmıştır. Yani skor değeri, α_t ağırlıklar ve $h_t(x)$ zayıf sınıflayıcılar olmak üzere, şu şekilde hesaplanmıştır:

$$H(x) = \sum_{t=1}^T \alpha_t h_t(x). \quad (5.1)$$

Bu formüldeki T de zayıf sınıflayıcıların sayısını belirtmektedir.

Denklem 5.1 ile her piksele, o pikselin kalp duvarı olup olmadığını gösteren bir skor değeri verilir. Sadece, kalp alanı olarak belirlenen alandaki piksellere skor değeri verilmektedir ve o alandaki piksel skorlarının oluşturduğu imgeye skor imgesi adı verilmiştir.

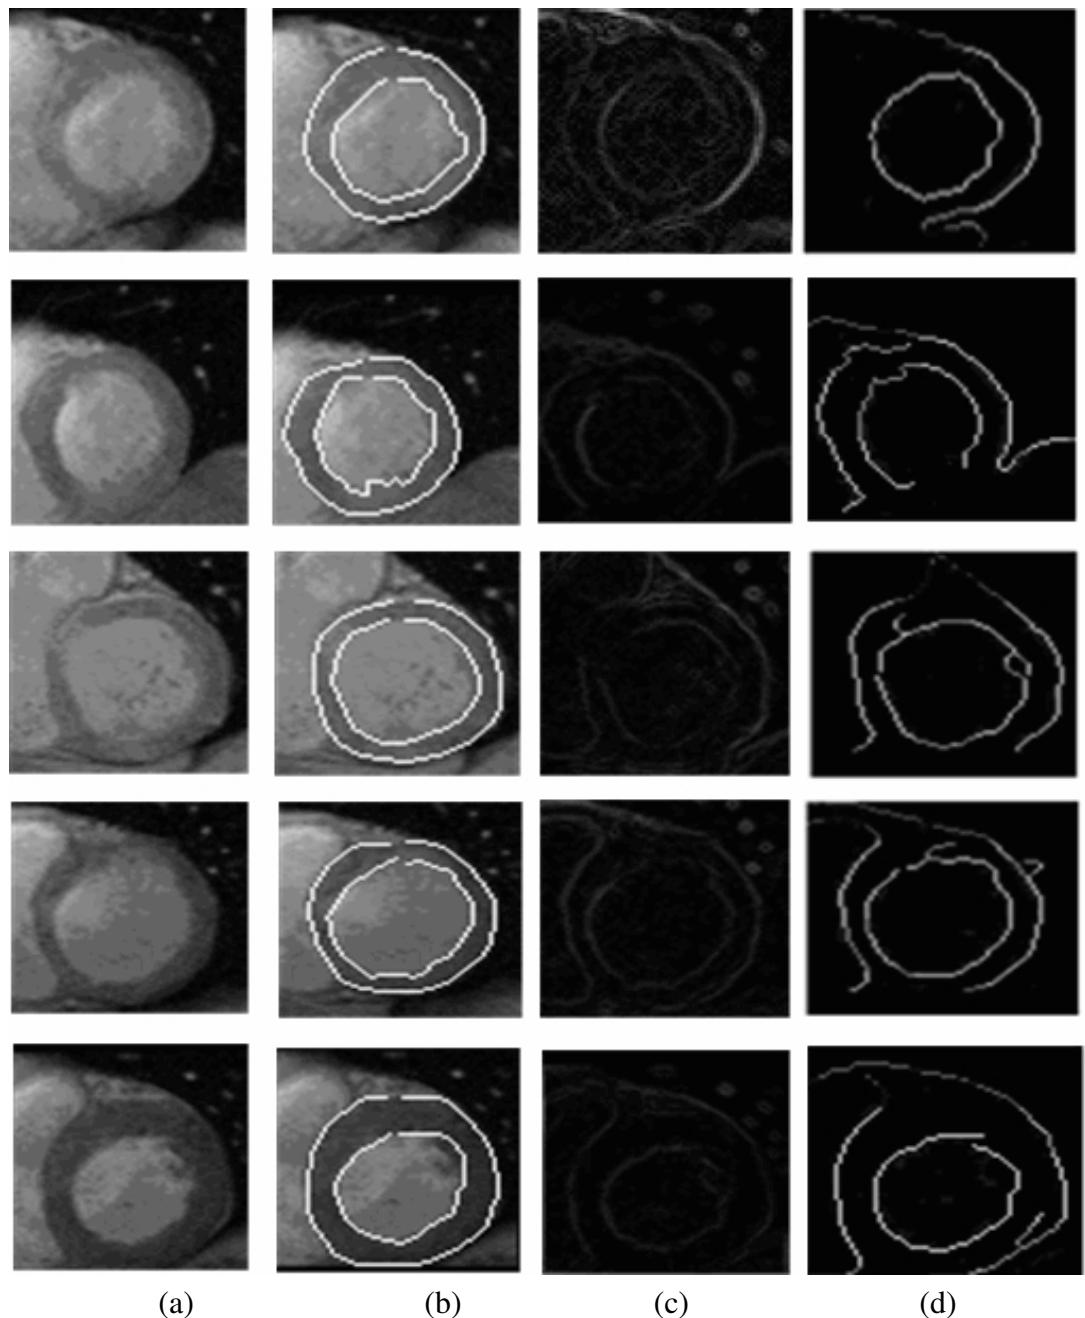
5.3. Deneysel Sonuçlar

Geliştirilen sistem, 14 gerçek kalp MR imgesi içeren bir veri kümesi [Stegmann, 2000] üzerinde test edilmiştir. MR imgeleri 256x256 piksel boyutundadır. Sol karıncığın endokardiyal ve epikardiyal konturu 33 nirengi noktası ile bir uzman tarafından işaretlenmiştir. Uzman konturları pozitif örnekler olarak kullanılmıştır. 9 imgé eğitim için, diğer 5 imgé ise test için kullanılmıştır.

Sol karıncık alanının bulunması için, değişik boyutlarda pencereler manüel olarak belirlenmiştir. Her imgé için, 5 pozitif örnek pencere ve 17 negatif örnek pencere eğitim kümesinde kullanılmıştır. PYGH tanımlayıcısında 3 düzey kullanılmış ve sele sayısı 8 olarak belirlenmiştir. Her pencere için PYGH tanımlayıcısının toplam öznitelik sayısı 168'dir. Kayan pencerenin boyutu 50x50 pikselden 80x80 piksele kadar değişmektedir.

Yapılan deneyde sol karıncık alanı 5 test imgesinde de doğru olarak tespit edilmiştir. Bu pencerelerin kesişimi asıl sol karıncık alanı olarak tanımlanmıştır. Şekil 5.3(a)'da bulunan pencereler gösterilmiştir. Sistemin tüm test imgelerinde sol karıncık yerini doğru bulması PYGH tanımlayıcısının, kalp konturlarının özniteliklerini çok başarılı bir şekilde çıkarmasından kaynaklanmaktadır. PYGH ile yuvarlağa benzer sol karıncık iyi tanımlanmıştır ve MR imgesinde bu şekilde başka bir yuvarlak yapı bulunmamaktadır. Bu da hiç yanlış pozitiforneğin olmamasını sağlamaktadır. Ayrıca, eğitim kümesinde çok az sayıda imgé olmasına rağmen sistem başarılıdır.

Sol karıncık alanı bulmada kullanılan 9 eğitim imgesi ve 5 test imgesi, piksellere skor vermek için de aynen kullanılmıştır. Her piksel için çıkarılan öznitelik sayısı 21'dir. Uzman tarafından her imgé için işaretlenen 66 piksel pozitif örnek olarak kullanılmıştır. Diğer piksellerin rasgele seçilmiş %25'i negatif örnek olarak kullanılmıştır.



Şekil 5.3: (a) Bulunan sol karıncık alanları, (b) uzmanlar tarafından işaretlenmiş konturlar, (c) bulunan alanlardaki gradyan şiddetleri, (d) skor verme işlemi sonuçları.

5 test imgesi için Şekil 5.3(b) uzman konturlarını, (c) alanlardaki gradyan şiddetini ve (d) geliştirilen sistem tarafından bulunan skor imgesini göstermektedir. Skor imgelerindeki parlak pikseller skor değerlerinin ve kalp duvari olma ihtimalini yüksek olduğu yerleri, parlak olmayan pikseller skor değerlerinin düşük olduğu ve kalp duvari olmayan yerleri göstermektedir. Sonuçlar görsel olarak incelemiş zaman, skor verme işlemi sonucunda kalp konturlarının büyük kısmının bulunabildiği görülmektedir. Yalnız, çoğu imgede aortun bağlandığı kalp duvari bulunamamış, aksine aort kalp duvarının devamı gibi yüksek skor değeri almıştır. Skor değerlerini içeren imgeler (Şekil 5.3(d)), gradyan şiddeti imgelerinden daha fazla kontur bilgisi içermektedir ve geleneksel kontur bulma işlemlerinde kullanılabilir.

5.4. Yorumlar

Bu bölümde PYGH tanımlayıcıları ile öznitelik çıkararak, Adaboost ile kalp MR imgelerinde sol karıncığın yerini saptama ve sadece lokal özelliklerle kalp konturlarına skor değerleri atama metodu sunulmuştur. Kalbin yeri önceden tespit edilerek birçok kontur bulma işlemi daha verimli hale getirilebilir. Ayrıca kullanılan PYGH öznitelikleri, sol karıncığı çok iyi tanımlamıştır. PYGH metodu, diğer tıbbi imgelerde de organ özniteliklerini çıkarmak için kullanılabilir.

Geliştirilen metod, sol karıncık alanını bulduktan sonra bu alandaki piksellerin lokal olarak özelliklerine bakarak onlara skor değerleri atamıştır. Kalp konturlarının büyük bir kısmı basit lokal özniteliklerle bulunmuştur; fakat bazı konturun belli olmadığı ve kontrastın düşük olduğu bazı yerlerde (özellikle aort çevresinde) bulunamamıştır. Bu da bize, basit lokal önsellerle kalp duvari bulmanın mümkün olmadığını göstermektedir. Ancak üretilen skor imgesi, geleneksel kontur bulma algoritmalarında kullanılabilir.

Bu bölümdeki metod, arama uzayı dar dahi olsa, çok az lokal önselle global bilgi kullanmadan başarılı bir şekilde kontur bulmanın olamayacağını göstermesi açısından önem taşımaktadır. Lokal bilgi ile oluşturulan skor imgesi, konturlar hakkında normal imgelerden daha fazla bilgi verebilir. Hatta, skor imgesine basit bir elips yerleştirme (fitting) işlemi ile tüm sol karıncık konturu bulunabilir.

6. SONUÇLAR ve YORUMLAR

Bilgisayarla görme teknikleri ile nesne saptama ve nesnelerin konturlarını bulma, üzerinde uzun zamandan beri üzerinde çalışılan iki temel konudur. İmgelerin aşırı gürültülü olması, nesnelerin bazı yerlerinin kapanmış olması, nesnelerin görünüşlerinin duruşa ve boyuta göre değişmesi gibi sebeplerden dolayı bu işlemler her zaman başarılı bir şekilde gerçekleştirilememektedir. Literatürde, nesne saptama ve kontur bulma işlemlerini daha başarılı hale getirmek için çeşitli önsel bilgi ekleme metotları önerilmiştir. Bu şekilde, hedef nesne ile ilgili daha fazla bilginin nesne saptama veya kontur bulma işlemine katılması ile daha iyi sonuçlar elde edilmektedir.

Bu tez çerçevesinde, nesne saptama ve kontur bulma için çeşitli önsel bilgi ekleme yaklaşımları sunulmuştur. Literatürdeki metotlar, genellikle ya hedef nesnenin tümünü, ya da nesneyi parçalara ayırarak önsel bilgi olarak kullanmışlardır. Lakin, bu tezde eklenen önsel bilgi lokal ve global olarak sınıflandırılmıştır. Böylece hem alt seviyedeki lokal özellikler, hem de nesnenin daha üst düzeydeki global bilgiler hiyerarşik bir şekilde kullanılmıştır. Bu da, farklı türdeki bilgilerin kolay ve verimli bir şekilde eklenmesini sağlamıştır. Sunulan yaklaşımlar, hedef nesnenin önceden belli olduğu ve nesne hakkında ana hatlarıyla önsel bilgiye sahip olunan çeşitli tıbbi imgeler üzerinde uygulanmıştır.

Geliştirilen metotlar, farklı tiplerdeki lokal özellikleri çeşitli makine öğrenmesi metotlarını kullanarak öğrenmişlerdir. Global önsel bilgiler ise, düzey kümesi ve grafiksel model gibi tekniklerle işlemlere dahil edilmiştir. Yeni metotlarla, sol karıncık konturları MR imgelerinden ve ekokardiyogramlardan bulunmuştur. Ayrıca, lomber omurlar arasındaki diskler MR imgeleri üzerinde konumlandırılmışlardır.

Bu tezin, bilgisayarla görme ve tıbbi görüntüleme alanları için faydalı olabilecek birçok katkısı bulunmaktadır. İlk olarak, önsel bilginin lokal ve global olarak hiyerarşik bir şekilde ayrılması ve aşağıdan yukarıya bir yaklaşım benimsenmesi, kurulan çerçevenin daha modüler ve esnek olmasını sağlar. Böylece, eklenen bilginin hangi seviyede yeterli olduğuna karar verilip, gereksiz yere fazla bilginin eklenmesi ile sistemin yükünün artırılmasının önüne geçilmiş olur. Ayrıca, farklı tipteki bilgiler hiyerarşik düzen korunarak farklı metotlarla sisteme dahil edilebilir.

İkinci olarak, tıbbi imgelerin kendilerine has birçok öznitelikleri vardır. Bu öznitelikler, en uygun metodlarla çıkartılmıştır. Mesela, kalp duvarları için Haar tipi filtreler kullanılırken, diskler için YGH tanımlayıcısı kullanılmıştır. Bu şekilde, gözle görülemeyen küçük öznitelikler dahi kodlanabilmiştir. Ayrıca, bu özniteliklerin çıkarımında integral histogram gibi hızı artırıcı teknikler kullanılmış ve nesneler bu şekilde tanımlanmıştır.

Üçüncü olarak, makine öğrenmesi metodlarının tıbbi görüntülerle beraber kullanılmasıdır. Çıkarılmış öznitelikler, DVM ve Adaboost gibi makine öğrenmesi metodları ile öğrenilmiştir. Eğitim ve test sırasında, öznitelikler çok farklı tipteki bilgileri de tanımlasalar, hiçbir regülarizasyona ihtiyaç duyulmadan birlikte öğrenilmişlerdir. Bu şekilde, bilgileri ayrı ayrı modellemeye gerek kalmamış ve bu modeller birleştirilirken de parametreye ihtiyaç duyulmamıştır.

Dördüncü olarak, zaman-uzamsal bilginin 3 boyutlu filtrelerle sisteme dahil edilmesidir. Normalde, kalp hareketini belirlemek ve modelleyip bölütleme işleminde kullanmak oldukça zordur. Geliştirilen sistemde, filtreleri kaydırarak ve en büyük değeri alıp metodu doğrusal olmayan hale getirerek kalp hareketi belirlenmiş ve lokal önsel olarak kullanılmıştır.

Ayrıca, olasılık tabanlı grafiksel zincir tipindeki model tıbbi imgelere uygulanmış ve polinom zamanda kesin çıkışım yapılmıştır. Bu literatürdeki metodlardan daha hızlı ve etkili sonuçlara ulaşılmasını sağlamıştır.

Son olarak, geliştirilen yaklaşımlar sadece üzerinde çalıştırıldıkları tıbbi imgelere değil, küçük değişikliklerle başka tıbbi imgelere de uygulanabilir. Ayrıca, hedef nesne hakkında bilgiye sahip olunan ve tıbbi olmayan gerçek dünya imgeleri üzerinde de çalıştırılabilir.

Sonuç olarak, bu tezde düzey kümesi, makine öğrenmesi ve grafiksel model gibi farklı metodlarla hiyerarşik olarak sınıflandırılmış önsel bilginin kullanımı gösterilmiş ve daha başarılı sonuçlar ürettiği bulunmuştur.

KAYNAKLAR

- Akgul, Y. S. and Kambhamettu, C. (2003). A coarse-to-fine deformable contour optimization framework. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 25:174–186.
- Alomari, R. S., Corso, J. J., and Chaudhary, V. (2010). Labeling of lumbar discs using both pixel- and object-level features with a two-level probabilistic model. *IEEE Transactions on Medical Imaging*, (99):1 –10.
- Amores, J., Sebe, N., Radeva, P., Gevers, T., and Smeulders, A. (2004). Boosting contextual information in content-based image retrieval. In *Proceedings of the 6th ACM SIGMM international workshop on Multimedia information retrieval*, pages 31–38.
- Barrow, H. G., Tenenbaum, J. M., Bolles, R. C., and Wolf, H. C. (1977). Parametric correspondence and chamfer matching: two new techniques for image matching. In *Proceedings of International Conference on Artificial Intelligence*, pages 659–663, San Francisco, CA, USA. Morgan Kaufmann Publishers Inc.
- Besbes, A., Komodakis, N., Langs, G., and Paragios, N. (2009). Shape priors and discrete mrf's for knowledge-based segmentation. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, pages 1295–1302.
- Biederman, I. (1987). Recognition-by-components: a theory of human image understanding. *Psychological Review*, 94(2):115–147.
- Biederman, I., Mezzanotte, R. J., and Rabinowitz, J. C. (1982). Scene perception: Detecting and judging objects undergoing relational violations. *Cognitive Psychology*, 14(2):143–177.
- Bishop, C. M. (2007). *Pattern Recognition and Machine Learning (Information Science and Statistics)*. Springer.

- Bosch, A., Zisserman, A., and Munoz, X. (2007). Representing shape with a spatial pyramid kernel. In *Proceedings of the International Conference on Image and Video Retrieval*.
- Bresson, X., Vandergheynst, P., and Thiran, J.-P. (2006). A variational model for object segmentation using boundary information and shape prior driven by the mumford-shah functional. *International Journal of Computer Vision*, 68(2):145–162.
- Brown, M., Szeliski, R., and Winder, S. (2005). Multi-image matching using multi-scale oriented patches. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition, CVPR '05*, pages 510–517.
- Brunelli, R. (2009). *Template Matching Techniques in Computer Vision: Theory and Practice*. Wiley.
- Carballido-gamio, J., Belongie, S. J., and Majumdar, S. (2004). Normalized cuts in 3-d for spinal mri segmentation. *IEEE Transactions on Medical Imaging*, 23:36–44.
- Carneiro, G., Georgescu, B., Good, S., and Comaniciu, D. (2008). Detection and measurement of fetal anatomies from ultrasound images using a constrained probabilistic boosting tree. *IEEE Transactions on Medical Imaging*, 27(9):1342–1355.
- Caselles, V., Catté, F., Coll, T., and Dibos, F. (1993). A geometric model for active contours in image processing. *Numerische Mathematik*, 66(1):1–31.
- Chen, S. and Radke, R. J. (2009). Level set segmentation with both shape and intensity priors. In *IEEE International Conference on Computer Vision*, pages 763–770. IEEE.
- Chen, Y., Huang, F., Tagare, H. D., and Rao, M. (2007). A coupled minimization problem for medical image segmentation with priors. *International Journal Computer Vision*, 71(3):259–272.
- Chen, Y., Tagare, H. D., Thiruvenkadam, S., Huang, F., Wilson, D., Gopinath, K. S., Briggs, R. W., and Geiser, E. A. (2002). Using prior shapes in geometric active contours in a variational framework. *International Journal of Computer Vision*, 50(3):315–328.

- Cootes, T. F., Edwards, G. J., and Taylor, C. J. (1998). Active appearance models. *Proceedings of the European Conference on Computer Vision*, 2:484–498.
- Cootes, T. F., Taylor, C. J., Cooper, D. H., and Graham, J. (1995). Active shape models-their training and application. *Computer Vision and Image Understanding*, 61:38–59.
- Corso, J. J., Alomari, R. S., and Chaudhary, V. (2008). Lumbar disc localization and labeling with a probabilistic model on both pixel and object features. In *Proceedings of the 11th international conference on Medical Image Computing and Computer-Assisted Intervention - Part I*, MICCAI '08, pages 202–210, Berlin, Heidelberg. Springer-Verlag.
- Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20:273–297.
- Cremers, D., Rousson, M., and Deriche, R. (2007). A review of statistical approaches to level set segmentation: Integrating color, texture, motion and shape. *International Journal of Computer Vision*, 72:195–215.
- Crow, F. C. (1984). Summed-area tables for texture mapping. In *Proceedings of the Conference on Computer Graphics and Interactive Techniques*, pages 207–212, New York, NY, USA.
- Dalal, N. and Triggs, B. (2005). Histograms of oriented gradients for human detection. In *International Conference on Computer Vision and Pattern Recognition*, volume 2, pages 886–893.
- Duda, R. O. and Hart, P. E. (1972). Use of the hough transformation to detect lines and curves in pictures. *ACM Communications*, 15:11–15.
- Duda, R. O., Hart, P. E., and Stork, D. G. (2001). *Pattern Classification (2nd Edition)*. Wiley-Interscience, 2 edition.
- Edwards, G. J., Taylor, C. J., and Cootes, T. F. (1998). Learning to identify and track faces in image sequences. In *Proceedings of the 3rd. International Conference on Face & Gesture Recognition*, FG '98, pages 260–.

- Feng, S., Zhou, S., Good, S., and Comaniciu, D. (2009). Automatic fetal face detection from ultrasound volumes via learning 3d and 2d information. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, pages 2488–2495.
- Fink, M. and Perona, P. (2004). Mutual boosting for contextual inference. In *Neural Information Processing Systems*, volume 17.
- Freund, Y. (1990). Boosting a weak learning algorithm by majority. In *Proceedings of the Third Annual Workshop on Computational Learning Theory*, COLT '90, pages 202–216, San Francisco, CA, USA. Morgan Kaufmann Publishers Inc.
- Freund, Y. and E.Schapire, R. (1997). A decision-theoretic generalization of on-line learning and an application to boosting. *The Journal of Computer and System Sciences International*, 55(1):119–139.
- Fulkerson, B., Vedaldi, A., and Soatto, S. (2008). Localizing objects with smart dictionaries. In *European Conference on Computer Vision*.
- Georgescu, B., Zhou, X., Comaniciu, D., and Gupta, A. (2005). Database-guided segmentation of anatomical structures with complex appearance. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, volume 2, pages 429–436.
- Giles, L. and Singer, K. (2007). *Clinical Anatomy and Management of Low Back Pain*. Butterworth-Heinemann.
- Goferman, S., Zelnik-Manor, L., and Tal, A. (2010). In *IEEE Conference on Computer Vision and Pattern Recognition*.
- Gower, J. (1975). Generalized procrustes analysis. *Psychometrika*, 40:33–51.
- Kass, M., Witkin, A., and Terzopoulos, D. (1988). Snakes: Active contour models. *International Journal of Computer Vision*, 1(4):321–331.
- Kumar, R., Wang, F., Beymer, D., and Syeda Mahmood, T. (2009). Echocardiogram view classification using edge filtered scale-invariant motion features. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, pages 723–730.

- Laptev, I. (2009). Improving object detection with boosted histograms. *Image and Vision Computing*, 27:535–544.
- Lazebnik, S., Schmid, C., and Ponce, J. (2006). Beyond bags of features: Spatial pyramid matching for recognizing natural scene categories. In *IEEE Conference on Computer Vision and Pattern Recognition*.
- Lee, H., Codella, N. C. F., Cham, M. D., Weinsaft, J. W., and Wang, Y. (2010). Automatic left ventricle segmentation using iterative thresholding and an active contour model with adaptation on short-axis cardiac mri. *IEEE Transactions on Biomedical Engineering*, 57(4):905–913.
- Lepetit, V. and Fua, P. (2006). Keypoint recognition using randomized trees. *IEEE Transactions on Pattern Analysis Machine Intelligence*, 28:1465–1479.
- Leventon, M., Faugeras, O., Grimson, E., and Wells, W. (2000). Level set based segmentation with intensity and curvature priors. In *Proceedings of the IEEE CVPR Workshop on Mathematical Methods in Biomedical Image Analysis*, page 4, Washington, DC, USA.
- Li, C., Xu, C., Gui, C., and Fox, M. D. (2005). Level set evolution without re-initialization: A new variational formulation. In *Proceedings of IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 1, pages 430–436, Washington, DC, USA. IEEE Computer Society.
- Liu, Y., Chen, X., Yao, H., Cui, X., Liu, C., and Gao, W. (2009). Contour-motion feature (cmf): A space \times time approach for robust pedestrian detection. *Pattern Recognition Letters*, 30:148–156.
- Lowe, D. G. (2004). Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60:91–110.
- Malladi, R., Sethian, J. A., and Vemuri, B. C. (1995). Shape modeling with front propagation: a level set approach. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 17(2):158–175.
- Navon, D. (1977). Forest before trees: The precedence of global features in visual perception. *Cognitive Psychology*, 9:353–383.

- Noble, J. and Boukerroui, D. (2006). Ultrasound image segmentation: A survey. *IEEE Transactions on Medical Imaging*, 25(8):987–1010.
- Nordstrøm, M. M., Larsen, M., Sierakowski, J., and Stegmann, M. B. (2004). The IMM face database - an annotated dataset of 240 face images.
- Oktay, A. B. and Akgul, Y. S. (2008a). A novel level set based echocardiographic contour extraction method with prior knowledge. In *British Machine Vision Conference*, volume 2, pages 975–84.
- Oktay, A. B. and Akgul, Y. S. (2008b). Prior information based segmentation: A 3d level set surface matching approach”. In *International Symposium on Computer and Information Sciences*.
- Oktay, A. B. and Akgul, Y. S. (2009). Echocardiographic contour extraction with local and global priors through boosting and level sets. In *Proceedings of the IEEE CVPR Workshop on Mathematical Methods in Biomedical Image Analysis*, pages 46–51.
- Oktay, A. B. and Akgul, Y. S. (2010). Kalp duvarlarinin adaboost ve duzey kumesi ile bulunmasi. In *IEEE 18. Sinyal Isleme ve Iletisim Uygulamalari Kurultayi*, pages 503–506, Diyarbakir, Turkey.
- Oktay, A. B. and Akgul, Y. S. (2011). A modular framework for shape and image prior based anatomical structure contour extraction. *Journal of Medical and Biological Engineering (in press)*.
- Osher, S. and Sethian, J. A. (1988). Fronts propagating with curvature dependent speed: algorithms based on hamilton-jacobi formulations. *International Journal of Computational Physics*, 79:12–49.
- Paragios, N. (2003). Shape-based segmentation and tracking in cardiac image analysis. *IEEE Transactions on Medical Imaging*, 22:402–407.
- Platt, J. C. (1999a). *Advances in kernel methods*, pages 185–208. MIT Press, Cambridge, MA, USA. Fast training of support vector machines using sequential minimal optimization.
- Platt, J. C. (1999b). *Advances in Large Margin Classifiers*, pages 61–74.

- Porikli, F. (2005). Integral histogram: A fast way to extract histograms in cartesian spaces. In *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, CVPR '05*, pages 829–836.
- Pujol, O., Rosales, M., Radeva, P., and Nofrarias-fernandez, E. (2003). Intravascular ultrasound images vessel characterization using adaboost. *Functional Imaging and Modeling of the Heart: LNCS*, pages 242–251.
- Qian, X. and Tagare, H. (2006). Overcoming dropout while segmenting cardiac ultrasound images. In *IEEE International Symposium on Biomedical Imaging: Macro to Nano*, pages 105–108.
- Qian, Z., Metaxas, D. N., and Axel, L. (2006). Boosting and nonparametric based tracking of tagged mri cardiac boundaries. In *Medical Image Computing and Computer-Assisted Intervention*, pages 636–644.
- Roth, P. and Winter, M. (2008). Survey of appearance-based methods for object recognition,. *Tech. report ICG-TR-01/08, Inst. for Computer Graphics and Vision, Graz Univ. of Technology*.
- Rousson, M. and Paragios, N. (2002). Shape priors for level set representations. In *ECCV '02: Proceedings of the 7th European Conference on Computer Vision-Part II*, pages 78–92. Springer-Verlag.
- Schapire, R. E. (1990). The strength of weak learnability. *Machine Learning*, 5:197–227.
- Schmidt, S., Bergtholdt, M., Dries, S., and Schnörr, C. (2007). Spine detection and labeling using a parts-based graphical model. *Information Processing in Medical Imaging*, 4584:122–133.
- Seifert, S., Wachter, I., Schmelzle, G., and Dillmann, R. (2009). A knowledge-based approach to soft tissue reconstruction of the cervical spine. *IEEE transactions on medical imaging*, 28(4):494–507.
- Shashua, A., Gdalyahu, Y., and Hayun, G. (2004). Pedestrian detection for driving assistance systems: Single-frame classification and system level performance. In *Proceedings of IEEE Intelligent Vehicles Symposium*, pages 1–6.

- Stegmann, M. B. (2000). Active appearance models: Theory, extensions and cases. *M. Eng. thesis, Informatics and Mathematical Modelling, Technical University of Denmark, Available: <http://www.imm.dtu.dk/~aam/>.*
- Trucco, E. and Verri, A. (1998). *Introductory Techniques for 3-D Computer Vision.* Prentice Hall.
- Tsai, A., Yezzi, A., Wells, W., Tempany, C., Tucker, D., Fan, A., Grimson, W. E., and Willsky, A. (2001). Model-based curve evolution technique for image segmentation. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, volume 1, pages I–463–I–468 vol.1.
- Viola, P., Jones, M., and Snow, D. (2003). Detecting pedestrians using patterns of motion and appearance. In *International Conference on Computer Vision*, pages 734–741.
- Viola, P. and Jones, M. J. (2004). Robust real-time face detection. *International Journal of Computer Vision*, 57(2):137–154.
- Wilson, D. C. and Geiser, E. A. (1992). Automatic center point determination in two-dimensional short-axis echocardiographic images. *Pattern Recognition*, 25(9):893–900.
- Wolf, L. and Bileschi, S. (2006). A critical view of context. *International Journal of Computer Vision*, 69:251–261.
- Yan, P. and Kassim, A. A. (2006). Medical image segmentation using minimal path deformable models with implicit shape priors. *IEEE Transactions on Information Technology in Biomedicine*, 10(4):677–684.
- Z. Peng, J. Zhong, W. W. and Lee, J. H. (2005). Automated vertebra detection and segmentation from the whole spine mr images. In *Conf. Proc. IEEE Engineering in Medicine and Biology Society*.
- Zheng, Y., Nixon, M., and Allen, R. (2004). Automated segmentation of lumbar vertebrae in digital videofluoroscopic images. *IEEE Transactions on Medical Imaging*, 23(1):45 –52.

ÖZGEÇMİŞ

Ayşe Betül Oktay, 22 Nisan 1982 tarihinde Ankara'da doğmuştur. İlk ve orta öğrenimi çeşitli illerdeki okullarda tamamladıktan sonra, 2000 yılında Fatih Üniversitesi Bilgisayar Mühendisliği bölümünde burslu olarak lisans eğitimine başlamıştır ve 2004 yılında mezun olmuştur. 2004-2006 yılları arasında Fatih Üniversitesi Bilgisayar Mühendisliği bölümünde yüksek lisans çalışmasını tamamladıktan sonra, 2007 yılında Gebze Yüksek Teknoloji Enstitüsü Bilgisayar Mühendisliği bölümünde doktora çalışmasına başlamıştır ve aynı kurumda araştırma görevlisi olarak çalışmaktadır.

EK A

TERİMLER

İngilizce-Türkçe

A	
abstraction	soyutlama
appearance	görünüş
active contour	aktif kontur
alignment	hizalama
aspect ratio	en-boy oranı
axis	eksen
B	
bin	sele, sepet
boundary detection	sınırları bulma
C	
cervical	boyuna ait, boyun
chamber	odacık
classification	sınıflandırma
conditional dependence	koşullu bağımlılık
configuration	düzenleniş
contour	kontur, çevrit
contour extraction	çevrit bulma
contour matching	kontur eşleştirme
conventional	geleneksel
converge	yakınsamak
convergence	yakınsama
convolution	evrişim
corpus callosum	korpus kallozum
coupled	bağlaşımlı
cross sectional	kesitsel
curvature	eğrilik, kıvrım
curve	eğri
D	
debug	hata ayıklama
deformable contour	biçim değiştirebilir kontur
deformable model	biçim değiştirebilir model
descriptor	tanımlayıcı, betimleyici

diastole	diyastol
disc	disk
discrete	ayırık
discretized	ayırıklaştırılmış
distribution	dağılım
E	
echocardiogram	ekokardiyogram
echocardiography	ekokardiyografi
edge	kenar
effectiveness	etkinlik
ejection fraction	ejeksiyon fraksiyonu
endocardial	endokardiyal
explicit	açık, mutlak
exponential	üstel
evolution	gelişim
expectation maximization	beklenti enbüyütmesi
F	
feature	özellik, öznitelik
feature extraction	öznitelik çıkarma
fetal	cenine ait
filter	filtre
floroscopic	floroskopik
frame	çerçeve, kare
framework	çerçeve
functional	fonksiyonel
G	
Gaussian	Gauss
global	küresel, global
gradient	gradyan
grid	izgara
ground truth	tam doğrusu
H	
heuristic	sezgisel
Hough transform	Hough dönüşümü
I	
image	imge
imaging modality	görüntüleme kipi
implementation	gerçekleştirim
implicit function	kapalı fonksiyon

inference	çıkarım
initialization	ilklendirme
intensity	parlaklık
interpolation	aradeğerlendirme
intervertebral	intervertebral
iteration	döngü
iterative	döngülü
J	
K	
kare	frame
kernel	çekirdek
Kernel Density Estimation	Çekirdek Yoğunluğu Tahmini
L	
landmark	nirengi
latent variable	gizli değişken
leave-one-out	birini dışında bırakma
level set	düzey kümesi
line	doğru
local	lokal,yerel
localization	konumlama
logistic regression	lojistik bağlanım
lower back pain	bel ağrısı
lumbar	lomber
M	
Machine learning	makina öğrenmesi
medical	tibbi,medikal
modularity	birimsellik, modülerlik
modality	kip
motion	hareket
N	
node	düğüm
noise	gürültü
non-invasive	girişimsel olmayan
normalized cross corelation	normalize edilmiş çapraz ilinti
normalized cut	normalize edilmiş kesme
O	
object detection	nesne saptama
on the fly	çalışırken, anında
occlusion	kapanma

optimal	en iyi
orientation	yönelim
orientational	yönelimsel
outlier	aykırı değer
overtraining	aşırı eğitilme
P	
patch	parça
pixel	imgecik,piksel
point distribution model	nokta dağılım modeli
polar	kutupsal
principal component analysis	ana bileşen analizi
prior	önsel
probabilistic boosting tree	istatistiksel artırma ağacı
Q	
quadtree	dörtlüağac
quantize	nicelemek,nicemlemek
quantization	nicemleme
R	
random variable	rastgele değişken
reconstruction	yeniden çatma
rectangular	dikdörtgensel
recursive	özyinelemeli
re-initialization	yeniden ilklendirme
rigid transformation	katı dönüşüm
robust	dayanıklı
rotation	dönme, döndürme
S	
salt and pepper noise	tuz ve biber gürültüsü
scaling	ölçekleme
segmentation	bölümleme
Sequential minimal optimization	ardışık en küçük eniyileme
short axis	kısa akslı
signal drop-out	sinyal düşmesi
simulated annealing	benzetimli tavlama
singular value decomposition	tekil değer ayrışımı
smoothness	düzlük
snake	yılan
spatial	uzamsal
spatiotemporal	zaman-uzamsal

speckle noise	benek gürültüsü, alacalı gürültü
spinal cord	omirilik
spine	omurga
spline	şerit
steepest descent	dik iniş
Support Vector Machine	destek vektör makinesi
synthetic	sentetik
systole	sistol
T	
template matching	şablon eşleştirme
threshold	esik
training	eğitim
transformation	dönüşüm
translation	öteleme
translational	ötelemesel
transthoracic	göğüsten geçen
trivial	Çözümü görünen, apaçık
U	
W	
warp	eğrilmek
X	
V	
variation	değişim
variational	değişimsel
voxel	voksel
vertebra	omur
vertebral column	omurga
Z	

Türkçe-İngilizce

A	
açık	explicit
aktif kontur	active contour
alacaklı gürültü	speckle noise
anında	on the fly
apaçık	trivial
aradeğerlendirme	interpolation
ardışık en küçük eniyileme	Sequential minimal optimization
aşırı eğitilme	overtraining
aykırı değer	outlier
ayrık	discrete
ayırıklaştırılmış	discretized
B	
bağlaşımlı	coupled
beklenti enbüyükmesi	expectation maximization
bel ağrısı	lower back pain
benek gürültüsü	speckle noise
benzetimli tavlama	simulated annealing
betimleyici	descriptor
biçim değiştirebilir kontur	deformable contour
biçim değiştirebilir model	deformable model
birimsellik	modularity
birini dışında bırakma	leave-one-out
boyuna ait	cervical
bölütleme	segmentation
buluşsal	heuristic
C	
cenine ait	fetal
çalışırken	on the fly
çekirdek	kernel
Çekirdek Yoğunluğu Tahmini	Kernel Density Estimation
çerçeve	frame, framework
çevrit	contour
çevrit bulma	contour extraction
çıkarım	inference
çözümü görünen	trivial
D	
dağılım	distribution

dayanıklı	robust
değişim	variation
değişimsel	variational
destek vektör makinesi	Support Vector Machine
dik iniş	steepest descent
dikdörtgensel	rectangular
disk	disc
diyastol	diastole
doğru	line
döndürme	rotation
döngü	iteration
döngülü	iterative
dönme	rotation
dönüşüm	transformation
dörtlüağaç	quadtree
düğüm	node
düzenleniş	configuration
düzey kümesi	level set
düzlük	smoothness
E	
eğitim	training
eğri	curve
eğrilik	curvature
eğriltmek	warp
ejeksiyon fraksiyonu	ejection fraction
ekokardiyografi	echocardiography
ekokardiyogram	echocardiogram
eksen	axis
en iyi	optimal
en-boy oranı	aspect ratio
endokardiyal	endocardial
eşik	threshold
etkinlik	effectiveness
evrişim	convolution
F	
filtre	filter
floroskopik	fluoroscopic
fonksiyonel	functional
G	

Gauss	Gaussian
geleneksel	conventional
gelişim	evolution
gerçekleştirim	implementation
gizli değişken	latent variable
göğüsten geçen	transthoracic
görüntüleme kipi	imaging modality
görünüş	appearance
gradyan	gradient
gürültü	noise
H	
hareket	motion
hata ayıklama	debug
hızalama	alignment
Hough dönüşümü	Hough transform
I	
izgara	grid
ilkendirme	initialization
imge	image
imgecik	pixel
intervertebral	intervertebral
istatistiksel artırma ağacı	probabilistic boosting tree
J	
K	
kapalı fonksiyon	implicit function
kapanma	occlusion
katı dönüşüm	rigid transformation
kenar	edge
kesitsel	cross sectional
kısa akslı	short axis
kıvrım	curvature
kip	modality
kontur eşleştirme	contour matching
kontur	contour
konumlama	localization
korpus kallozum	corpus callosum
koşullu bağımlılık	conditional dependence
kutupsal	polar
küresel	global

L		
lojistik bağlanım	logistic regression	
lokal	local	
lomber	lumbar	
M		
makina öğrenmesi	Machine learning	
medikal	medical	
modülerlik	modularity	
müdahalesiz	non-invasive	
mutlak	explicit	
N		
nesne saptama	object detection	
nicelemek	quantize	
nicemleme	quantization	
nirengi	landmark	
nokta dağılım modeli	point distribution model	
normalize edilmiş çapraz ilinti	normalized cross correlation	
normalize edilmiş kesme	normalized cut	
O		
odacık	chamber	
omirilik	spinal cord	
omur	vertebra	
omurga	spine	
omurga	vertebral column	
ölçekleme	scaling	
önsel	prior	
öteleme	translation	
ötelemesel	translational	
özellik	feature	
öznitelik	feature	
öznitelik çıkarma	feature extraction	
özyinelemeli	recursive	
P		
parça	patch	
parlaklık	intensity	
piksel	pixel	
Q		
R		
rastgele değişken	random variable	

S	
sele	bin
sentetik	synthetic
sezgisel	heuristic
sınıflandırma	classification
sınırları bulma	boundary detection
sinyal düşmesi	signal drop-out
sistol	systole
soyutlama	abstraction
şablon eşleştirme	template matching
şerit	spline
T	
tam doğrusu	ground truth
tanımlayıcı	descriptor
tekil değer ayrışımı	singular value decomposition
temel bileşen analizi	principal component analysis
tıbbi	medical
tuz ve biber gürültüsü	salt and pepper noise
U	
uzamsal	spatial
üstel	exponential
V	
voksel	voxel
W	
X	
yakınsama	convergence
yakınsamak	converge
yeniden çatma	reconstruction
yeniden ilklendirme	re-initialization
yerel	local
yılan	snake
yönelim	orientation
yönelimsel	orientational
Z	
zaman-uzamsal	spatiotemporal